APROKSIMACIJA FUNKCIJA

Problem

- Problem: odrediti vrednosti nepoznate funkcije $f: x \to y,\ y \in \mathbb{R}$

- Funkcija f je nepoznata u smislu da ne poznajemo tačnu matematičku formulu zavisnosti y od x

- U mogućnosti smo da izvršimo eksperimentalna merenja pomoću kojih možemo da dobijemo vrednosti y u *određenim tačkama* x
  - Poznat nam je skup podataka (x_1,y_1), (x_2,y_2), (x_3,y_3),..., (x_n,y_n).
  - Želimo da odredimo y za x koje nije ni jedno od x_i

Problem

$f: x \to y,\ y \in \mathbb{R}$

Ako uložimo x [1000 $], koliko ćemo zaraditi y [M$] ?

Advertising, budget, and sails dataset

https://www.kaggle.com/datasets/yasserh/advertising-sales-dataset/

	TV Ad Budget ($)	Radio Ad Budget ($)	Newspaper Ad Budget ($)	Sales ($)
1	230.1	37.8	69.2	22.1
2	44.5	39.3	45.1	10.4
3	17.2	45.9	69.3	9.3

Budžet za TV reklame [1000 $]

Prihod od prodaje [M$]

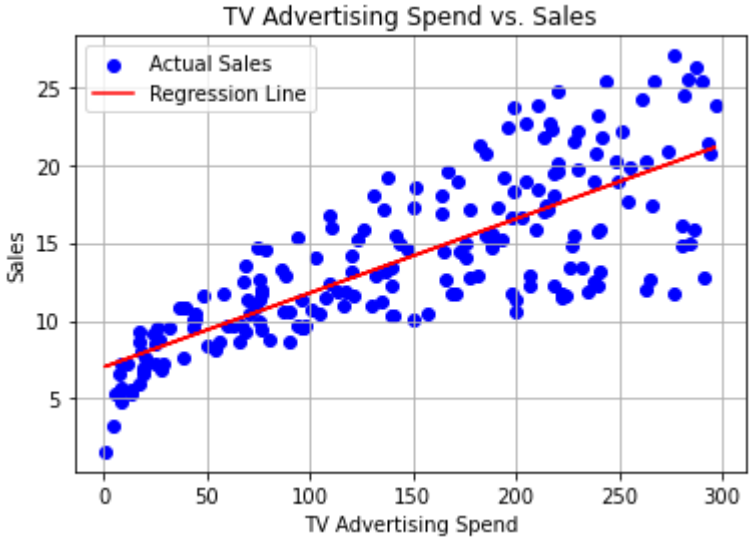

Regresija

- Regresija ima za cilj da pronađe funkciju koja se “najbolje uklapa” u podatke.
- Rezultujuća funkcija ne mora da prođe kroz svaku tačku
- Ako koristimo polinom, njegov stepen ne zavisi od broja tačaka, već ga zadaje korisnik

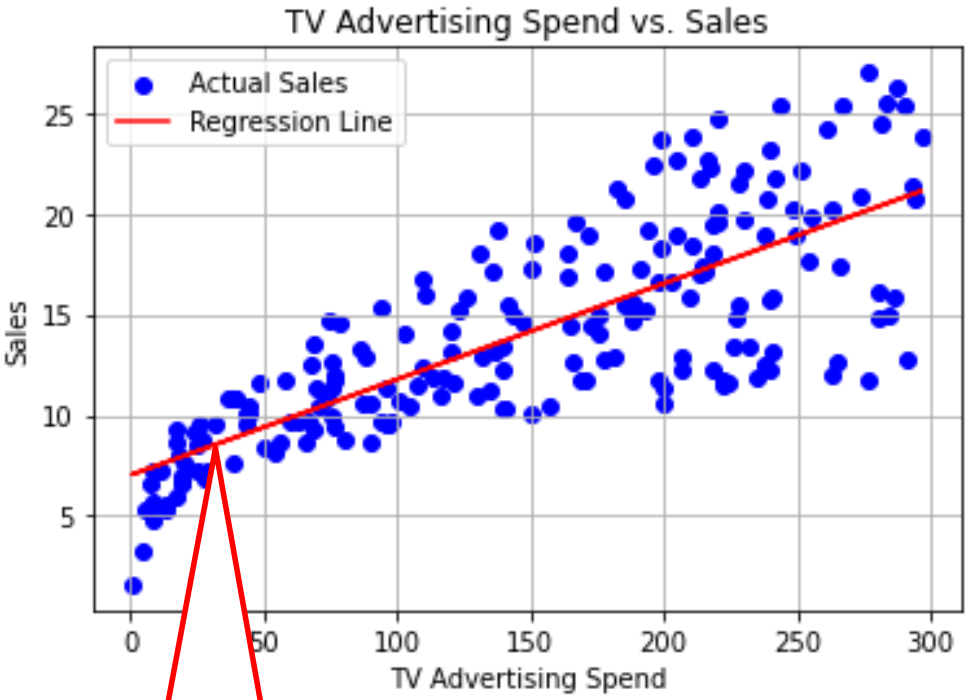

Tražimo trend u podacima.

Opisujemo ga pomoću funkcije.

Na slici je dat primer linearnog trenda

Određivanje cene nekretnine na osnovu njene kvadrature

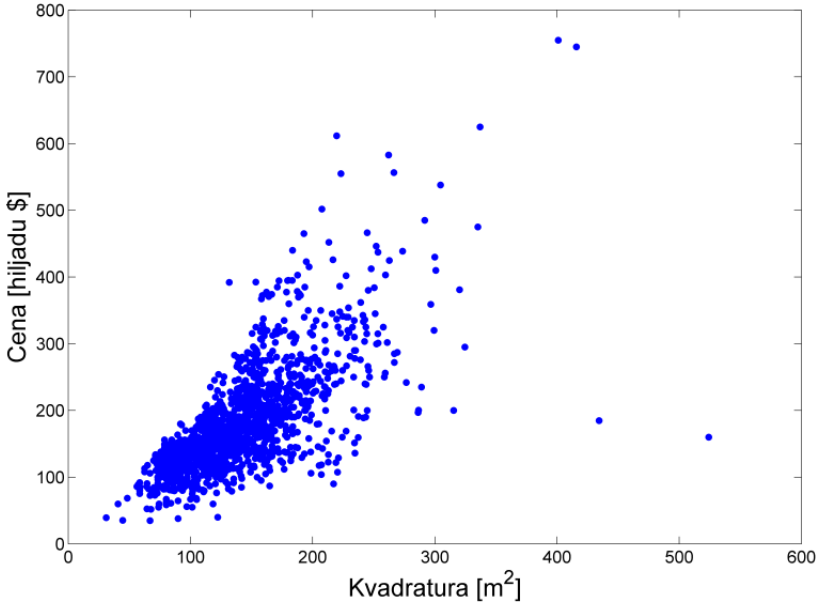

- Postoje nekretnine iste kvadrature, a različitih cena
- Razlike mogu da potiču od faktora koje nismo uključili u razmatranje
  - lokacija, godina izgradnje, kvalitet,...
- Otkrivamo trend u podacima: formulu kako se cena nekretnine menja sa porastom kvadrature

- Otkrivamo trend → adekvatno je primeniti regresiju
- Ne insistiramo da ako nekretnina ima istu kvadraturu kao neka iz skupa podataka, mora imati i potpuno istu cenu
- U realnosti, cene bi bile bliske ali ne nužno identične

Motivacioni primer

- Kao jedan od primera upotrebe regresije uzećemo predikciju ishoda utakmica u *Premier* ligi.
- Tim koji stoji iza sajta http://www.football-data.co.uk/ , želeo je da napravi model za “fer” kvote za utakmice.
- “Fer”: kvota nije definisana sa ciljem zarade od tuđeg klađenja (kao kod kladionica), već predstavlja stvarnu verovatnoću događaja

Motivacioni primer

- Pretpostavka: razlika u broju datih i primljenih golova na *prethodnim* utakmicama je dobar indikator kvaliteta tima
  - Odlučeno je da se posmatra period od 6 utakmica koje prethode utakmici čiji ishod predviđamo
- Kreiran je indikator koji su nazvali rejting utakmice (*Match Rating*, MR):

$$MR = RG_{domaći\ tim} - RG_{gostujući\ tim},$$

- gde RG predstavlja razliku u golovima:

$$RG = broj\ datih\ golova - broj\ primljenih\ golova.$$

Motivacioni primer

$$MR = RG_{domaći\ tim} - RG_{gostujući\ tim}$$

$$RG = broj\ datih\ golova - broj\ primljenih\ golova$$

- Primer:
  - Domaćin*: Manchester,* gost*: Liverpool*
  - Neka je u toku prethodnih 6 utakmica:
    - *Manchester* dao 10 golova, a primio 5: $RG_{Manchester} = 10 - 5 = 5$
    - *Liverpool* dao 6 golova, a primio 4: $RG_{Liverpool} = 6 - 4 = 2$
    - U tom slučaju je za razmatranu utakmicu:

$$MR = RG_{Manchester} - RG_{Liverpool} = 5 - 2 = 3$$

Motivacioni primer

- Uz dovoljno istorijskih podataka, možemo iskoristiti MR utakmice da predvidimo verovatnoću:
  - pobede domaćina
  - nerešenog ishoda
  - pobede gostujućeg tima

- Za primer utakmice *Manchester/Liverpool* sa MR=3, moramo videti koliko često se MR=3 završava pobedom domaćina, nerešenim rezultatom i pobedom gosta

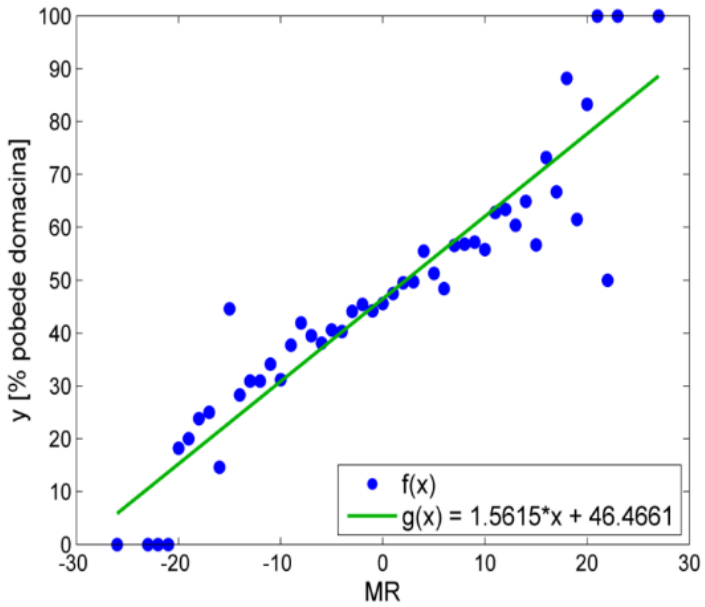

Motivacioni primer

- Posmatrane su sve utakmice od 1993. do 2001. godine
- Za svaku je zabeležen je MR i ishod utakmice

Neočekivano – ovo je samo ocena verovatnoće i to na malom broju utakmica

	MR	Br. pobeda domaćina	Br. nerešenih utakmica	Br. pobeda gostujućeg tima	% pobede domaćima	% nerešenih utakmica	% pobeda gostujućeg tima
Slab domaćin (malo utakmica)	-26	0	1	1	0.0%	50.0%	50.0%
	-23	0	0	2	0.0%	0.0%	100.0%
	-22	0	0	3	0.0%	0.0%	100.0%
	⋮	⋮	⋮	⋮	⋮	⋮	⋮
	-1	375	251	222	44.2%	29.6%	26.2%
Ujednačeno (najviše utakmica)	0	414	259	235	45.6%	28.5%	25.9%
	1	412	243	212	47.5%	28.0%	24.5%
	⋮	⋮	⋮	⋮	⋮	⋮	⋮
	22	1	0	1	50.0%	0.0%	50.0%
Jak domaćin (malo utakmica)	23	1	0	0	100.0%	0.0%	0.0%
	27	1	0	0	100.0%	0.0%	0.0%

Motivacioni primer

- Kreiran regresioni model:

$$x = MR, y = P_{pobeda\ domaćina}$$

  - (*P* - *%* pobeda)

- „Fer“ kvota:

$$kvota = \frac{1}{P_{pobeda\ domaćina}}$$

  - Na primer, ako je procenat pobede domaćina 46.7%, kvota je $1/0.467 = 2.14$

Motivacioni primer

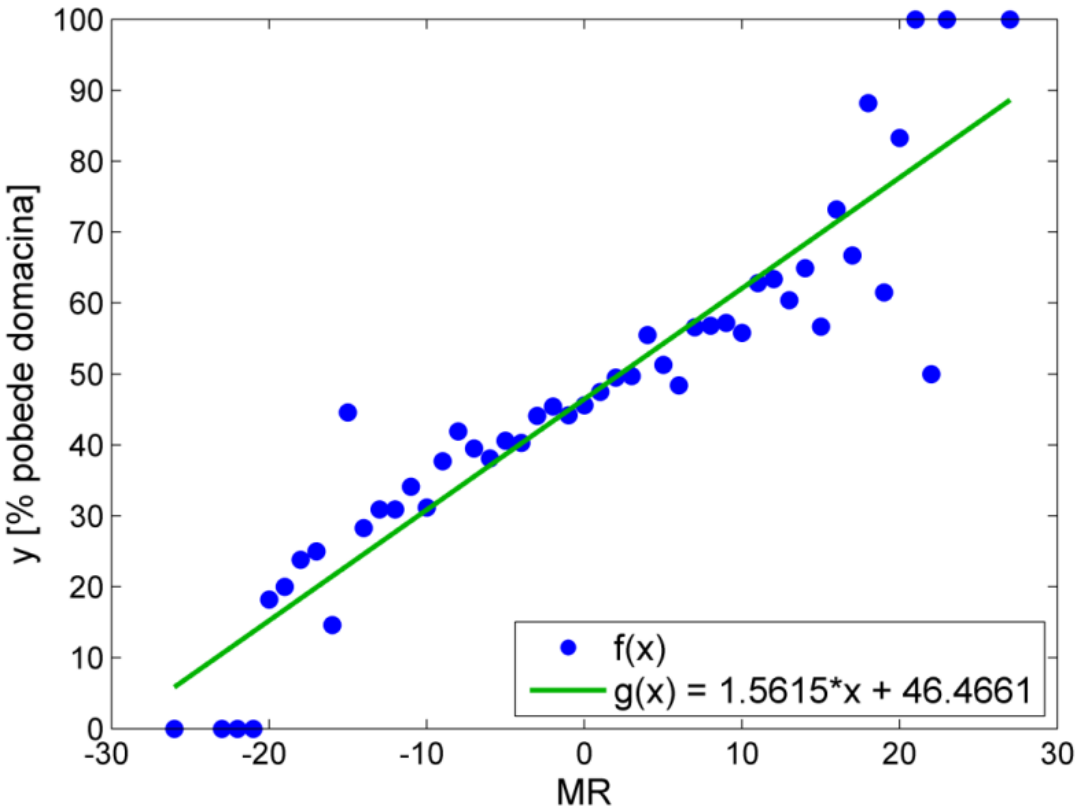

- Sa porastom rejtinga utakmice raste i % pobede domaćina
- Linearan trend

- Za utakmicu čiji je rejting $MR = 10$, procenjena verovatnoća pobede je $0.0156 \cdot 10 + 0.4647 = 0.621$
- (62% šanse da pobedi domaćin)
- Fer kvota $1/0.621 = 1.61$

Motivacioni primer

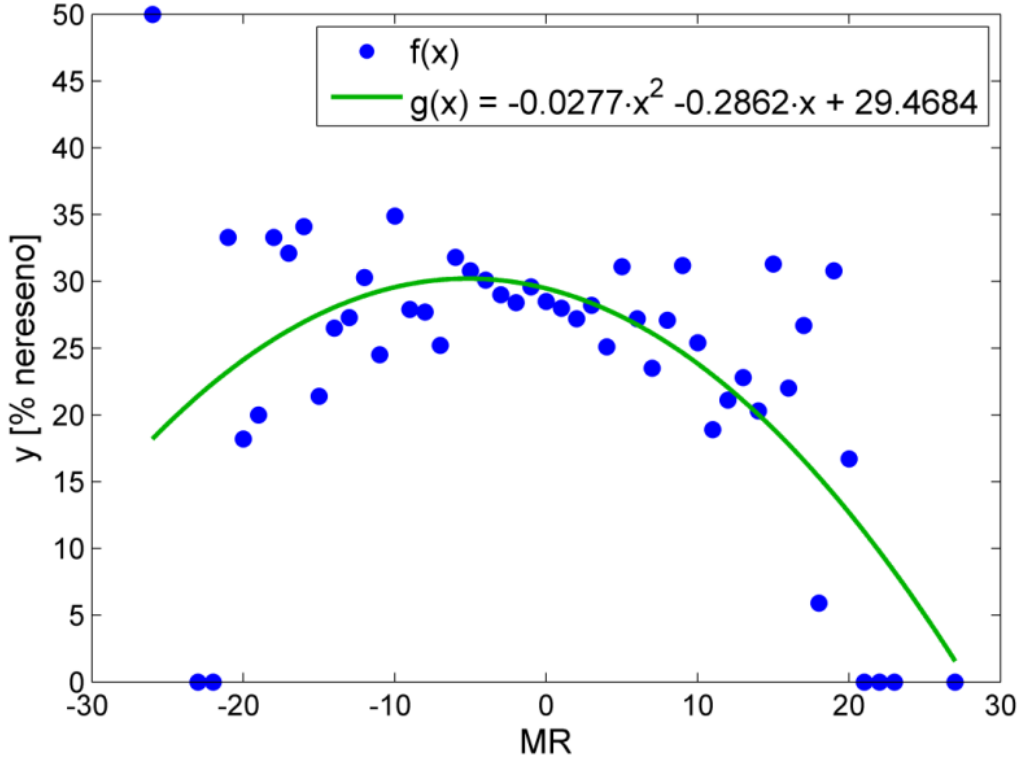

- Sa porastom rejtinga utakmice opada % nerešenih ishoda
- U podatke se najbolje uklopa parabola (kvadratna zavisnost)

Motivacioni primer

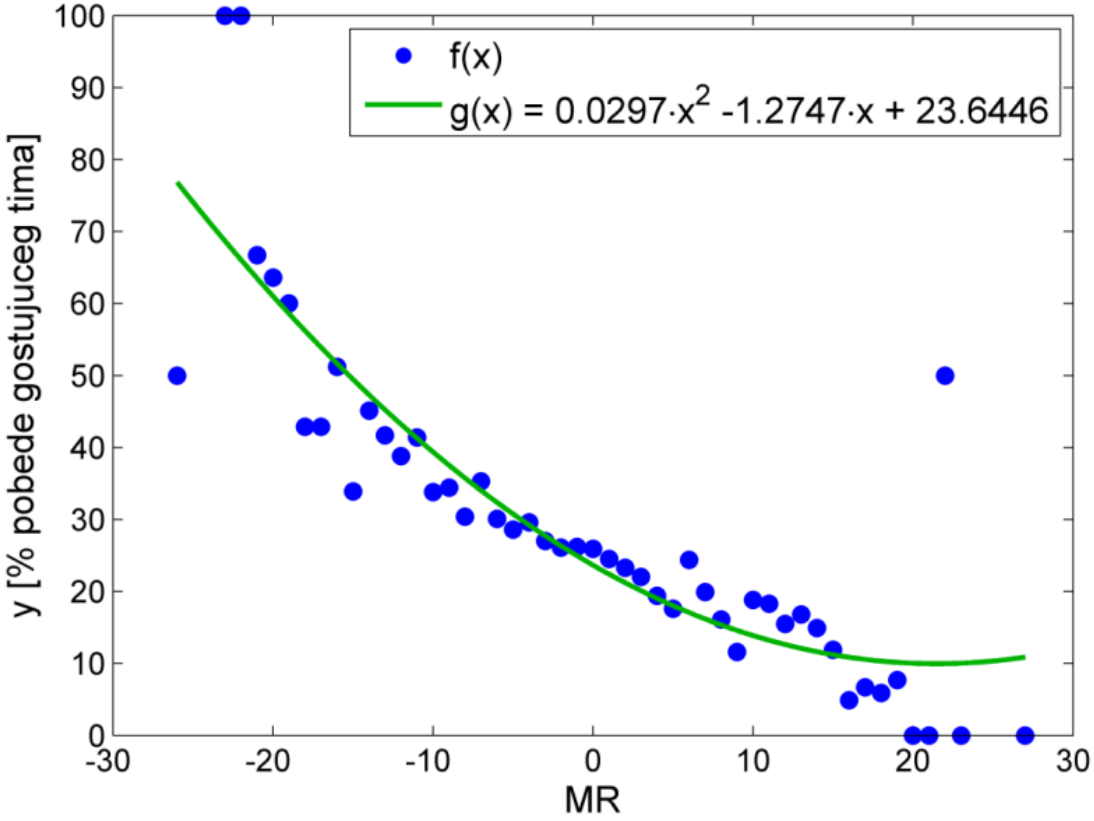

- Sa porastom rejtinga utakmice opada % pobede gostujućeg tima
- U podatke se najbolje uklopa parabola (kvadratna zavisnost)

Motivacioni primer

- Prilikom kreiranja modela su korišćeni podaci o utakmicama iz 1993. - 2001.
- Rezultate možemo evaluirati na podacima iz 2002.
- Rezultati:
  - Opklada na sve utakmice bi donela profit od 2.1%
  - Opklada na „neizvesne utakmice“(-2<MR<2) bi donela profit od 10.13%
    - Model je najpouzdaniji upravo na ovim podacima jer ima mnogo više utakmica sa rejtingom bliskim nuli u odnosu na ekstremne vrednosti rejtinga
  - „Slepo“ klađenje na domaćina bi donelo gubitak od 3.73%
- Prednost modela jeste i što se radi o automatskom sistemu – nije neophodno da se razumemo u fudbal

Regresija opšti problem

- Za zadate:
  - podatke $\{(x_i, y_i), i = 1, \dots, N\}$,
  - oblik funkcije $g(x)$,
  - i kriterijum za meru „najboljeg uklapanja“,
- Odrediti nepoznate parametre funkcije $g(x)$

Regresija opšti problem

- Postoji više mogućnosti za oblik funkcije $g(x)$. Zavisno od njega, imamo različit broj parametara koje treba da odredimo:
  - Linearni (prava): $g(x) = a \cdot x + b$
  - Kvadratni polinom: $g(x) = a \cdot x^2 + b \cdot x + c$
  - Polinom stepena D: $g(x) = \sum_{d=0}^{D} a_d x^d$
  - Opšti oblik funkcije: $g(x) = \sum_{m=0}^{M} a_m g_m(x)$, gde su $g_m(x)$ unapred zadate proizvoljne funkcije

Regresija opšti problem

- „Najbolje uklapanje“ u funkciju $y = f(x)$ se može definisati na više načina

- Regresija – jedna od strategija je regresija najmanjih kvadrata (*Least Squares Regression*)
- Nepoznate koeficijente funkcije g ćemo odrediti minimizacijom sume kvadrata grešaka:
  $\sum_{i=1}^{N} e_i^2 = \sum_{i=1}^{N} \left(y_i - g(x_i)\right)^2$

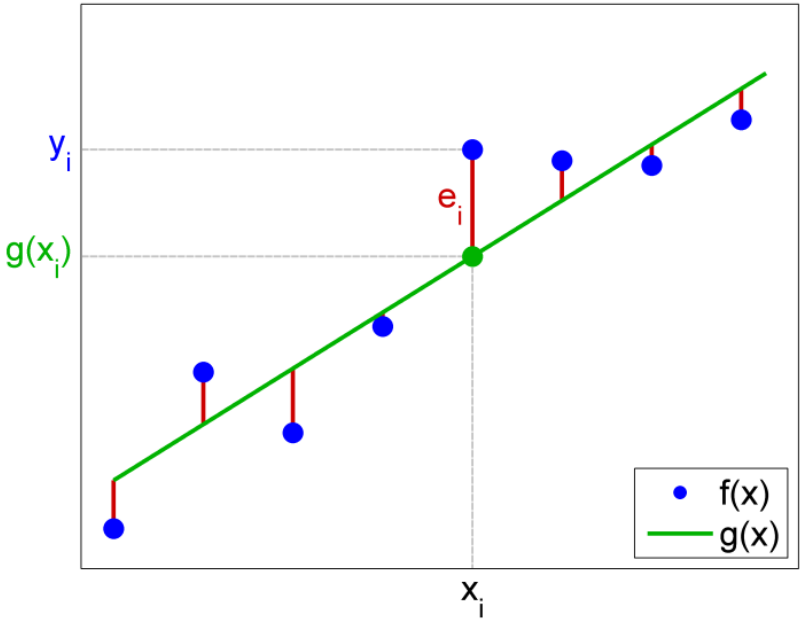

Linearna regresija

- Metod za određivanje koeficijenata prikazaćemo na primeru linearne regresije.
- Oblik funkcije koju koristimo je prava

$$g(x)=ax+b$$

- Zadatak nam je da odredimo a i b, tako da je vrednost funkcije greške minimalna

$$\Phi(a,b)=\sum_{i=1}^{n}(b+ax_i-y_i)^2$$

- Primetite da vrednost $\Phi(a,b)$ zavisi isključivo od *a* i *b*
  - (x_i, y_i) su konstante (nepromenljivi zadati podaci)

Linearna regresija
određivanje koeficijenata

- Da bi odredili minimun funkcije greške, izjednačavamo njene parcijalne izvode po a i b sa nulom.

$$\frac{\partial\ \Phi(a,b)}{\partial\ a} = 0$$

$$\frac{\partial\ \Phi(a,b)}{\partial\ b} = 0$$

Linearna regresija
određivanje koeficijenata

$$\Phi(a,b) = \sum_{i=1}^{n} (b + ax_i - y_i)^2$$

$$\frac{\partial\ \Phi(a,b)}{\partial\ a} = \sum_{i=1}^{n} 2\left(b + ax_i - y_i\right)x_i = 0$$

$$\frac{\partial\ \Phi(a,b)}{\partial\ b} = \sum_{i=1}^{n} 2\left(b + ax_i - y_i\right) = 0$$

Linearna regresija
određivanje koeficijenata

$$\frac{\partial\ \Phi(a,b)}{\partial\ a} = \sum_{i=1}^{n} 2\left(b + ax_i - y_i\right)x_i = 0$$

$$\frac{\partial\ \Phi(a,b)}{\partial\ b} = \sum_{i=1}^{n} 2\left(b + ax_i - y_i\right) = 0$$

$$\left(\sum_{i=1}^{n} x_i\right) b + \left(\sum_{i=1}^{n} x_i^2\right) a = \left(\sum_{i=1}^{n} x_i\ y_i\right)$$

$$n\,b + \left(\sum_{i=1}^{n} x_i\right) a = \left(\sum_{i=1}^{n} y_i\right)$$

Linearna regresija
određivanje koeficijenata

$$\left(\sum_{i=1}^{n} x_i\right) b + \left(\sum_{i=1}^{n} x_i^2\right) a = \left(\sum_{i=1}^{n} x_i\, y_i\right)$$

$$n\, b + \left(\sum_{i=1}^{n} x_i\right) a = \left(\sum_{i=1}^{n} y_i\right)$$

$$a = \frac{n\left(\sum_{i=1}^{n} x_i\, y_i\right) - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n\left(\sum_{i=1}^{n} x_i^2\right) - \left(\sum_{i=1}^{n} x_i\right)^2}$$

$$b = \frac{1}{n}\left(\left(\sum_{i=1}^{n} y_i\right) - a\left(\sum_{i=1}^{n} x_i\right)\right)$$

Linearna regresija
Primer

- Posmatramo 10 planinara. Merimo njihovo vreme hodanja i pređeni put.

Planinar	Vreme hodanja (h)	Pređeni put (km)
1	2	10
2	2	11
3	3	12
4	4	13
5	4	14
6	5	15
7	6	20
8	7	18
9	8	22
10	9	25

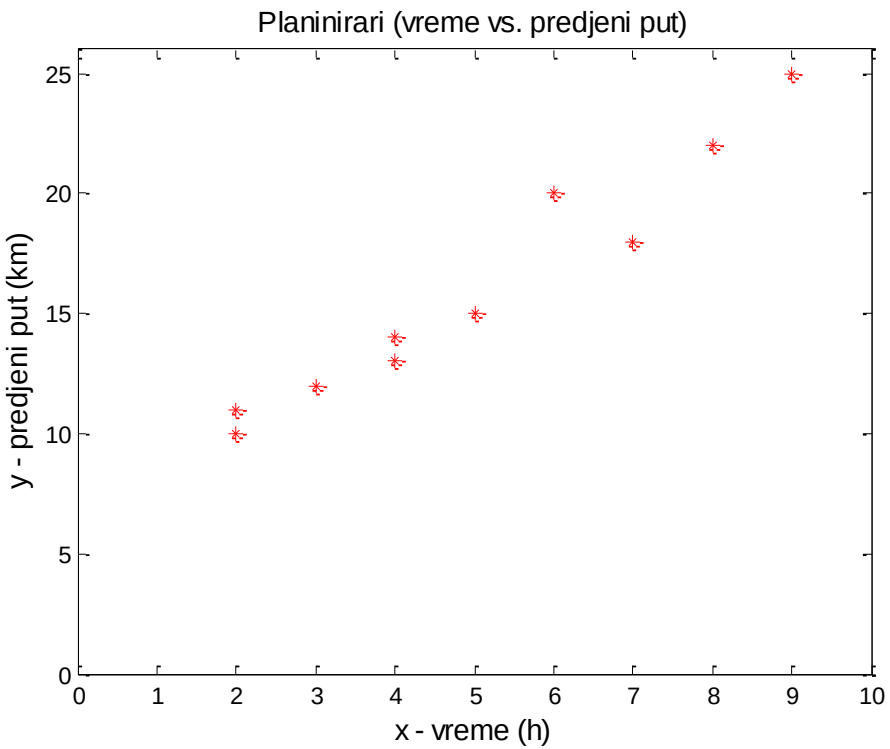

Linearna regresija
Primer

- Oblik funkcije je prava: f(x) = ax+b
- Podaci:

Planinar	Vreme hodanja (h)	Pređeni put (km)
1	2	10
2	2	11
3	3	12
4	4	13
5	4	14
6	5	15
7	6	20
8	7	18
9	8	22
10	9	25

Jednačine za a i b:

$$n\,b + \left(\sum_{i=1}^{n} x_i\right) a = \left(\sum_{i=1}^{n} y_i\right)$$

$$\left(\sum_{i=1}^{n} x_i\right) b + \left(\sum_{i=1}^{n} x_i^2\right) a = \left(\sum_{i=1}^{n} x_i\, y_i\right)$$

Linearna regresija
Primer

- Izračunavamo potrebne vrednosti:

#i	1	2	3	4	5	6	7	8	9	10	Σ
x_i	2	2	3	4	4	5	6	7	8	9	50
y_i	10	11	12	13	14	15	20	18	22	25	160
x_i^2	4	4	9	16	16	25	36	49	64	81	304
$x_i\ y_i$	20	22	36	52	56	75	120	126	176	225	908

- Dobijamo jednačine

$$n\,b + \left(\sum_{i=1}^{n} x_i\right) a = \left(\sum_{i=1}^{n} y_i\right) \qquad \Rightarrow 10b + 50a = 160$$

$$\left(\sum_{i=1}^{n} x_i\right) b + \left(\sum_{i=1}^{n} x_i^2\right) a = \left(\sum_{i=1}^{n} x_i\ y_i\right) \Rightarrow 50b + 304a = 908$$

Linearna regresija
Primer

- Rešavamo sistem

$$10b + 50a = 160$$

$$50b + 304a = 908$$

- Rešenje je a=2, b=6 dakle:

f(x)=2x+6

Linearna regresija
Primer

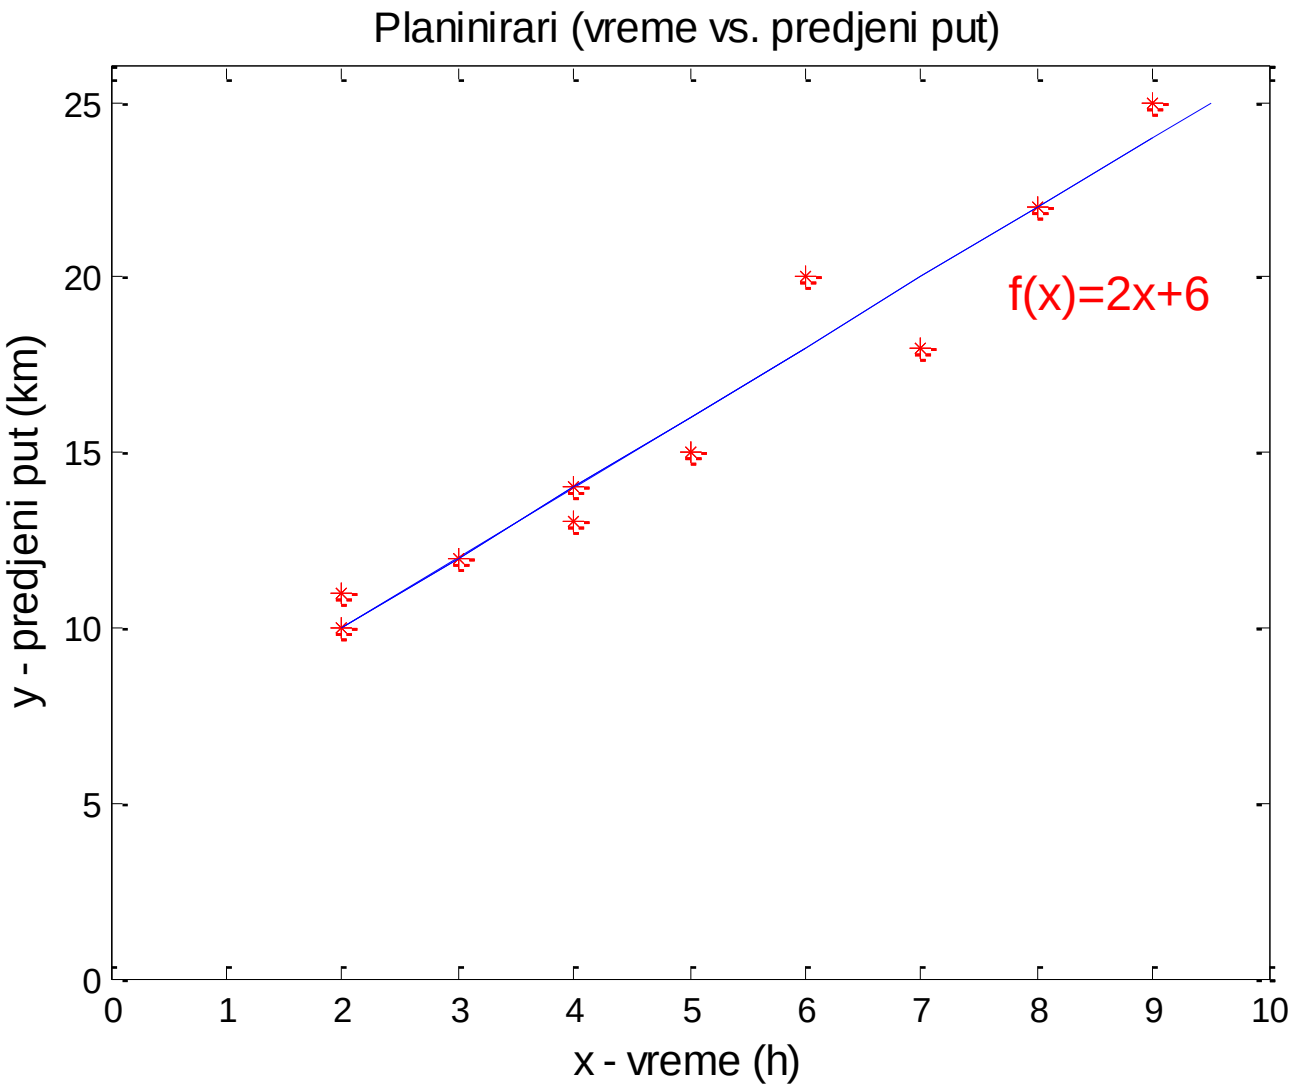

Merenje kvaliteta regresione funkcije

- Iako se pomoću grafika može utvrditi koliko se regresiona funkcija uklapa u podatke,
- Potreban nam je automatski način da izmerimo kvalitet regresione funkcije.
- Na sledećih nekoliko slajdova pokazaćemo na koji način to možemo da uradimo.

Merenje kvaliteta regresione funkcije

- Ako je $g(x_i)$ procena regresione funkcije, a y_i data vrednost, prvo što možemo da uradimo je da saberemo kvadrate grešaka.

$$SSE = \sum_{i=1}^{n} (g(x_i) - y_i)^2 = \sum_{i=1}^{n} (b + ax_i - y_i)^2$$

- SSE – *sum of squares error*
- Za primer sa šetačima imamo SSE=12.
- Da li je 12 mala ili velika vrednost?
- Potrebna nam je vrednost u odnosu na koju ćemo da uporedimo SSE.

Merenje kvalitet regresione funkcije

- Da bismo odredili vrednost sa kojom poredimo SSE, postavljamo sledeće pitanje:
- Kako bismo odredili funkciju f, ako ne bismo imali informaciju x (nezavisnu promenljivu) već samo y?

- Pošto nemamo informaciju o vremenu (nemamo x), najbolja moguća procena za pređeni put tj. *y* je $\bar{y}$ (*srednja vrednost* pređenog puta).
- Morali bismo da koristimo $\bar{y} = 16$ da procenimo broj pređenih kilometara za svakog od planininara, bez obzira na to koliko je ta osoba dugo hodala.

Merenje kvalitet regresione funkcije

- Ako označimo f(x) sa $\tilde{y}$ za primer sa planinarima imamo sledeći slučaj

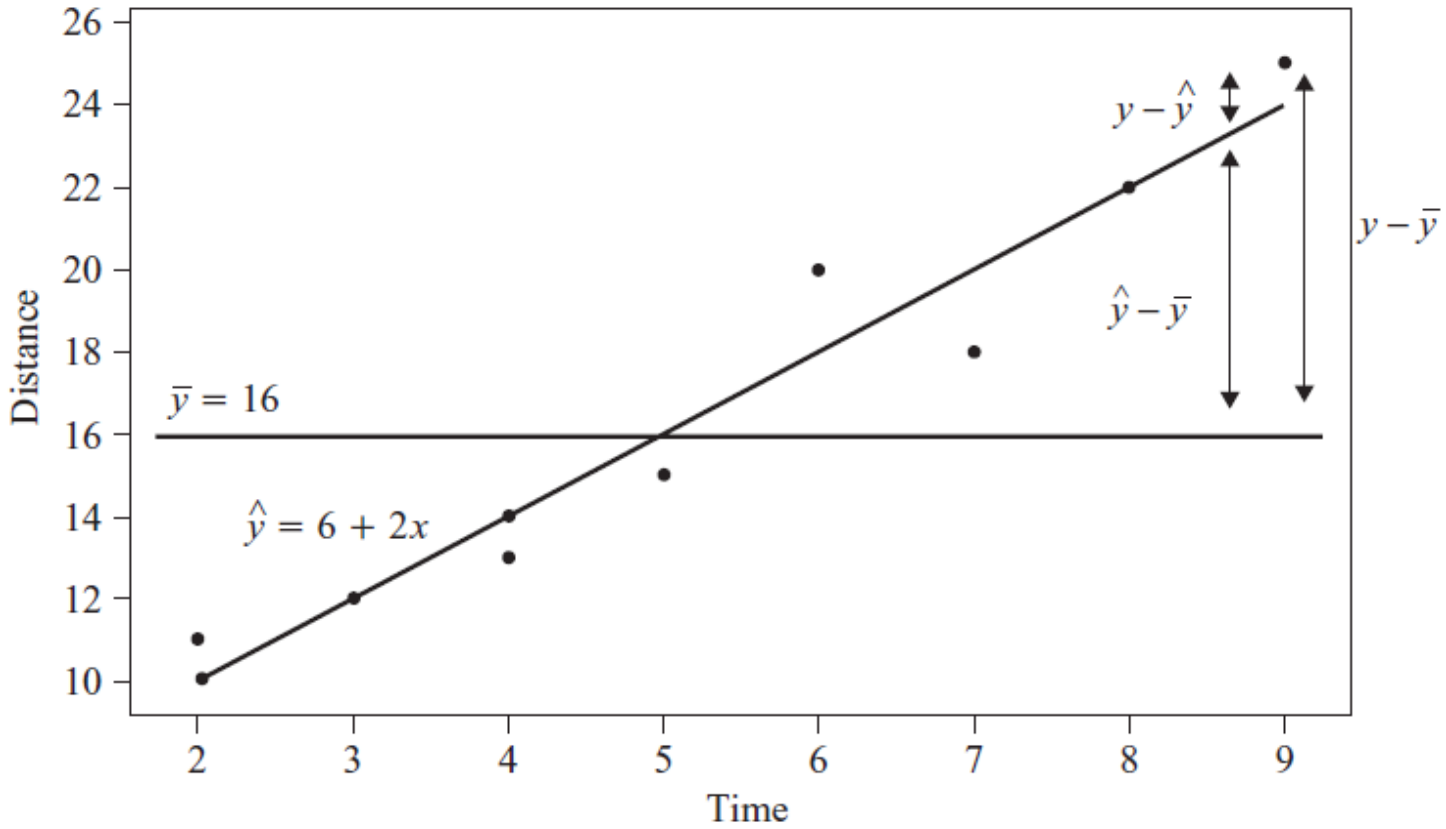

Merenje kvalitet regresione funkcije

- Razlika $y - \bar{y}$ predstavlja grešku u proceni prilikom upotrebe samo srednje vrednosti *y* promenljive.
- Ako sumiramo ove greške dobijamo sumu kvadrata grešaka (*sum of squares total*, SST):

$$SST = \sum (y - \bar{y})^2$$

- Da li se očekuje da će vrednost *SST* biti manja ili veća od vrednosti *SSE*?

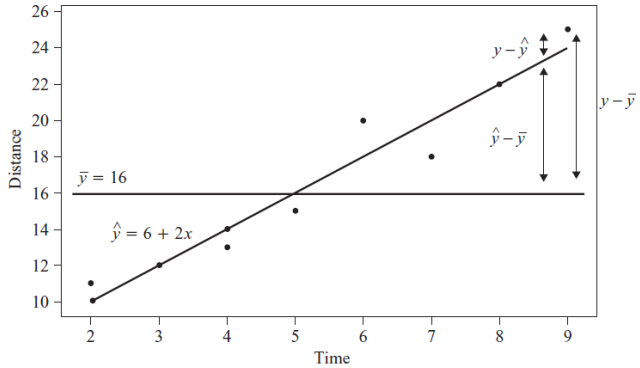

Merenje kvalitet regresione funkcije

- Za naš primer sa šetačima imamo *SST* = 228, što je mnogo veće od vrednosti *SSE* = 12.
- Sada imamo vrednost u odnosu na koju ćemo da poredimo *SSE*.
- Činjenica da je vrednost *SSE* mnogo manja u odnosu na vrednost *SST*,
- je indikator toga da upotreba nezavisne promenljive tj. vremena hodanja poboljšava rezultate procene pređenog puta u odnosu na slučaj kad nam informacija o vremenu nije poznata.

Merenje kvalitet regresione funkcije

- Da bi izmerili koliko upotreba nezavisne promenljive poboljšava kvalitet regresije izračunavamo sumu *kvadrata grešaka regresije* (*sum of squares regression*):

$$SSR = \sum (\tilde{y} - \bar{y})^2$$

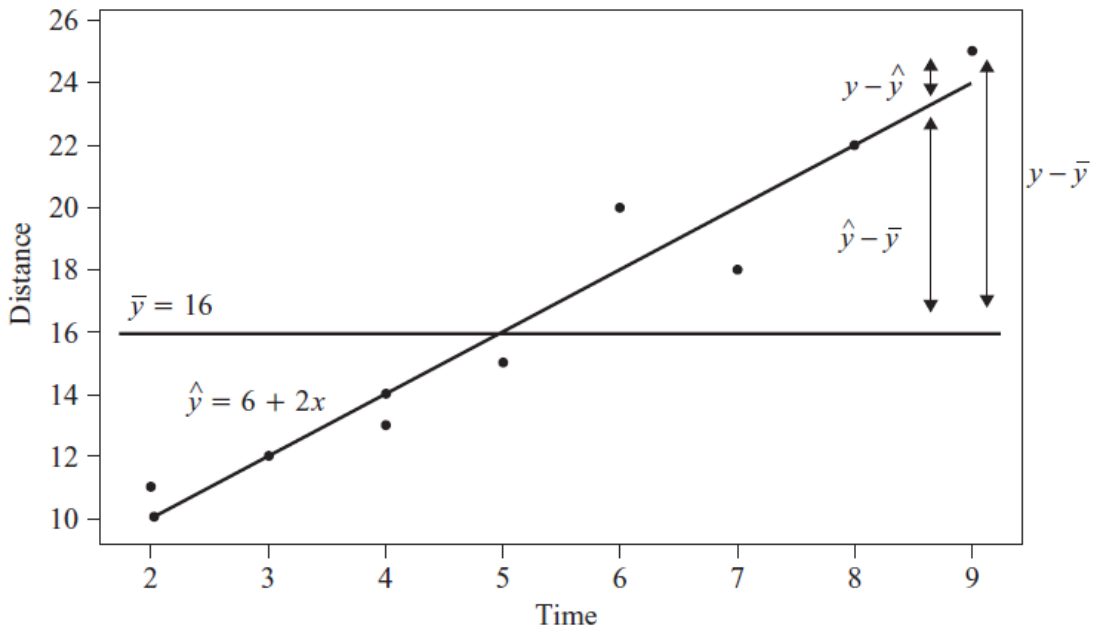

Koeficijent determinacije

- Sada možemo da uvedemo koeficijent determinacije (*coefficient of determination*) r^2, koji služi za merenje kvaliteta regresije:

$$R^2 = \frac{SSR}{SST}$$

- R^2 meri deo varijabilnosti promenljive *y* koji se može objasniti pomoću regresione jednačine

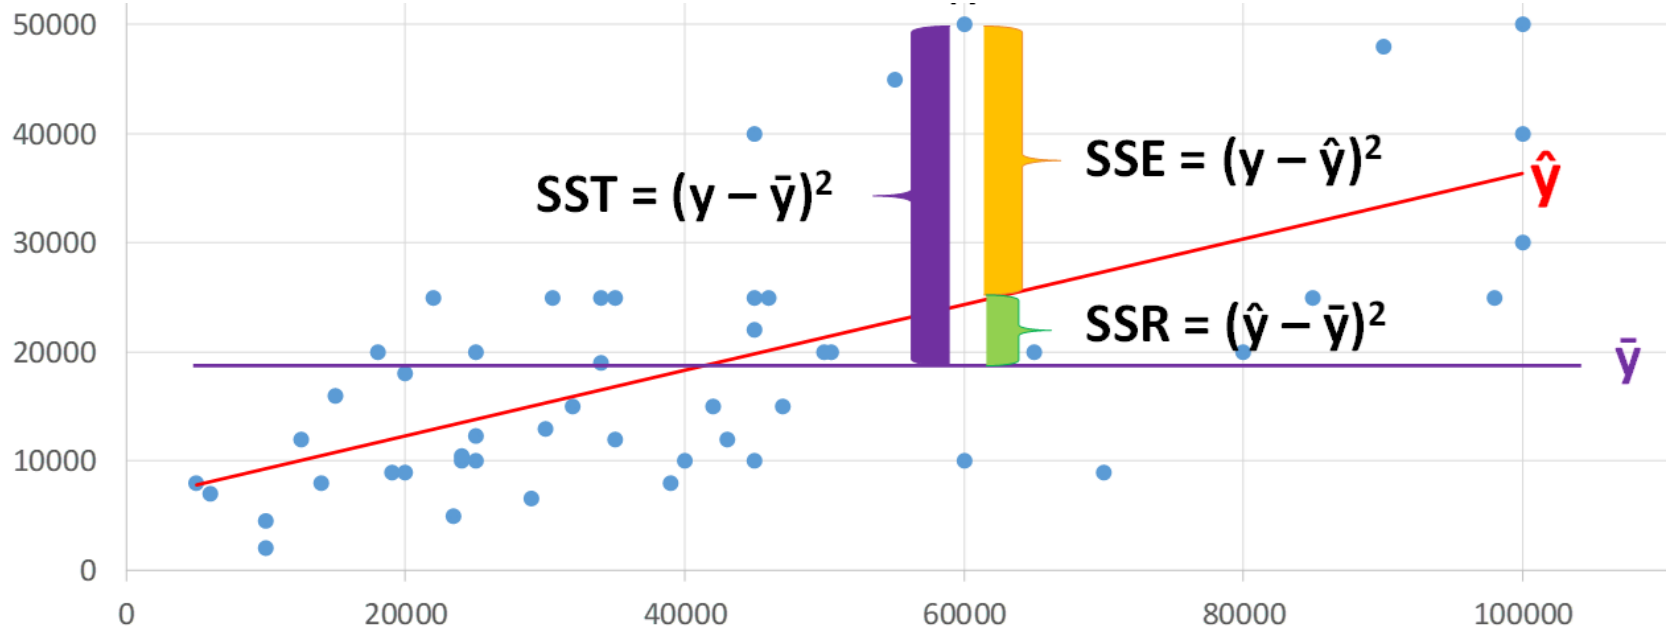

Koeficijent determinacije

$$r^2 = \frac{SSR}{SST}$$

- Koje su minimalne i maksimalne vrednosti za r^2 ?
- Ako regresija ne donosi nikakvo poboljšanje u odnosu na samo srednju vrednost tj:

$$\tilde{y} = \bar{y} \quad SSR = \sum (\tilde{y} - \bar{y})^2 = \sum (\bar{y} - \bar{y})^2 = 0$$

onda je SSR=0 iz čega sledi r^2=0.

- Ako se regresiona prava savršeno uklapa u date podatke tj:

$$y = \tilde{y} \quad SSR = \sum (\tilde{y} - \bar{y})^2 = \sum (y - \bar{y})^2 = SST$$

onda je SSR=SST iz čega sledi r^2=1.

Koeficijent determinacije

- Za primer sa planinarim imamo:

$$r^2 = \frac{SSR}{SST} = \frac{216}{228} = 0{,}947$$

što znači da je približno 95% varijabilnosti u vrednostima za pređeni put objašnjeno pomoću informacija o vremenu šetanja.

Tipična greška procene

- Mera tačnosti procene dobijene pomoću regresione jednačine:

$$s = \sqrt{\frac{SSE}{n - m - 1}}$$

gde je *n* broj tačaka u datom skupu podataka, a *m* je broj nezavisnih promenljivih, što je za naš slučaj 1.

- Intuitivno, na ovaj način merimo koliko regresiona funkcija tipično odstupa od datih tačaka.

Tipična greška procene

- Za primer sa planinarima imamo:

$$s = \sqrt{\frac{12}{10-1-1}} = 1.2$$

što znači da kada koristimo našu regresionu jednačinu za procenu pređenog puta za za dato vreme, tipično grešimo za 1.2 km.

Koeficijent korelacije

- Predstavlja idikator “snage” linearnog odnosa dve promenljive:

$$r = \frac{\sum (x - \bar{x})(y - \bar{y})}{(n-1)s_x s_y}$$

- gde su s_x ,s_y standardne devijacije za vrednosti promenljivih x i y.

$$s_x = \sqrt{\frac{\sum_{i=1}^{n} (x - \bar{x})^2}{n}} \qquad s_y = \sqrt{\frac{\sum_{i=1}^{n} (y - \bar{y})^2}{n}}$$

Koeficijent korelacije

- Vrednost koeficijenta korelacije je u intervalu [-1,1] i tumači se na sledeći način:
  - Vrednosti blizu 1 znače jaku pozitivnu korelaciju
    - ako se povećava x povećava se y
  - Vrednosti blizu -1 znače jaku negativnu korelaciju
    - ako se povećava x smanjuje se y
  - Vrednost blizu 0 znači da ne postoji korelacija između x i y.
- Šta znači blizu 1 ili -1, zavisi od oblasti iz koje potiču podaci.
- Ako su u pitanju prirodne nauke teži se vrednostima koje su vrlo blizu 1, dok je kod društvenih nauka (gde podaci uglavnom dolaze iz eksperimenata sa ljudima) vrednosti ne moraju biti uz 1.

Koeficijent korelacije

- Generalni savet za tumačenje vrednosti:
  - [0.7, 1] jaka korelaciija
  - [0.33, 0.7] srednja korelacija
  - [0, 0.33] nema korelacije
  - iste vrednosti samo negativne važe za negativnu korealciju

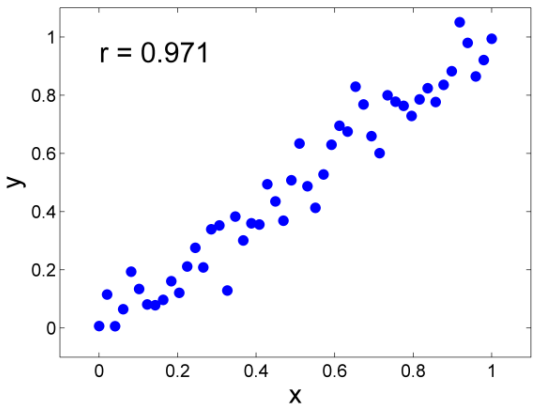

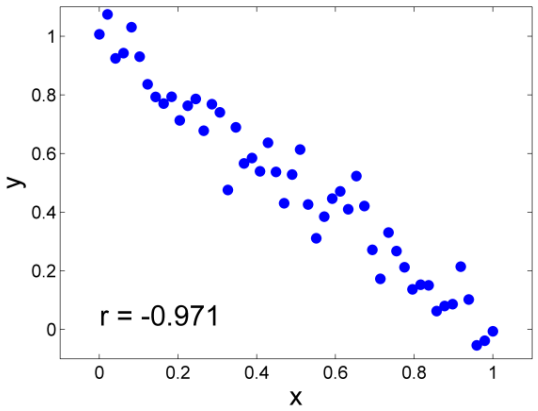

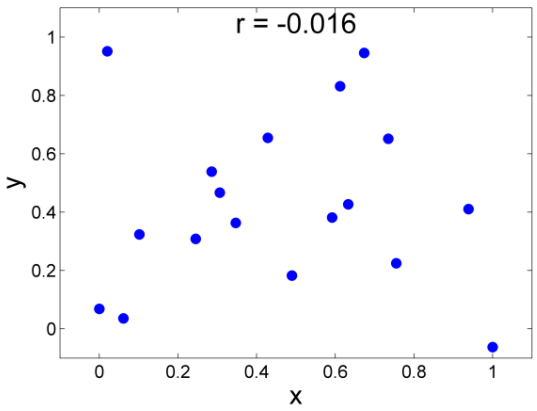

Koeficijent korelacije

- Za primer sa planinarima imamo

$$r=0.9773$$

- Što znači, da postoji jaka pozitivna korelacija između vremena hodanja i pređenog puta.
- Pozitivna vrednost znači da sa povećanjem vremena hodanja povećava se i pređeni put.

Ne-linearna regresija

- Do sada smo obrađivali slučaj kad je regresiona funkcija prava.
- Međutim, trend u podacima nije uvek linearan.
- Tada regresiju vršimo krivom.

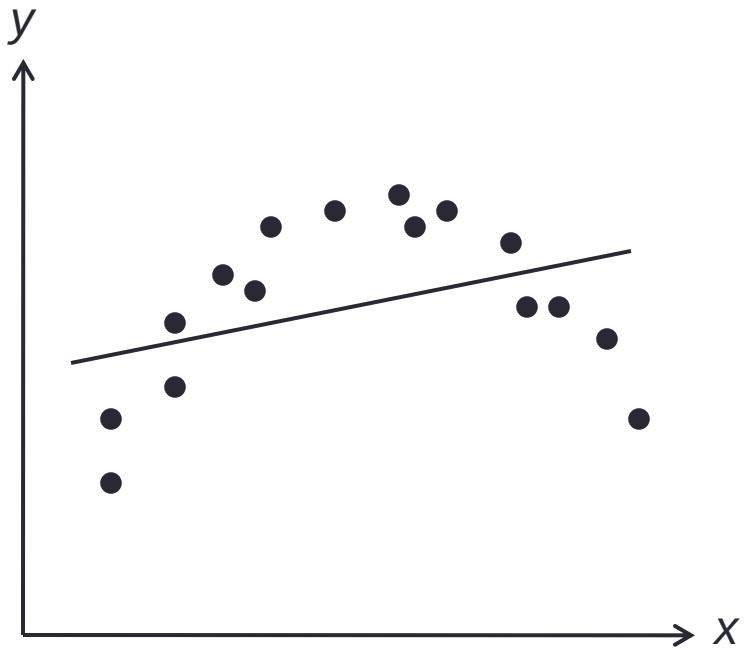

Linearna regresija

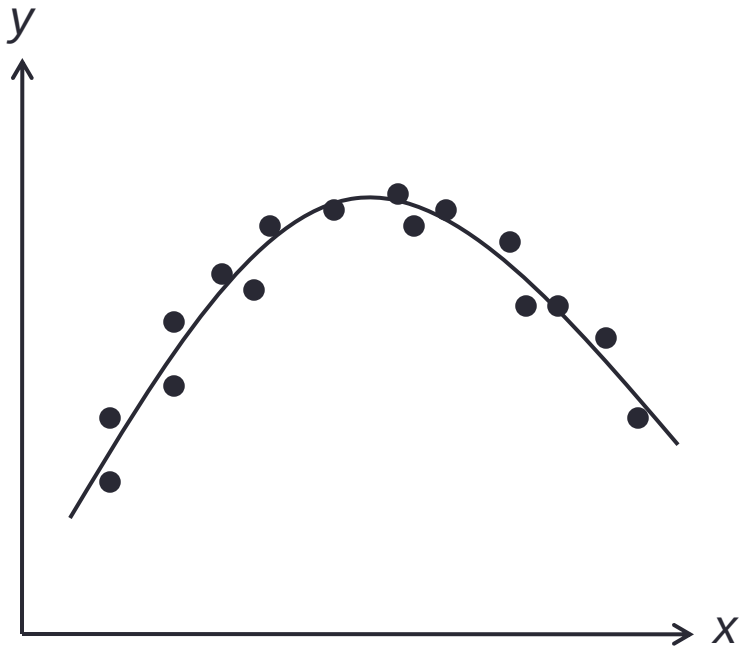

Regresija parabolom

Regresija polinomom

- Regresija najmanjih kvadrata može da se uopšti za polinom proizvoljnog stepena.
- Dat je primer polinoma drugog stepena.

$$\mathrm{g}(x) = a + bx + cx^2, \quad e_i^2 = (g(x) - y_i)^2$$

$$\text{Odredjujemo minimum} \quad \Phi(a,b,c) = \sum_{i=1}^{n} \left(a + bx_i + cx_i^2 - y_i\right)^2$$

$$\frac{\partial \Phi(a,b,c)}{\partial a} = 0, \qquad \frac{\partial \Phi(a,b,c)}{\partial b} = 0, \qquad \frac{\partial \Phi(a,b,c)}{\partial c} = 0$$

Regresija polinomom stepena 2 (parabola)

$$\text{Min. od}: \quad \Phi(a,b,c) = \sum_{i=1}^{n} \left(a + bx_i + cx_i^2 - y_i\right)^2$$

$$\frac{\partial \Phi(a,b,c)}{\partial a} = 2\sum_{i=1}^{n} \left(a + bx_i + cx_i^2 - y_i\right) = 0$$

$$\frac{\partial \Phi(a,b,c)}{\partial b} = 2\sum_{i=1}^{n} \left(a + bx_i + cx_i^2 - y_i\right) x_i = 0$$

$$\frac{\partial \Phi(a,b,c)}{\partial c} = 2\sum_{i=1}^{n} \left(a + bx_i + cx_i^2 - y_i\right) x_i^2 = 0$$

Regresija polinomom stepena 2 (parabola)

$$2\sum_{i=1}^{n}\left(a+bx_i+cx_i^2-y_i\right)=0$$

$$a\,n+b\sum_{i=1}^{n}x_i+c\sum_{i=1}^{n}x_i^2=\sum_{i=1}^{n}y_i$$

$$2\sum_{i=1}^{n}\left(a+bx_i+cx_i^2-y_i\right)x_i=0$$

$$a\sum_{i=1}^{n}x_i+b\sum_{i=1}^{n}x_i^2+c\sum_{i=1}^{n}x_i^3=\sum_{i=1}^{n}x_i y_i$$

$$2\sum_{i=1}^{n}\left(a+bx_i+cx_i^2-y_i\right)x_i^2=0$$

$$a\sum_{i=1}^{n}x_i^2+b\sum_{i=1}^{n}x_i^3+c\sum_{i=1}^{n}x_i^4=\sum_{i=1}^{n}x_i^2 y_i$$

Regresija parabolom – Primer

#i	1	2	3	4	5	6	Σ
x_i	0	1	2	3	4	5	15
y_i	2.1	7.7	13.6	27.2	40.9	61.1	152.6
x_i^2	0	1	4	9	16	25	55
x_i^3	0	1	8	27	64	125	225
x_i^4	0	1	16	81	256	625	979
$x_i\, y_i$	0	7.7	27.2	81.6	163.6	305.5	585.6
$x_i^2\, y_i$	0	7.7	54.4	244.8	654.4	1527.5	2488.8

$$a\,n + b\sum_{i=1}^{n} x_i + c\sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} y_i$$

$$a\sum_{i=1}^{n} x_i + b\sum_{i=1}^{n} x_i^2 + c\sum_{i=1}^{n} x_i^3 = \sum_{i=1}^{n} x_i y_i$$

$$a\sum_{i=1}^{n} x_i^2 + b\sum_{i=1}^{n} x_i^3 + c\sum_{i=1}^{n} x_i^4 = \sum_{i=1}^{n} x_i^2 y_i$$

$$6\,a + 15\,b + 55\,c = 152.6$$

$$15\,a + 55\,b + 225\,c = 585.6$$

$$55\,a + 225\,b + 979\,c = 2488.8$$

Regresija parabolom
Primer

- Rešavamo sistem

$$6\,a + 15\,b + 55\,c = 152.6$$
$$15\,a + 55\,b + 225\,c = 585.6$$
$$55\,a + 225\,b + 979\,c = 2488.8$$

$$a = 2.4786, \qquad b = 2.3593, \qquad c = 1.8607$$
$$g(x) = 2.4786 + 2.3593\,x + 1.8607\,x^2$$

Regresija parabolom
Primer - grafik

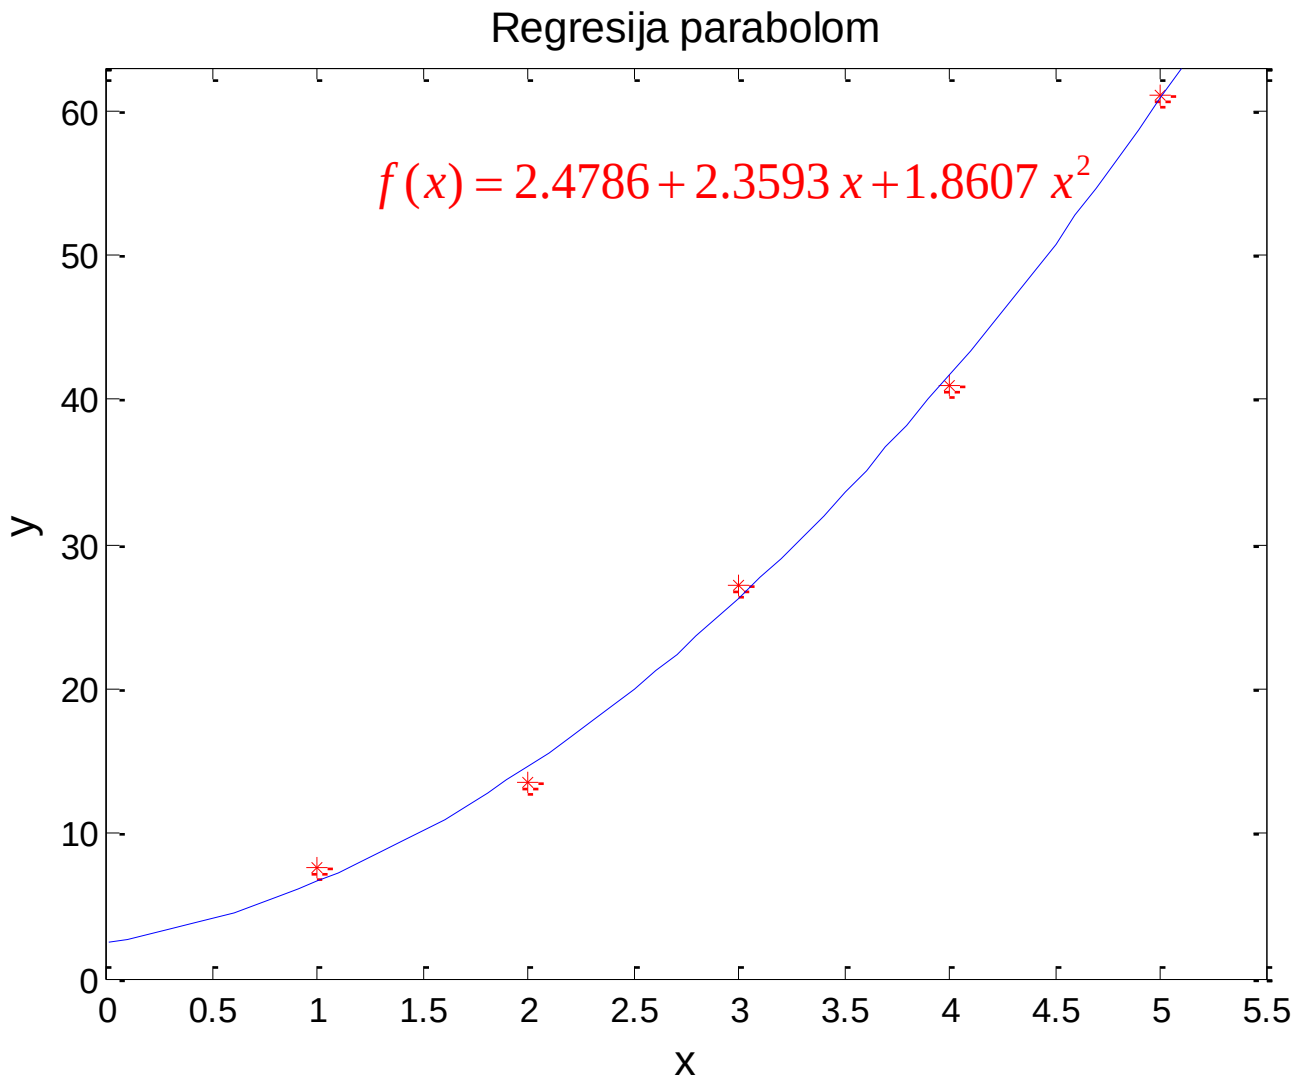

Regresija polinomom proizvoljnog stepena

- Sada pokušavamo da rešimo problem kod koga je obično m<<n.
- Dato nam je n tačaka. Cilj na je da tačke uklopimo polinom stepena m (m≤n-1).
- Opšti oblik polinoma

$$\sum_{i=0}^{m} a_i x^i$$

Regresija polinomom proizvoljnog stepena

- Polinom uklapamo u tačke tako da minizujemo zbir kvadrata grešaka

$$\Phi(a,b) = \sum_{i=1}^{n} {e_i}^2 = \sum_{i=1}^{n} (g(x_i) - y_i)^2$$

Regresija polinomom proizvoljnog stepena

$$\frac{\partial \Phi(a_0, a_1, \dots, a_M)}{\partial a_0} = \frac{\partial \sum_{i=1}^{N} (y_i - \sum_{m=0}^{M} a_m x_i^m)^2}{\partial a_0} = \sum_{i=1}^{N} 2 \left(\sum_{m=0}^{M} a_m x_i^m - y_i \right) x_i^0 = 0$$

$$\vdots$$

$$\frac{\partial \Phi(a_0, a_1, \dots, a_M)}{\partial a_M} = \frac{\partial \sum_{i=1}^{N} (y_i - \sum_{m=0}^{M} a_m x_i^m)^2}{\partial a_M} = \sum_{i=1}^{N} 2 \left(\sum_{m=0}^{M} a_m x_i^m - y_i \right) x_i^M = 0$$

Regresija polinomom proizvoljnog stepena

$$(A^T \cdot A) \cdot a = A^T \cdot y,$$

gde je:

$$A = \begin{bmatrix} x_1^0 & x_1^1 & \cdots & x_1^M \\ x_2^0 & x_2^1 & \cdots & x_2^M \\ \vdots & \vdots & \ddots & \vdots \\ x_N^0 & x_N^1 & \cdots & x_N^M \end{bmatrix}_{N\times(M+1)}, \qquad a = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_M \end{bmatrix}_{(M+1)\times 1}, \qquad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}_{N\times 1}$$

Python kod

```python
def lsquares(x,y,stepen):
    n=len(x)
    A=np.zeros([n,stepen+1])

    for i in range(n):
        for j in range(stepen+1):
            A[i,j]=x[i]**j

    p=la.solve(np.matmul(A.T, A), np.matmul(A.T, y.T))
    p=np.flip(p)

    return p
```

$$A=\begin{bmatrix} x_1^{\,0} & x_1^{\,1} & x_1^{\,2} & \dots x_1^{\,m} \\ x_2^{\,0} & x_2^{\,1} & x_2^{\,2} & \cdots x_2^{\,m} \\ \vdots & & & \dots \\ x_n^{\,0} & x_n^{\,1} & x_n^{\,2} & \cdots x_n^{\,m} \end{bmatrix}_{n\,x(m+1)}$$

$$(A^T \cdot A) \cdot a = A^T \cdot y,$$

$$a=\begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_M \end{bmatrix}_{(M+1)\times 1}$$

```python
print(np.flip([0,1,2,3,4]))
```

```
[4 3 2 1 0]
```

$4 * x^4 + 3 * x^3 + 2 * x^2 + 1 * x + 0 * x^0$

Primer

- Rešavamo primer koji smo ranije imali kod regresije sa parabolom.

#i	1	2	3	4	5	6
x_i	**0**	**1**	**2**	**3**	**4**	**5**
y_i	**2.1**	**7.7**	**13.6**	**27.2**	**40.9**	**61.1**

```
import numpy as np
from matplotlib import pyplot as plt
from numpy.core.function_base import linspace


x = np.array([0.0, 1.0, 2.0, 3.0, 4.0, 5.0])
fX = np.array([2.1, 7.7, 13.6, 27.2, 40.9, 61.1])
p = least_squares_regression(x, fX, 2)

print(p)
plt.plot(x, fX, 'ko')

x = linspace(np.min(x), np.max(x), 100)
pX = np.polyval(p, x)

plt.plot(x, pX, 'r')
plt.show()
```

```
[1.86071429 2.35928571 2.47857143]
```

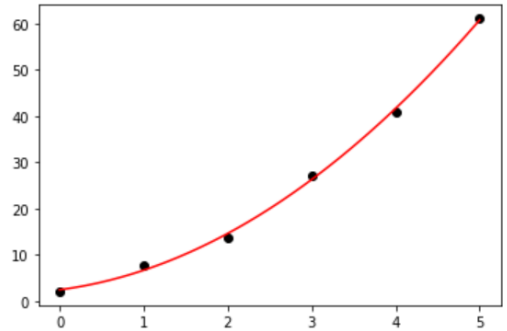

$$p(x) = 1.8607\,x^2 + 2.3593\,x + 2.4786$$

Primetite da u ovom slučaju (za razliku od interpolacije) možemo da zadamo stepen polinoma.

Dobijamo isti polinom kao i kada smo prethodno rešavali ovaj primer.

Revizija prethodnog gradiva

1. Šta je cilj regresije?
2. Kako smo formulisali ovaj zadatak?
3. Kako smo definisali meru "najboljeg uklapanja"?
   - Objasnite šta se optimizuje pomoću Metode Najmanjih Kvadrata
   - Definišete zbir kvadrata grešaka regresionog modela koristeći koje god oznake želite
4. Šta je rezidual?
5. Kako smo odredili nepoznate parametre modela?

$$\Phi(a,b) = \sum_{i=1}^{n} (b + ax_i - y_i)^2$$

Zadatak nam je da odredimo a i b, tako da je vrednost funkcije greške minimalna

$$\frac{\partial\ \Phi(a,b)}{\partial\ a} = 0$$

$$\frac{\partial\ \Phi(a,b)}{\partial\ b} = 0$$

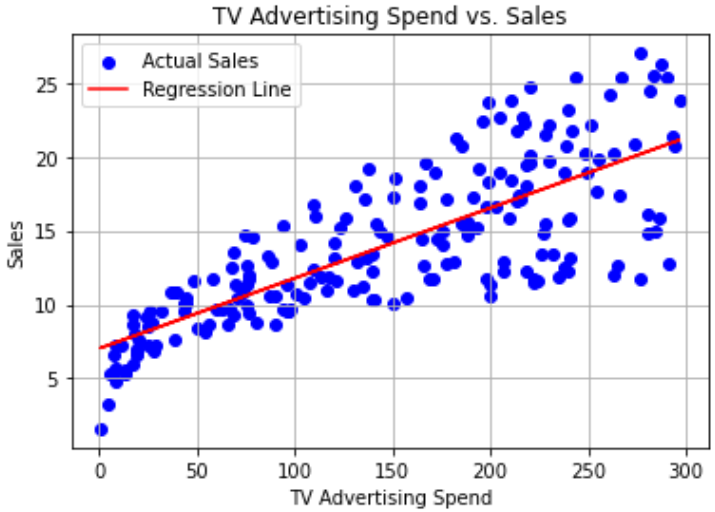

Za zadate:

- podatke $\{(x_i, y_i), i = 1, \dots, N\}$,
- oblik funkcije $g(x)$,
- i kriterijum za meru „najboljeg uklapanja",

Odrediti nepoznate parametre funkcije $g(x)$

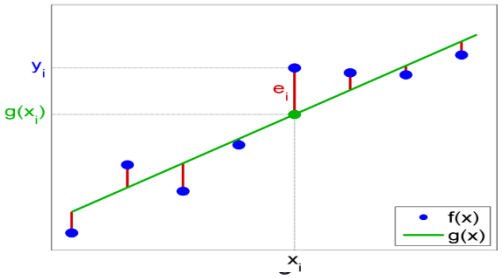

$$\sum_{i=1}^{N} e_i^2 = \sum_{i=1}^{N} \left(y_i - g(x_i)\right)^2$$

Revizija prethodnog gradiva

$$\sum_{i=1}^{N} e_i^2 = \sum_{i=1}^{N} \left(y_i - g(x_i)\right)^2$$

$$\sum_{i=0}^{m} a_i x^i$$

$$\frac{\partial \Phi(a_0, a_1, \dots, a_M)}{\partial a_0} = \frac{\partial \sum_{i=1}^{N} (y_i - \sum_{m=0}^{M} a_m x_i^m)^2}{\partial a_0}$$

$$\vdots$$

$$\frac{\partial \Phi(a_0, a_1, \dots, a_M)}{\partial a_M} = \frac{\partial \sum_{i=1}^{N} (y_i - \sum_{m=0}^{M} a_m x_i^m)^2}{\partial a_M}$$

1. Objasnite čemu služi koeficijent determinacije (R^2)
2. Interpretirajte $R^2 = 0.65$

Nelinearna regresija linearizacija

- Postoje primeri kod kojih je moguće primeniti linearnu regresiju iako podaci imaju nelinearni trend.
- Prvi korak za takve primere je transformacija podataka u prostor u kome će imati linearni trend – linearizacija.

$f(x)=e^{2x}$

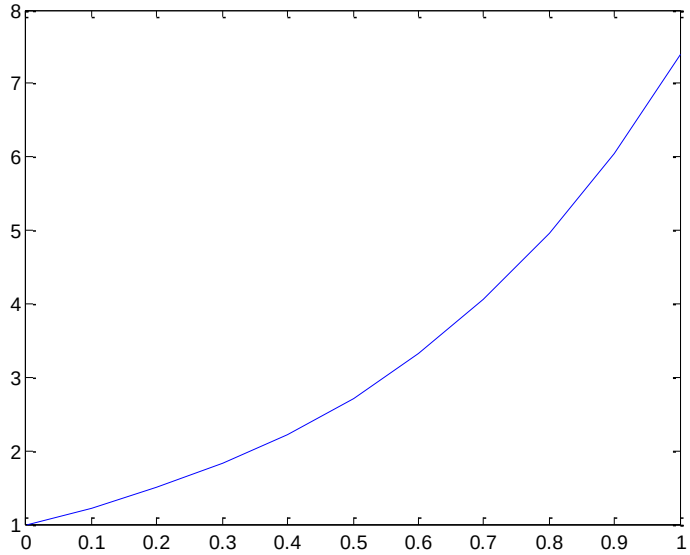

ln(x)

$f(x)=\ln(e^{2x})$

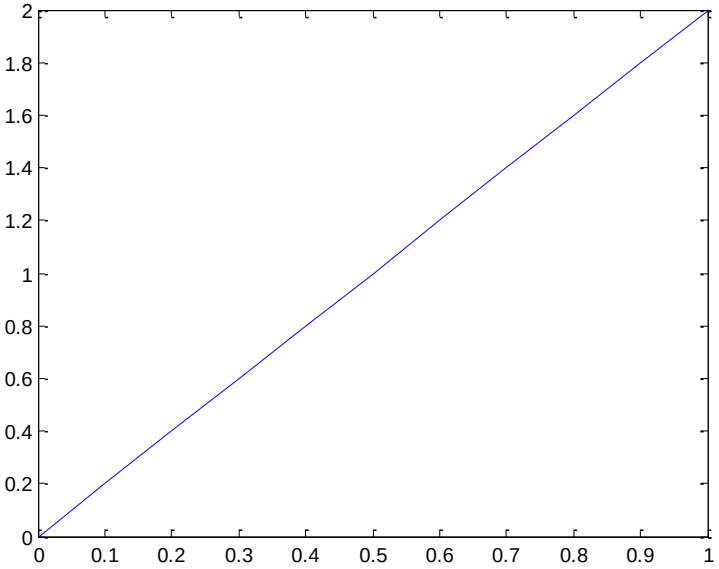

Nelinearna regresija linearizacija

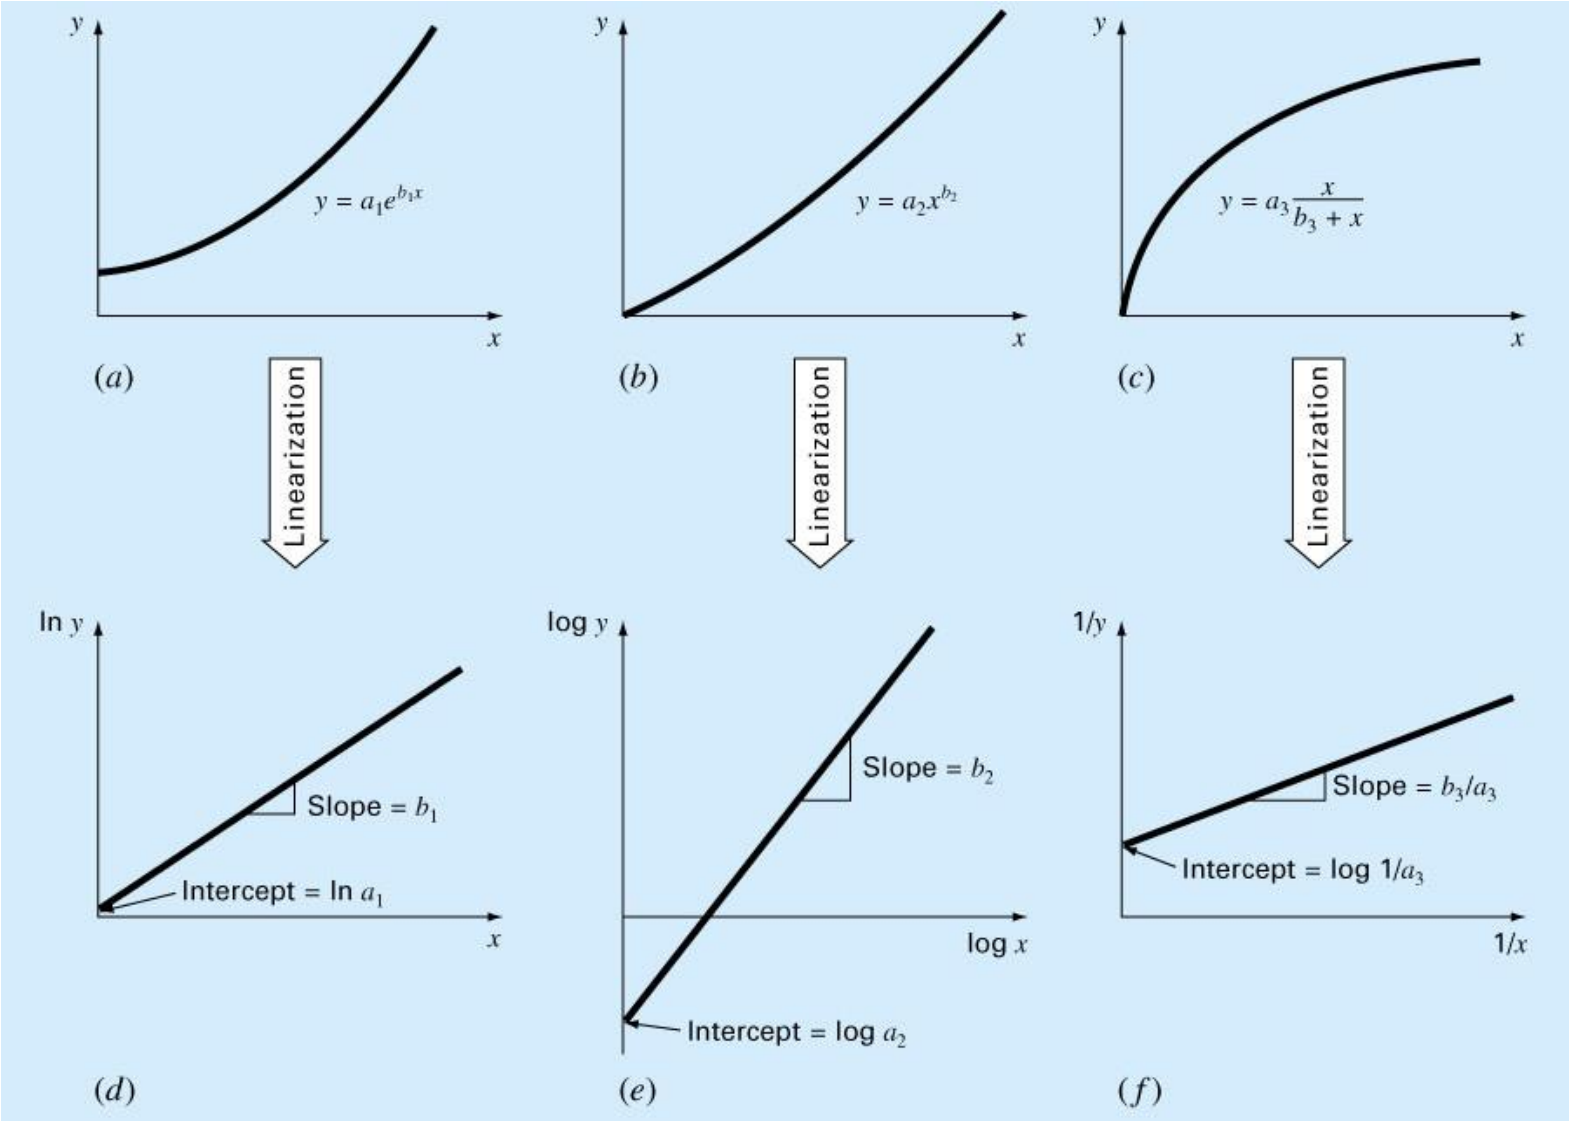

Interpretacija modela

Koji faktori utiču na očekivanu dužinu života stanovnika određene zemlje?

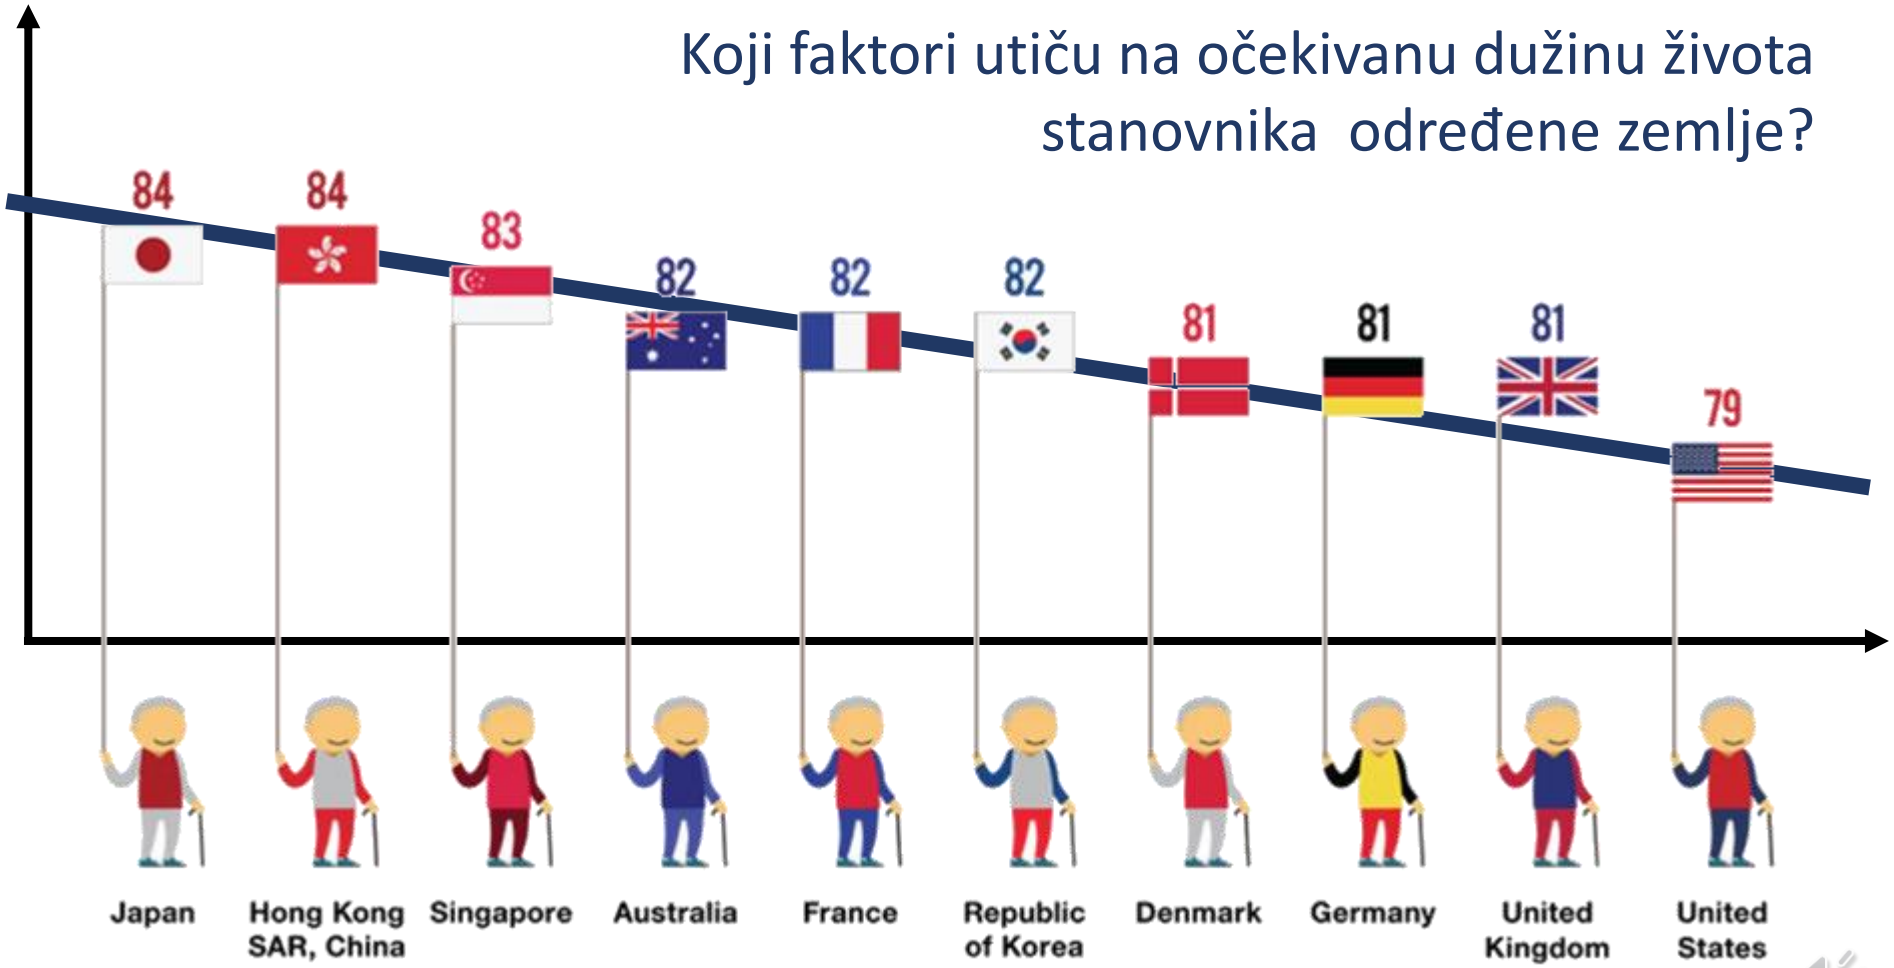

Jedna mogućnost:

pristup adekvatnim sanitarijama

Podaci

% stanovništva sa pristupom adekvatnim sanitarijama
http://apps.who.int/gho/data/node.main.46

Prosečna dužina života
http://apps.who.int/gho/data/node.main.688

Country	SanitationFacilities	LifeExpectancyBirth
Australia	100.0	82.8
Bahamas	92.0	76.1
Belize	90.5	70.1
Chile	99.1	80.5
Greece	99.0	81.0
Guatemala	63.9	71.9
Guyana	83.7	66.2
Hungary	98.0	75.8
Latvia	87.8	74.6
Malta	100.0	81.7

Serbia?

Ne postoji zemlja sa SF = 96.4

SanitationFacilities = 96.4

LifeExpectancyBirth = ?

Da li da uzmemo prosek sličnih?

Interpretacija modela

Od *klase modela*

$$h_\theta(x) = \theta_1(x) + \theta_0$$

odabrali smo model

$$h_{\hat{\theta}}(x) = \boxed{0.274} \cdot x + 50.7$$

koji najviše odgovara opservacijama

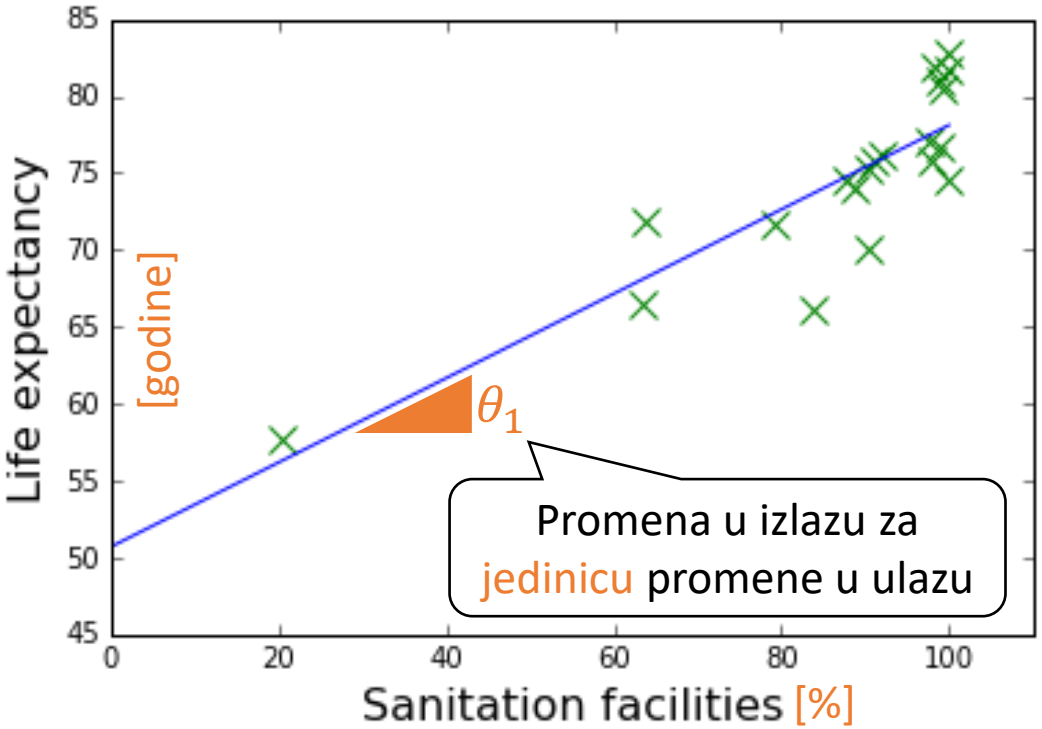

Ako 1% više stanovništva dobije pristup sanitarijama, životni vek poraste za 0.274 godine

Interpretacija modela

Od *klase modela*

$$h_\theta(x) = \theta_1(x) + \theta_0$$

odabrali smo model

$$h_{\hat{\theta}}(x) = 0.274 \cdot x + \boxed{50.7}$$

koji najviše odgovara opservacijama

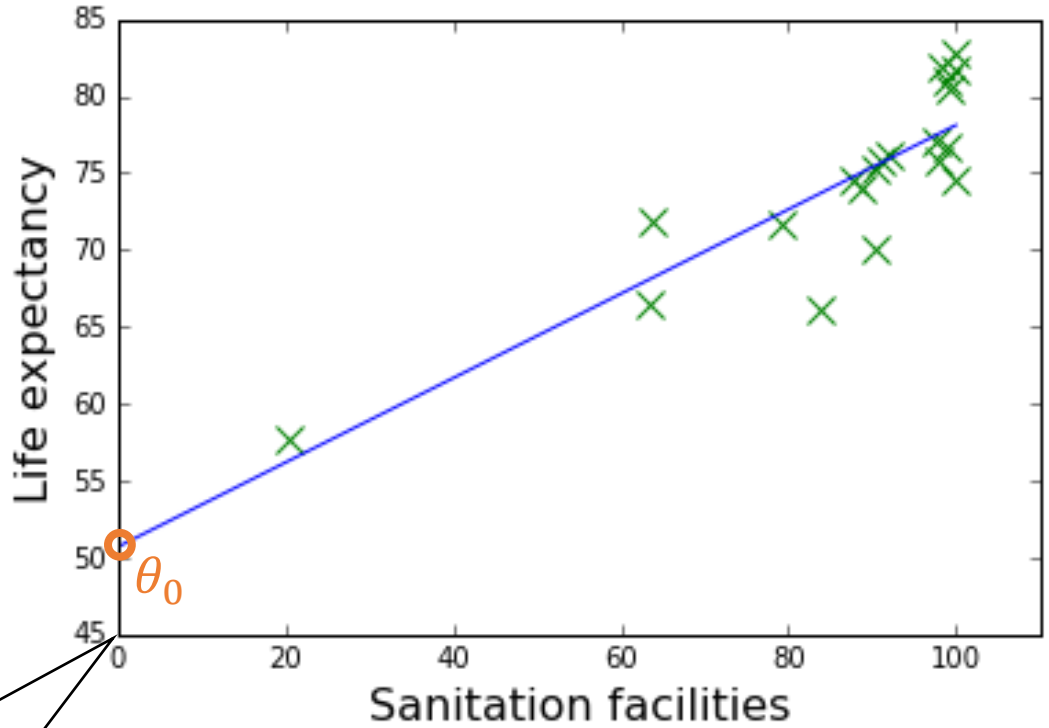

Koliki je životni vek kada niko nema pristup sanitarijama?

U opštem slučaju θ_0 nije interpretabilno

Interpretacija modela

Najčešće θ_0 nije interpretabilno

Matematički | θ_0 je očekivana vrednost y kada su x postavljeni na 0

Praktično | Da li je primer gde su svi $x = 0$ realno moguć?

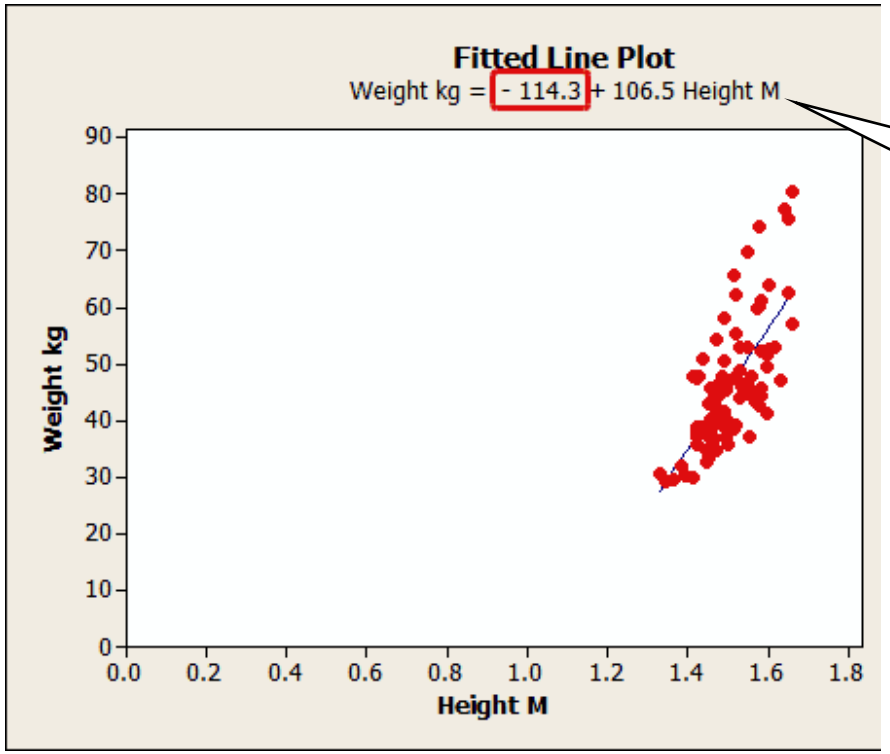

Čovek koji ima visinu 0 je težak – 114.3 kg

Ali, da li je realno moguće da se pojavi čovek sa visinom 0?

Interpretacija modela

Ako je realno postaviti sve x na 0, da li je onda θ_0 uvek interpretabilno?

Ne uvek, prisetite se interpolacije i ekstrapolacije

Ne treba da koristite regresioni model za predikciju tačaka van opsega trening podataka

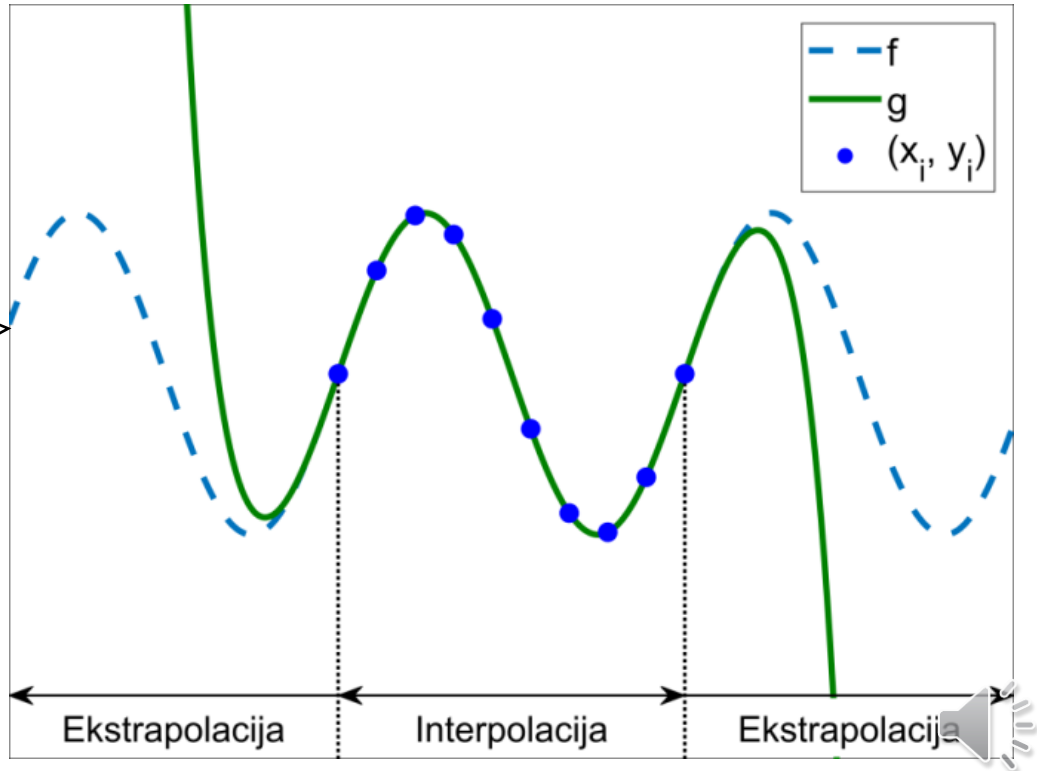

Interpretacija modela

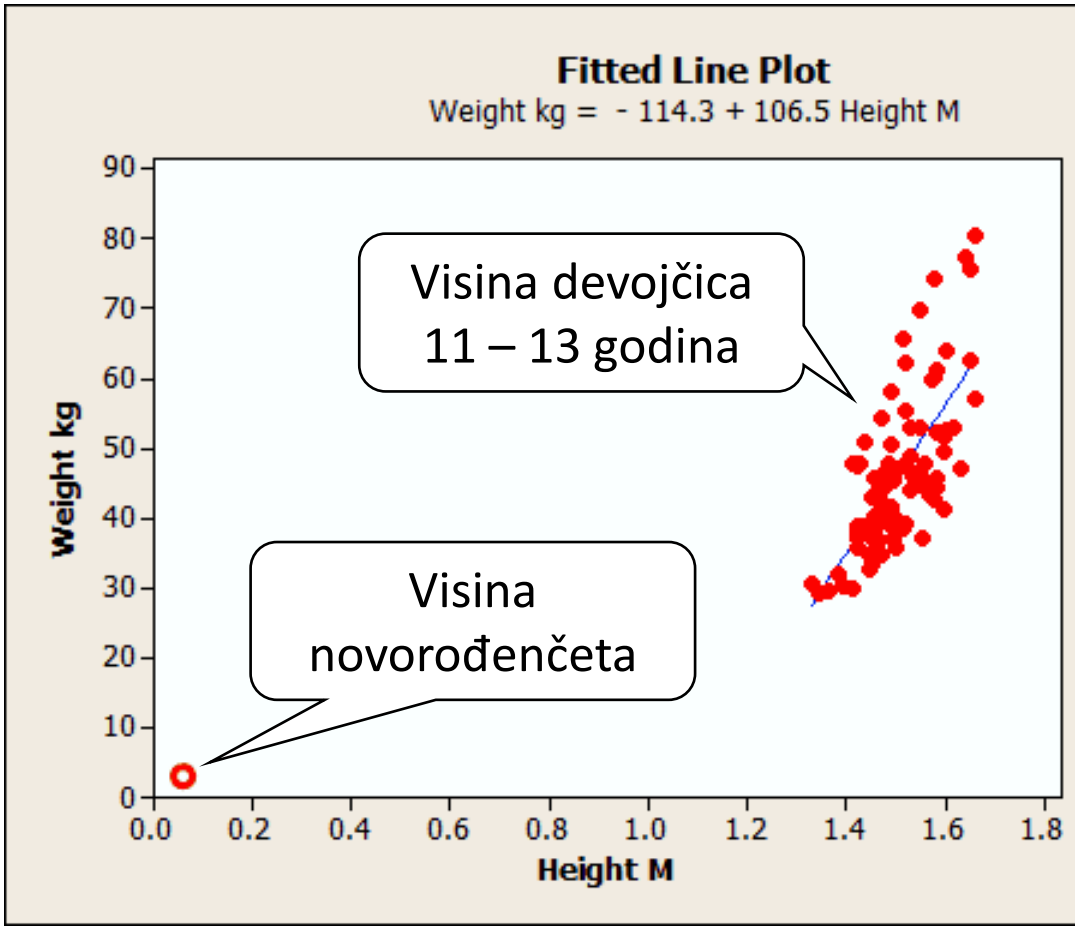

Ako nemamo trening podatke u okolini 0-vrednosti, ne vredi da interpretiramo θ_0

Čak i ako imamo, θ_0 ne mora biti interpretabilno

Interpretacija modela

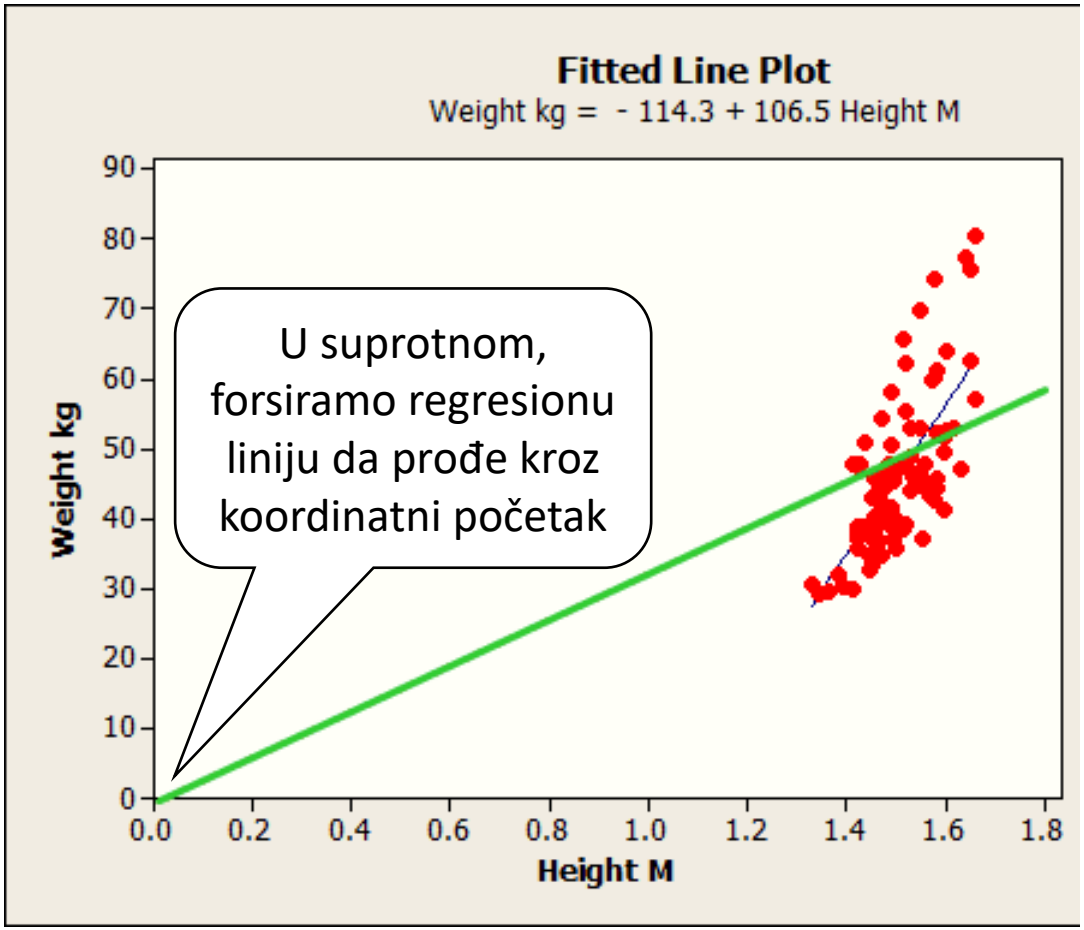

Ipak je od krucijalnog značaja da θ_0 uvrstimo u model