LINEARNA REGRESIJA

Pretpostavke linearne regresije

Definicija

- Alat za modelovanje veze zavisne promenljive *Y* sa jednom ili više nezavisnih promenljivih *X*.

- Veza se modeluje kao linearna kombinacija zavisnih promenljivih i parametara (težina):

$$\sum_{i=0}^{m} a_i x^i$$

- Parametri se određuju iz podataka.

Primeri grafika rasipanja – Linearna veza

Grafik rasipanja (*scatter plot*) je prvi alat za analizu odnosa dve promenljive

Jake veze | **Slabe veze** | **Nema povezanosti**

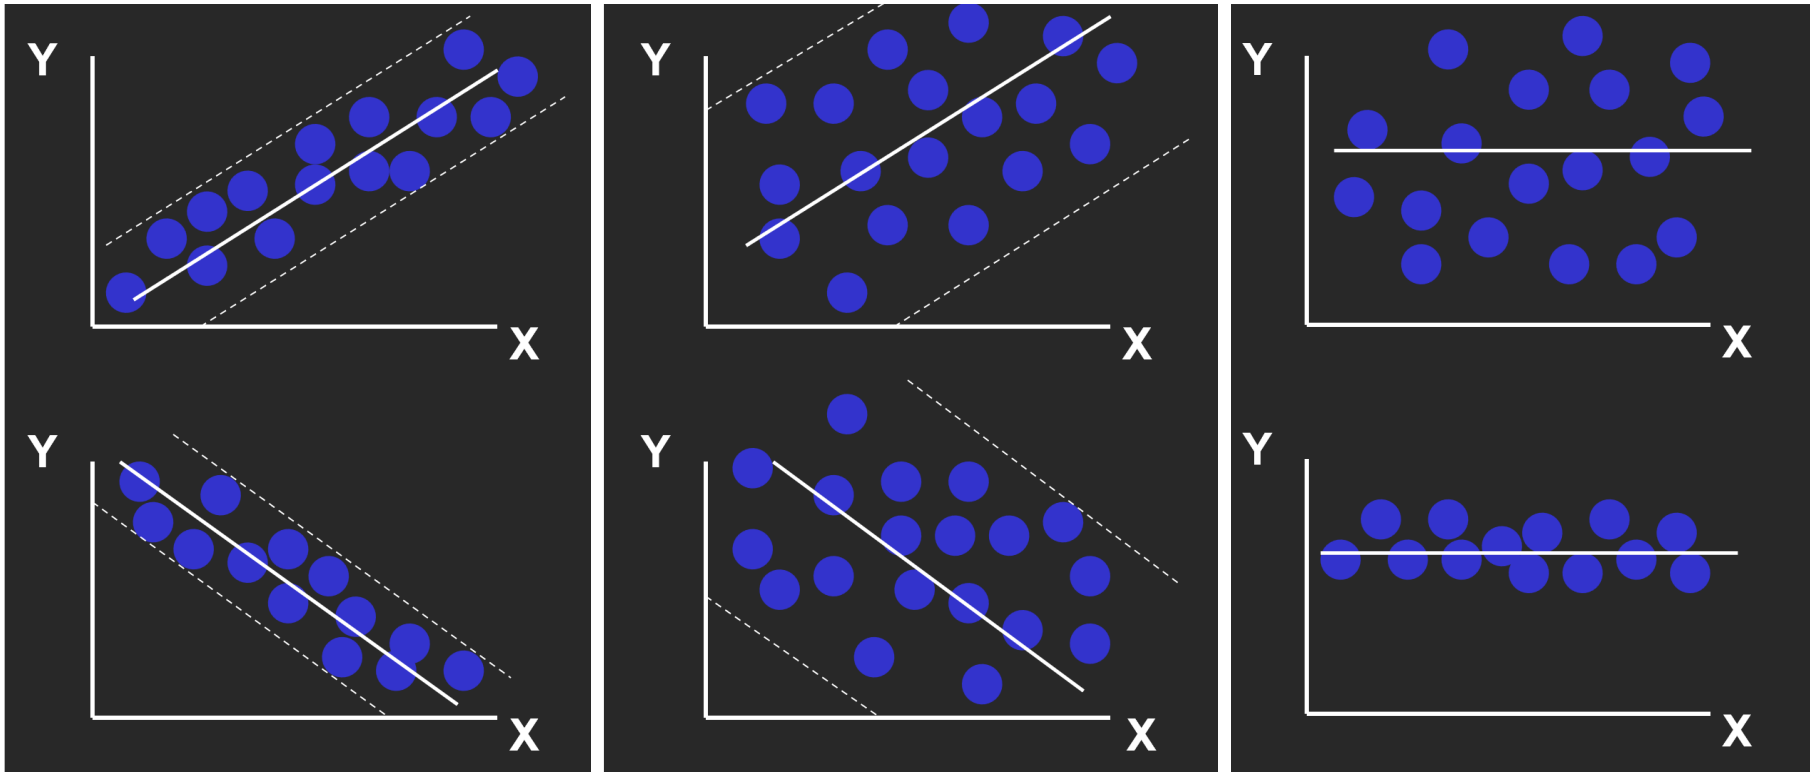

Korelacija i Regresija

- Analiza korelacije može da se koristi da se izmeri jačina linearne veze između dve promenljive
  - Korelacija nam samo pruža informaciju o jačini veze
  - Obe promenljive se tretiraju jednako
  - Ne analizira se uticaj jedne promenljive ne drugu

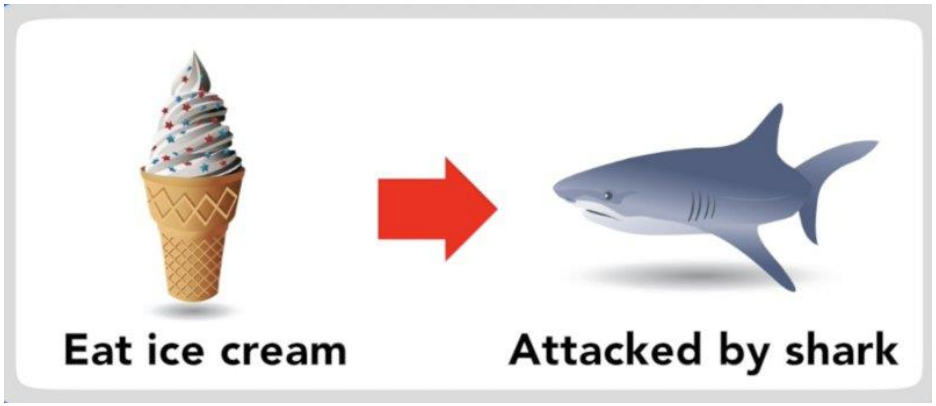

Chocolate 'may help keep people slim'

By Michelle Roberts
Health reporter, BBC News

27 March 2012 Share

People who eat chocolate regularly tend to be thinner, new research suggests.

The findings come from a study of nearly 1,000 US people that looked at diet, calorie intake and body mass index (BMI) - a measure of obesity.

It found those who ate chocolate a few times a week were, on average, slimmer than those who ate it occasionally.

Chocolate contains antioxidants but is also high in fat and sugar

Regresiona analiza se koristi za

Predikciju y na osnovu X

Supermarket želi da zna koliko će jedinica određenog proizvoda biti prodato sledeće nedelje. *Nije* cilj razumeti koji faktori utiču na prodaju, već precizno predvideti broj

Pogrešno predviđanje ima direktne finansijske posledice:

- premalo → prazni rafovi → gubitak prodaje
- previše → višak zaliha → bacanje ili sniženja → gubitak novca

Objašnjavanje uticaja promene X na y

Kompanija želi da razume **zašto su neki zaposleni produktivniji od drugih**. Oni *ne* pokušavaju da predvide produktivnost sledećeg meseca. Umesto toga, žele da saznaju:

Koji faktori zaista utiču na produktivnost i koliko?

Za svakog zaposlenog kompanija beleži:

- Ocenu produktivnosti (0–100) — ishod
- Broj sati obuke u poslednjih 6 meseci
- Godine iskustva
- Prosečan broj radnih sati nedeljno
- Ocenu zadovoljstva poslom (anketa, 1–10)

Jednostruka regesija

- Samo **jedna** nezavisna promenljiva x
- Parametri su nagib i odsečak prave i određuju se iz podataka

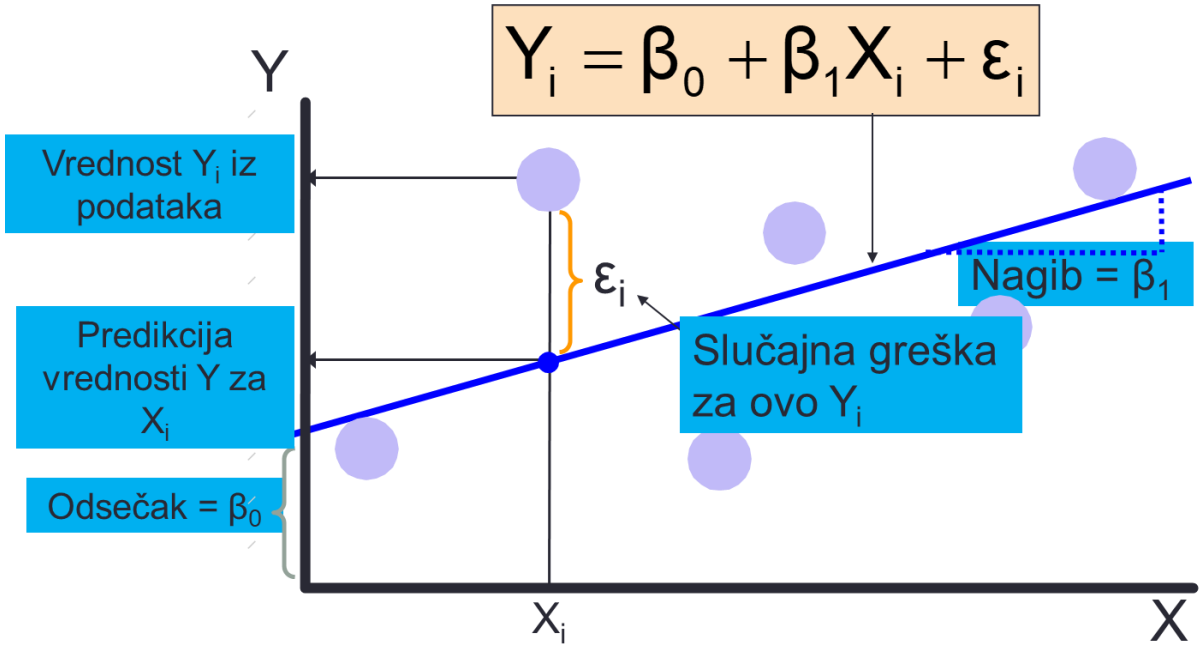

Nagib u linearnoj vezi

Veza između jedinične promene x i jedinične promene y

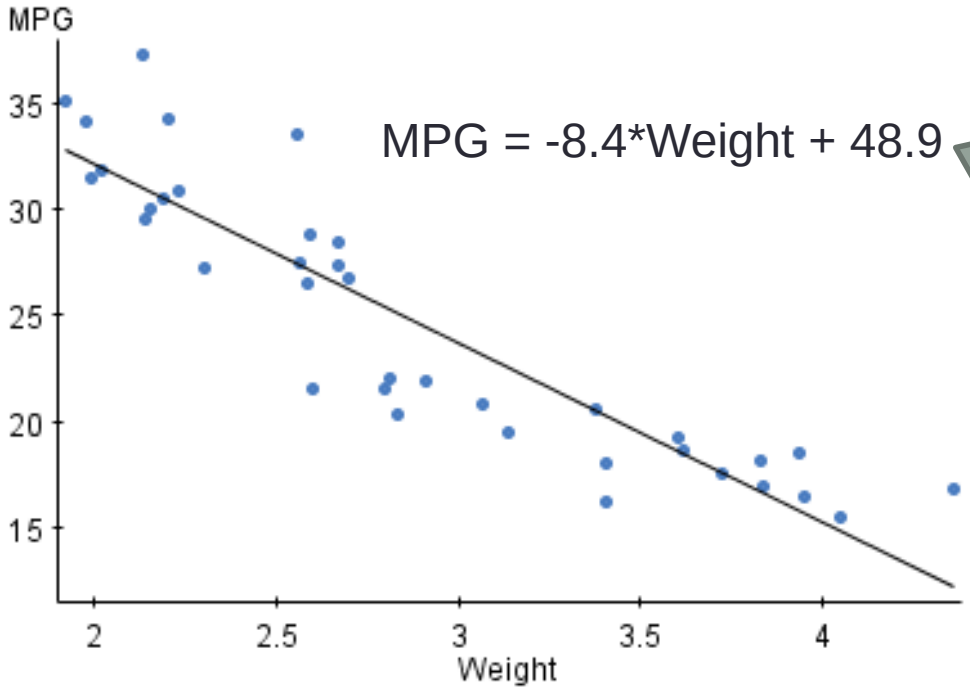

MPG = -8.4*Weight + 48.9

U proseku, uvećanje težine kola za 1000 funti smanjuje broj milja koji kola pređu sa jednim galonom goriva za 8.37

Da su težine vozila izražene u funtama umesto u hiljadama funti, nagib bi bio -0.00837

Model jednostruke linearne regresije

- Prikazani model je statistički model koji modeluje populaciju (populacioni model)
- Populacija je skup svih mogućih primera predmeta (pojave) koji se analizira
- Podaci koje koristimo za regresionu analizu su jedan uzorak populacije

Primer: predviđamo cene nekretnina u Srbiji:

- Populacija: svi stanovi u Srbiji (uključujući stanove čiju cenu ne znamo, one koji nisu oglašeni i one koji se ne prodaju)
- Uzorak: stanovi koje smo uspeli da prikupimo kao podatke (npr., sa sajta za nekretnine)

Populacija i uzorak (skup podataka)

- Populaciju biramo prema potrebama istraživanja
  - Nije realno da ona obuhvata sve primere na Zemlji
  - Ona obuhvata samo one primere za koje želimo da naš model bude važeći
- Primeri odabira populacije:
  - Predviđam cene nekretnina u Srbiji → populacija: sve nekretnine u Srbiji (ne na Zemlji)
  - Predviđam cene nekretnina u Novom Sadu → populacija: sve nekretnine u Novom Sadu
- Uzorak mora dobro da reprezentuje populaciju
  - Primer: predviđam cene nekretnina u Srbiji → selektujem različite tipove nekretnina iz različitih delova Srbije

Procene parametara modela iz uzorka

Jednačina jednostruke linearne regresije je procena parametara populacionog modela dobijena iz uzorka podataka.

Predikcija i-te vednosti promenjljive Y

Procenjena vrednost odsečka iz uzorka

Procenjena vrednost nagiba iz uzorka

i-ta vrednost promenjlive X

$$\hat{Y}_i = b_0 + b_1 X_i$$

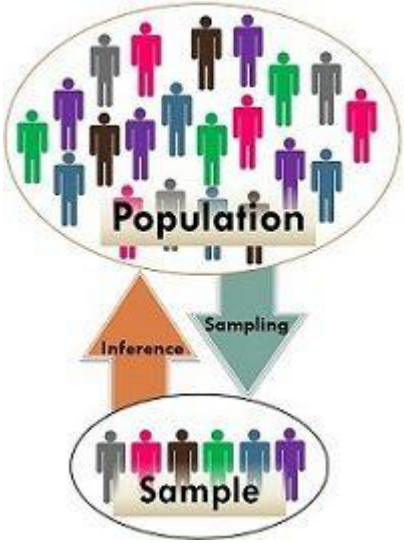

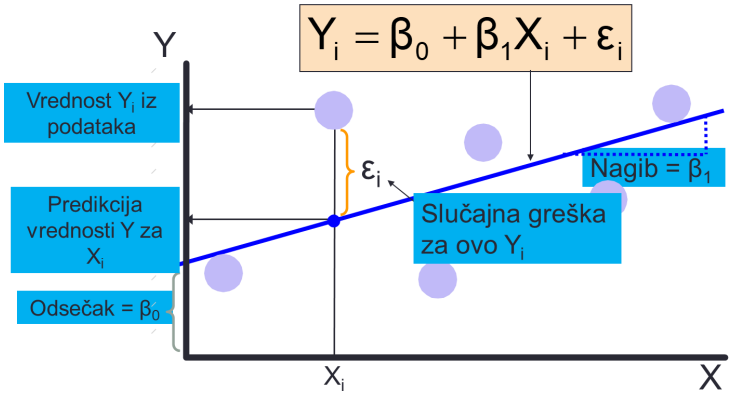

Metod Najmanjih Kvadrata

Parametri b_0 i b_1 dobijeni iz podataka (uzorka populacije) optimizacijom sume kvadrata grešaka, odnosno razlika između Y i $\hat{Y}$:

$$\min \sum (Y_i - \hat{Y}_i)^2 = \min \sum (Y_i - (b_0 + b_1 X_i))^2$$

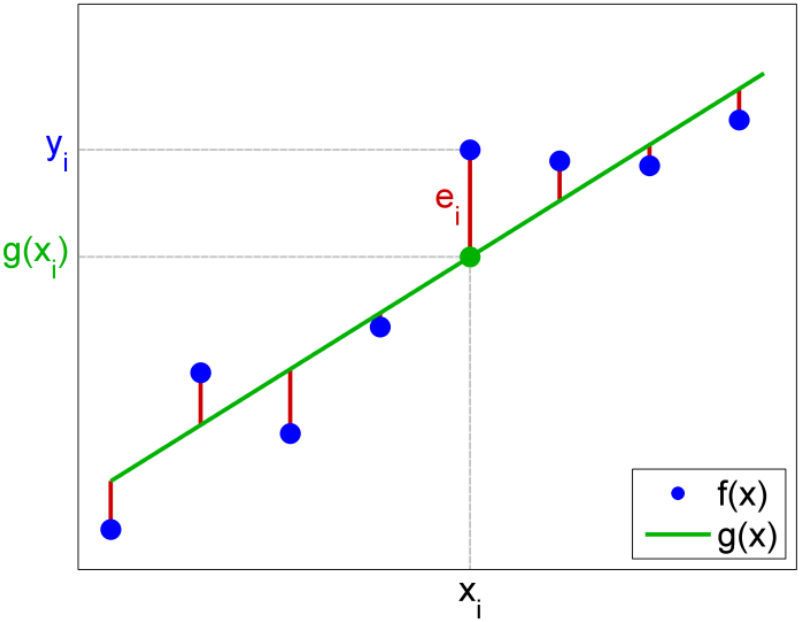

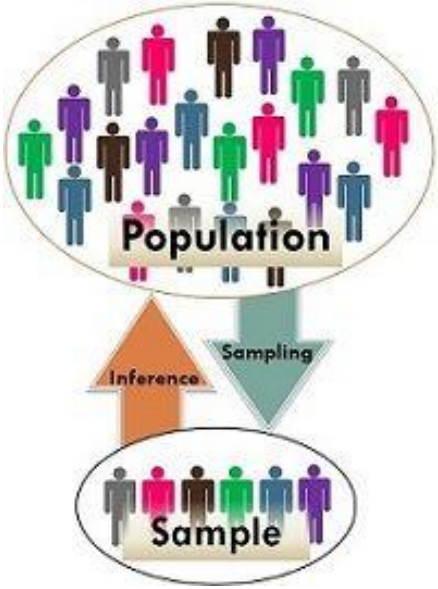

Interpretacija nagiba i odsečka

- b_0 je procenjena (iz podataka) srednja vrednost Y kada je vrednost X nula.

- b_1 je procenjena promena srednje vrednosti Y za povećanje X za jednu jedinicu.

$$\boxed{\hat{Y}_i = b_0 + b_1 X_i}$$

Jednostruka linearna regresija - primer

- Agent za nekretnine želi da ispita uticaj veličine placa na kome se nalazi kuća i cene te kuće.

- Podaci su uzorak od 280 kuća
  - Zavisna promenljiva (Y) = cena kuće u dolarima
  - Nezavisna promenljiva (X) = površina placa u kvadratnim metrima

Jednostruka linearna regresija - primer

- Skup podataka o 280 kuća iz kanadskog grada Windsor (1987)
- Pored cene (*price*) i površine placa (*lotsize*) postoji još 11 atributa:

1. price: sale price of a house
2. lotsize: the lot size of a property in square feet;
3. bedrooms: number of bedrooms
4. bathrms: number of full bathrooms
5. stories: number of stories excluding basement
6. driveway: dummy, 1 if the house has a driveway
7. recroom: dummy, 1 if the house has a recreational room
8. fullbase: dummy, 1 if the house has a full finished basement
9. gashw: dummy, 1 if the house uses gas for hot water heating
10. airco: dummy, 1 if there is central air conditioning
11. garagepl: number of garage places
12. prefarea: dummy, 1 if located in the preferred neighbourhood of the city

- U ovom primeru koristimo samo cenu i površinu placa, dok ćemo ostale upotrebiti kasnije tokom kursa.

Primer – deo skupa podataka

price	lotsize(m^2)	bedrooms	bathrms	stories	driveway	recroom	fullbase	gashw	airco	garagepl	prefarea
74700.0	658.5	3.0	1.0	1.0	1.0	1.0	1.0	.0	.0	2.0	1.0
85000.0	652.4	3.0	1.0	1.0	1.0	.0	1.0	.0	1.0	2.0	1.0
68500.0	650.6	3.0	1.0	2.0	1.0	.0	1.0	.0	.0	.0	.0
82900.0	650.6	3.0	1.0	1.0	1.0	.0	1.0	.0	.0	2.0	1.0
86000.0	641.3	3.0	2.0	1.0	1.0	1.0	1.0	.0	.0	.0	1.0
78900.0	641.3	3.0	1.0	1.0	1.0	1.0	1.0	.0	.0	.0	1.0
69000.0	637.8	3.0	1.0	2.0	1.0	.0	.0	.0	1.0	2.0	1.0
77500.0	634.3	3.0	1.0	1.0	1.0	1.0	1.0	.0	1.0	.0	1.0
86000.0	632.0	2.0	1.0	1.0	1.0	1.0	1.0	.0	.0	2.0	.0
91700.0	627.3	2.0	1.0	1.0	1.0	1.0	1.0	.0	.0	2.0	1.0
70000.0	624.6	3.0	1.0	1.0	1.0	.0	.0	.0	.0	.0	.0
77000.0	623.6	3.0	2.0	2.0	1.0	1.0	1.0	.0	.0	1.0	1.0
93000.0	619.9	3.0	1.0	3.0	1.0	.0	1.0	.0	.0	.0	1.0
80750.0	619.0	4.0	2.0	2.0	1.0	1.0	1.0	.0	.0	1.0	1.0
87000.0	614.8	4.0	2.0	2.0	1.0	1.0	.0	1.0	.0	1.0	.0
89900.0	613.4	3.0	2.0	3.0	1.0	.0	.0	.0	1.0	.0	1.0
89000.0	613.4	3.0	2.0	1.0	1.0	.0	1.0	.0	1.0	.0	1.0
87000.0	613.4	3.0	1.0	1.0	1.0	1.0	1.0	.0	.0	2.0	1.0
72000.0	613.4	3.0	1.0	1.0	1.0	1.0	1.0	.0	.0	.0	1.0
80000.0	613.4	4.0	2.0	1.0	1.0	.0	1.0	.0	.0	.0	1.0
78000.0	613.4	4.0	2.0	2.0	1.0	1.0	1.0	.0	.0	.0	1.0
85000.0	607.8	3.0	1.0	1.0	1.0	1.0	1.0	.0	.0	2.0	1.0
75000.0	607.8	4.0	2.0	2.0	.0	.0	.0	.0	1.0	.0	.0
85000.0	606.4	3.0	2.0	4.0	1.0	.0	.0	.0	.0	1.0	.0
84000.0	604.1	3.0	2.0	3.0	1.0	.0	.0	.0	1.0	.0	.0
62000.0	599.5	4.0	1.0	2.0	1.0	.0	.0	.0	.0	.0	.0
76900.0	599.5	3.0	2.0	1.0	1.0	1.0	1.0	1.0	.0	.0	.0
67900.0	598.5	2.0	1.0	1.0	1.0	.0	.0	.0	1.0	3.0	.0
87500.0	596.7	3.0	1.0	3.0	1.0	.0	1.0	.0	.0	.0	1.0
85000.0	596.7	3.0	1.0	1.0	1.0	.0	1.0	.0	1.0	.0	1.0
90000.0	594.8	3.0	1.0	1.0	1.0	1.0	1.0	.0	1.0	1.0	1.0
63900.0	591.1	2.0	1.0	1.0	1.0	.0	1.0	.0	1.0	1.0	.0
82000.0	591.1	3.0	1.0	1.0	1.0	1.0	1.0	.0	1.0	2.0	1.0
80000.0	591.1	3.0	1.0	3.0	1.0	.0	.0	.0	.0	.0	1.0
88500.0	590.2	3.0	2.0	3.0	1.0	1.0	.0	.0	1.0	.0	.0
68000.0	587.5	3.0	1.0	2.0	1.0	.0	1.0	.0	1.0	1.0	.0
70000.0	585.5	3.0	1.0	1.0	1.0	.0	.0	.0	1.0	2.0	.0
85000.0	581.2	4.0	2.0	1.0	1.0	.0	1.0	.0	.0	1.0	1.0
78000.0	577.2	4.0	1.0	4.0	1.0	1.0	.0	.0	1.0	.0	.0
79000.0	566.9	3.0	2.0	1.0	1.0	.0	1.0	.0	.0	2.0	1.0
78000.0	566.9	3.0	1.0	3.0	1.0	1.0	.0	.0	1.0	.0	1.0
73000.0	566.9	3.0	1.0	1.0	1.0	.0	1.0	.0	1.0	.0	1.0
74900.0	562.3	3.0	1.0	1.0	1.0	.0	1.0	.0	.0	.0	1.0
69000.0	561.4	3.0	1.0	1.0	1.0	.0	.0	.0	.0	2.0	1.0
82500.0	557.6	3.0	2.0	4.0	1.0	.0	.0	.0	1.0	.0	.0
67000.0	557.6	2.0	1.0	1.0	1.0	.0	1.0	.0	1.0	1.0	.0
59000.0	556.2	3.0	1.0	1.0	1.0	.0	1.0	.0	.0	.0	.0

Primer – dijagram rasipanja

- Sa dijagrama možemo da primetimo da skuplje kuće imaju veću površinu, i obrnuto.

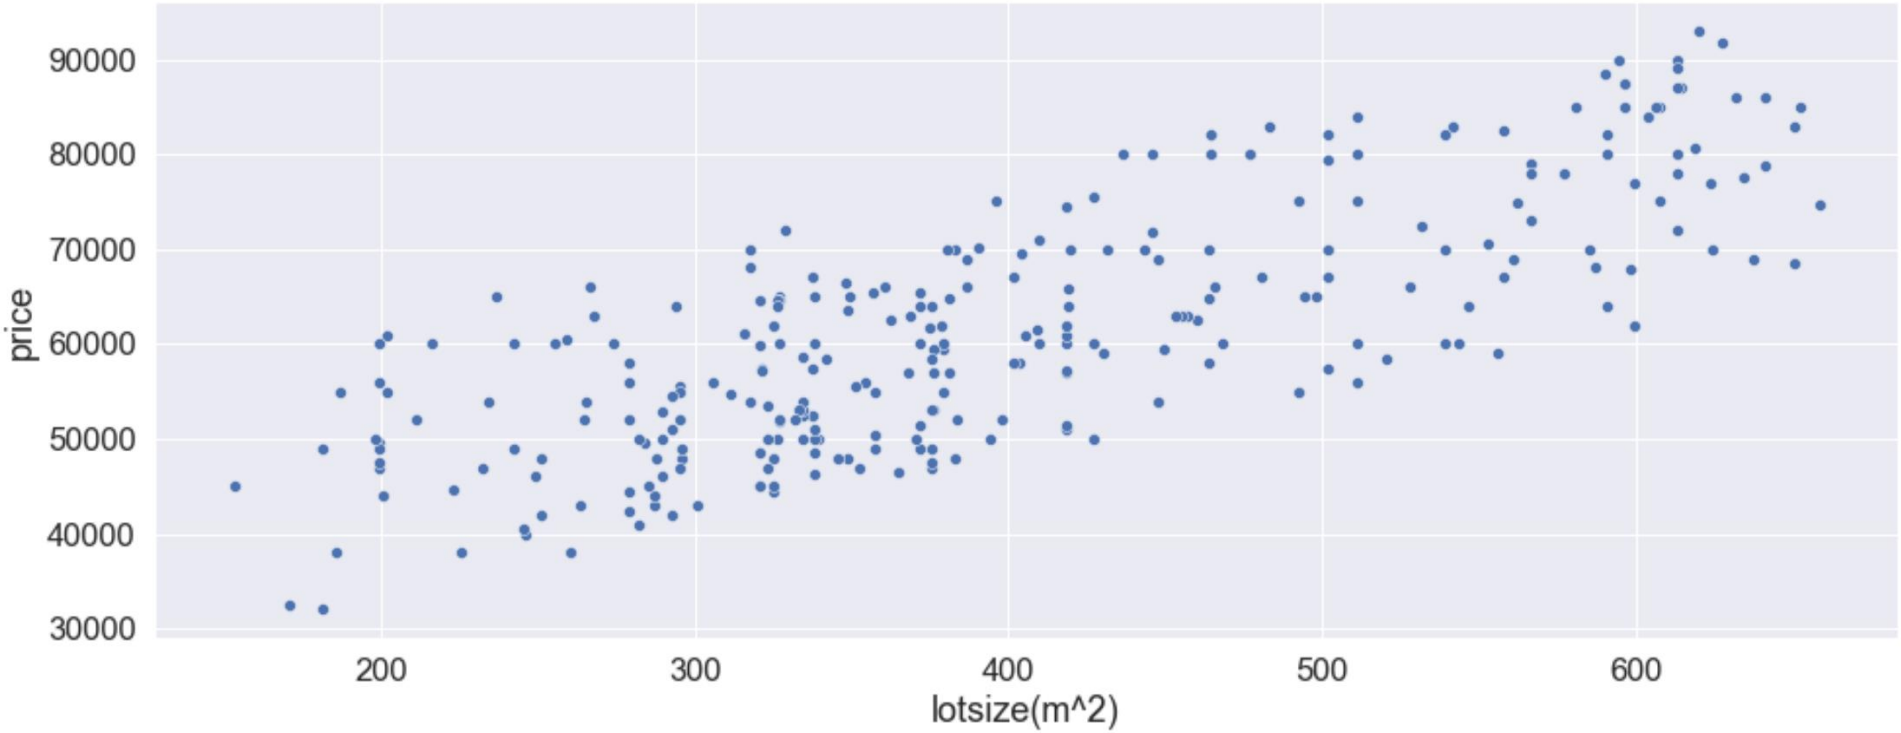

- Takođe vidimo da se većina tačaka ne nalazi na pravoj liniji što znači:
  - da postoji značajna linearna veza (trend), a ne egzaktan linearni odnos između cene kuća i površine placa.

Primer – jednačina jednostruke linearne regresije dobijena iz podataka

- Pomoću metoda *LinearRegression* iz biblioteke *scikit* dobijamo:

Cena = 80.07 * *površina_placa(m^2)* + 29421.88

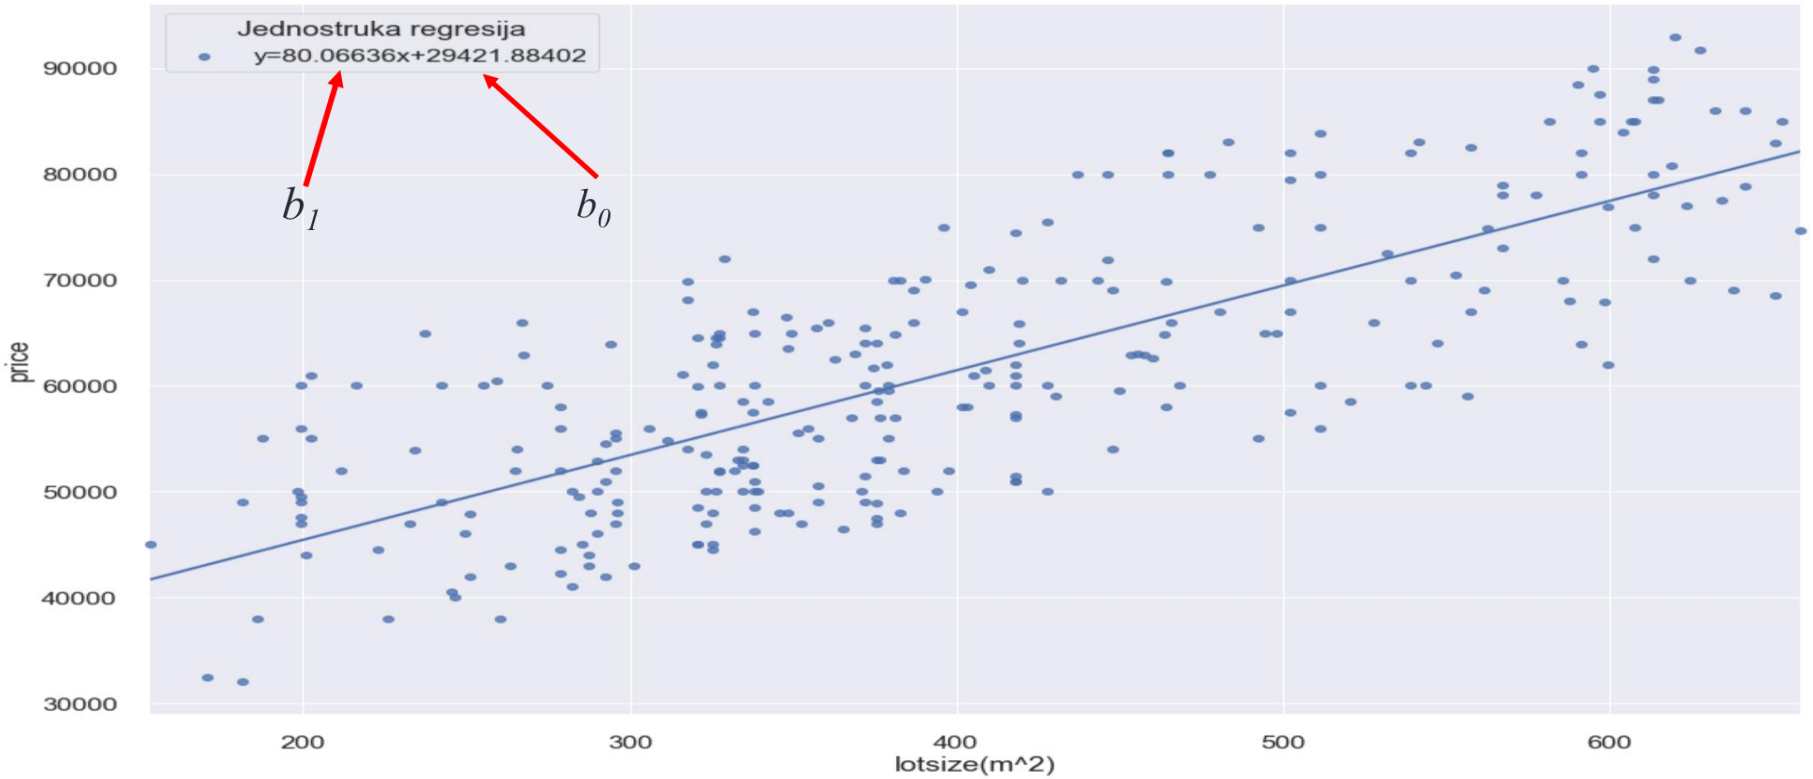

- Recimo da želimo da predvidimo cenu kuće sa površinom placa od 100m^2

Cena = 80.07 * *100* + 29421.88 = 37428.88

- Koliko je dobra naša predikcija? Time se bavimo u nastavku.

Primer – interpretacija osdečka b_o

Cena = 80.07 * *površina_placa(m^2)* + 29421.88

- b_0 procenjena (iz podataka) srednja vrednost Y kada je vrednost X nula.
- Imajući u vidu da kuća sa površinom placa od nula m^2 nema smisla možemo zaključiti da:
  - interpretacija b_0 nema uvek praktičnu vrednost u regresionoj analizi.

Primer – interpretacija nagiba b_1

Cena = 80.07 * *površina_placa(m^2)* + 29421.88

- b_1 je procenjena promena srednje vrednosti Y za povećanje X za jednu jedinicu.
- Za ovaj primer vrednost 80.07 kaže nam da se prosečna cena kuće poveća za 80.07 dolara kada se površina placa poveća za 1 m^2.

Evaluacija modela linearne regresije

- Postoji mnogo načina za evaluciju prediktivnih modela.

- Jedan od načina je primena modela na nepoznate podatke i onda merenje njegovih prefomansi npr. pomoću srednje vrednosti kvadrata grešaka.
  - Ovaj način je univerzalan za sve prediktivne modele.
  - Ovaj način obradićemo detaljno pomoću demonstracija na vežbama.

- Na ovom predavanju prikazaćemo proces evaluacije koji je specifičan za linearnu regresiju.

Evaluacija modela linearne regresije

- Na ovom predavanju pokazaćemo kako možemo da proverimo:
  1. Da li populacioni model dobro modeluje populaciju?
     Odnosno, da li je pretpostavka o tome da postoji linearna veza između X i Y tačna ili pogrešna?
  2. U kom intervalu realnih brojeva se nalaze parametri populacionog modela?
  3. U kom intervalu realnih brojeva se nalaze predikcije populacionog modela?

- Provere vršimo koristeći uzorak podataka koji smo upotrebili za formiranje našeg modela i statističke alate.

- Proces vršenja provera naziva se zaključivanje o modelu linearne regresije.

- Da bi zaključivanje bilo validno moraju da važe Pretpostavke Linearne Regesije – koje prikazujemo u nastavku.

Pretpostavke linearne regresije

- Model predstavlja celu populaciju, dok parametre modela procenjujemo iz jednog uzorka populacije pomoću Metoda Najmanjih Kvadrata (MNK).

- Metoda Najmanjih Kvadrata ćemo u ovom kontekstu zvati estimator parametara.

- Pretpostavke date u nastavku odnose se na kombinaciju estimatora i samog modela linearne regresije, zato se često nazivaju:

Pretpostavke MNK linearne regresije

- Dok predstavljamo pretpostavke naglasićemo koje se odnose samo na estimator, a koje i na esitmator i na model.

Pretpostavke MNK Linearne regresije

L.I.N.E $\boxed{Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i}$

- *Linearity* - Linearnost

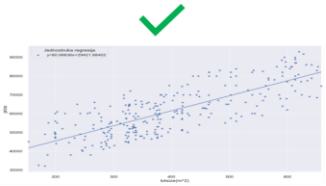

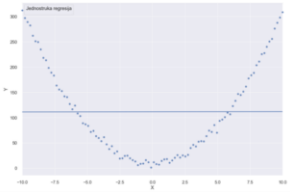

- *Independence of Errors* – Nezavisnost grešaka ε_i

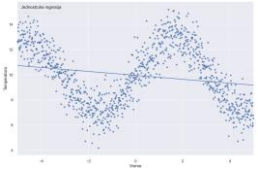

- *Normality of Error* – Normalnost grešaka ε_i

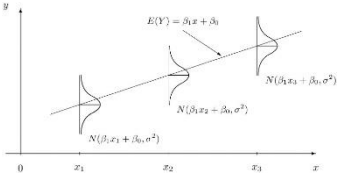

- *Equal Variance* – Jednaka varijansa

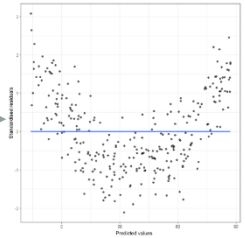

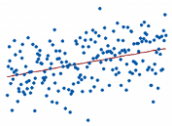

Linearnost

Ako odnos između x i y nije linearan, koristimo pogrešan model

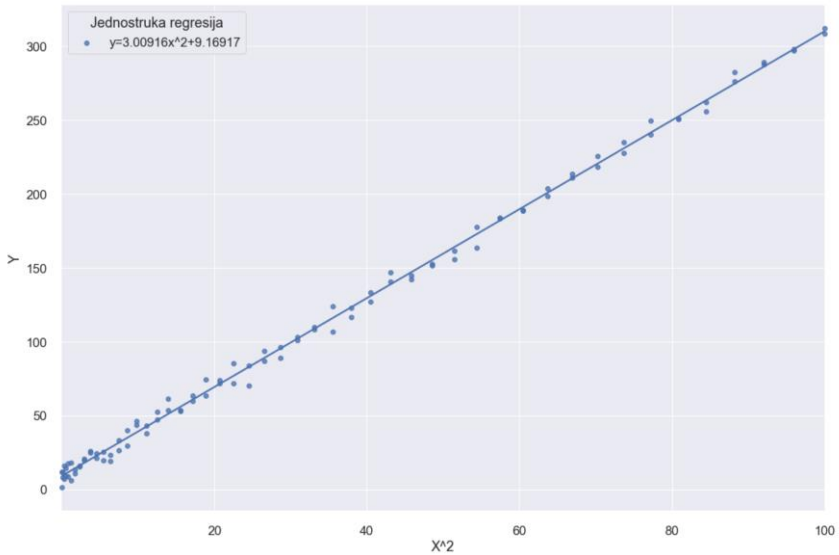

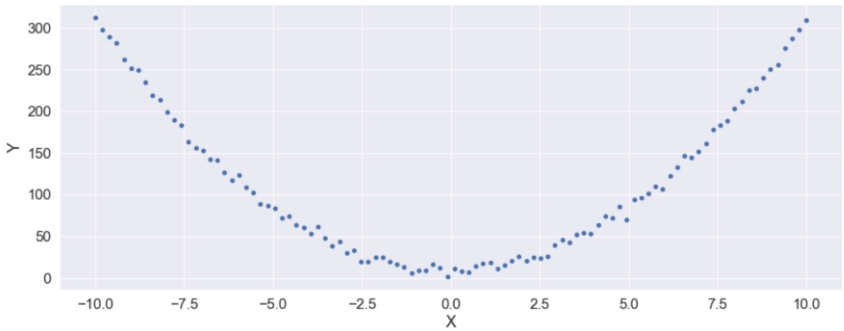

Šta znači linearna regresija

- Da li odnos x i y mora biti linearan da bismo primenili ovaj model?

- Ne. Ali moramo transformisati x tako da ima linearan odnos sa y

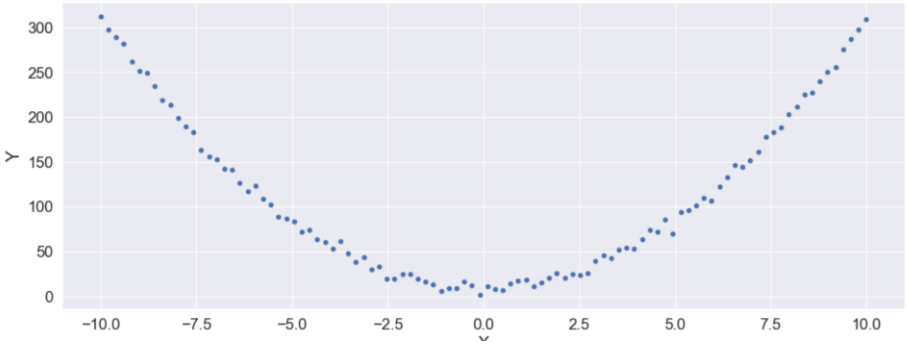

x

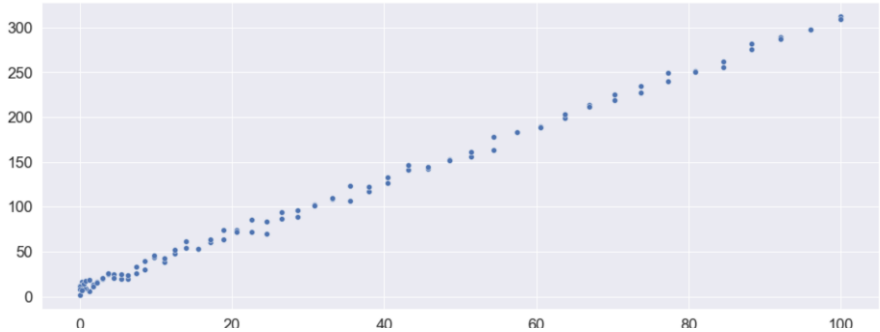

x^2

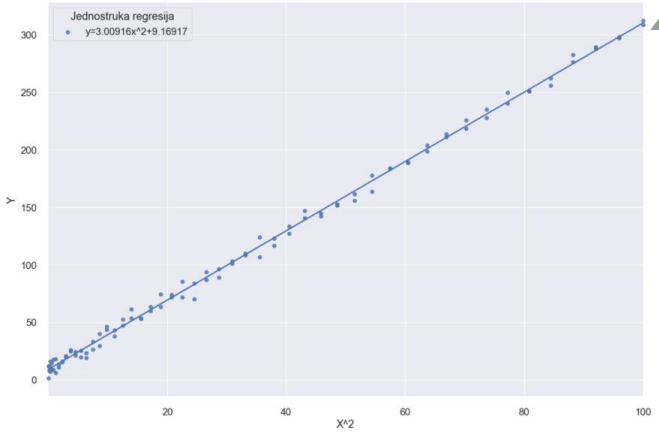

Šta znači linearna regresija

Prikazujemo prethodno dobijeni model $y = 3 * x^2 + 9.1$, ali tako da je na x-osi nezavisna promenjljiva x, a ne x^2:

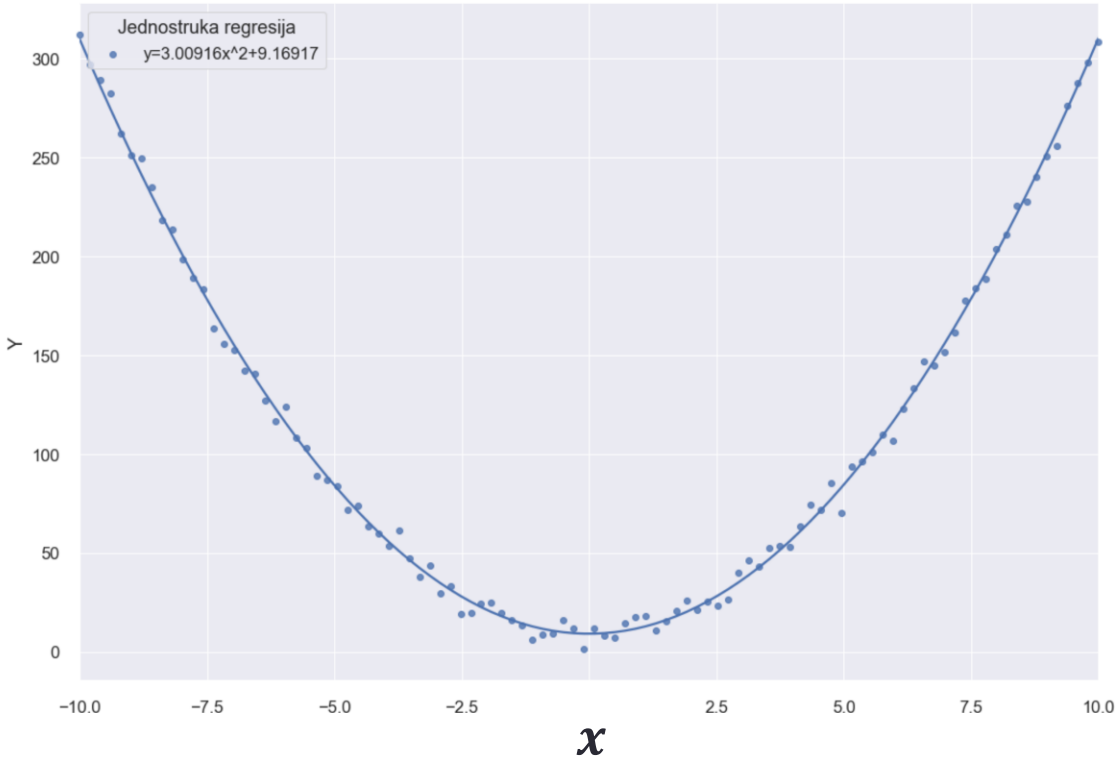

Figuriše x^2 → možemo li ovu regresiju zvati linearnom?

Linearnost u smislu parametara

- Model: $y = 3x^2 + 9.1 \rightarrow$ linearna kombinacija nagiba vrednosti 3, odsečka vrednosti 9.1 i nezavisne promenljive x^2

- Linearnost se odnosi na vezu između parametara i y, a x može biti i transformacija originalnog x iz podataka

- Primenjene transformacije se tipično nazivaju osobine/obeležja/karakteristike (*features)*.

- Problem: linearnost smo utvrdili posmatranjem grafika rasipanja; inspiraciju za transformaciju smo dobili sa istog grafika → Lako za 2-3 dimenzije, nemoguće za više

- U slučaju više dimenzija, potrebno je analizirati podatke i eksperimentisati sa različitim transformacijama

Kako testiramo linearnost?

- Jednostruka linearna regresija → pogledamo grafik rasipanja (2D)

- Ukoliko na grafiku postoje velika odstupanja podataka od regresione prave, linearan model je pogrešan izbor

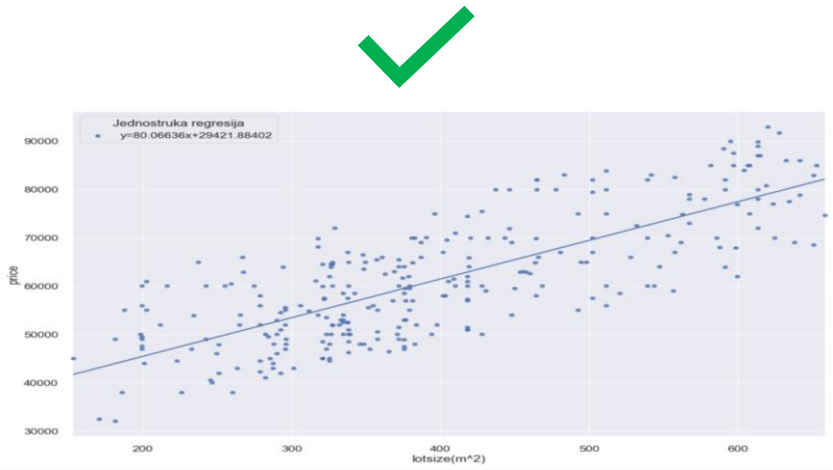

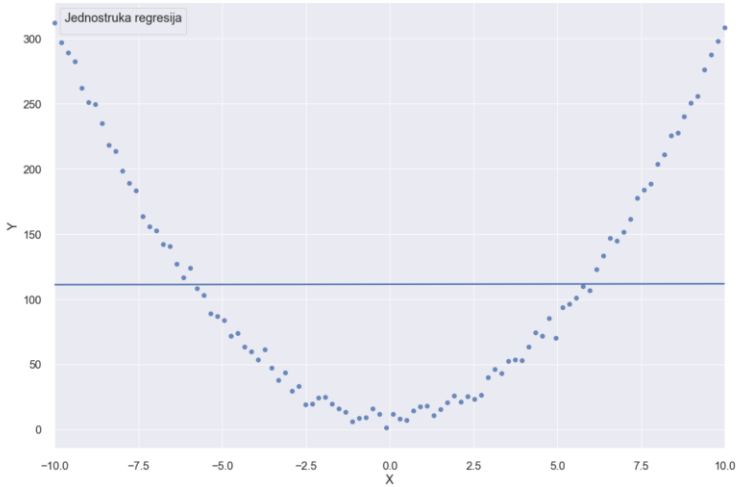

Šta da radimo ako odnos nije linearan?

- Linearnost je osnovna pretpostavka linearne regresije
- Ako je narušena, model koji smo formirali nije validan ni za predikciju niti za dalju analizu regresionih pretpostavki
- U nekim slučajevima možemo da uvidimo da postoji odgovarajuća transformacija x koja nam može omogućiti upotrebu linearne regresije (primer sa parabolom na prethodnim slajdovima)
- U drugim slučajevima, prikladnije je koristiti neki od nelinearnih modela – na primer, neuronske mreže

Nezavisnost grešaka ε_i

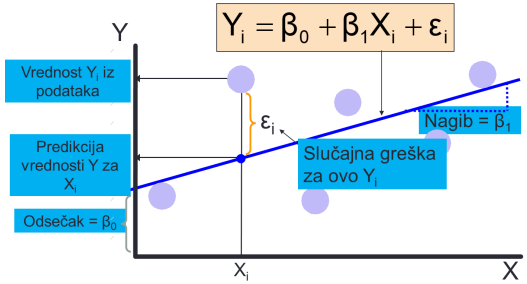

Ako znamo nešto o nekoj grešci ε_i, to nam ne govori ništa o bilo kojoj drugoj grešci ε_j

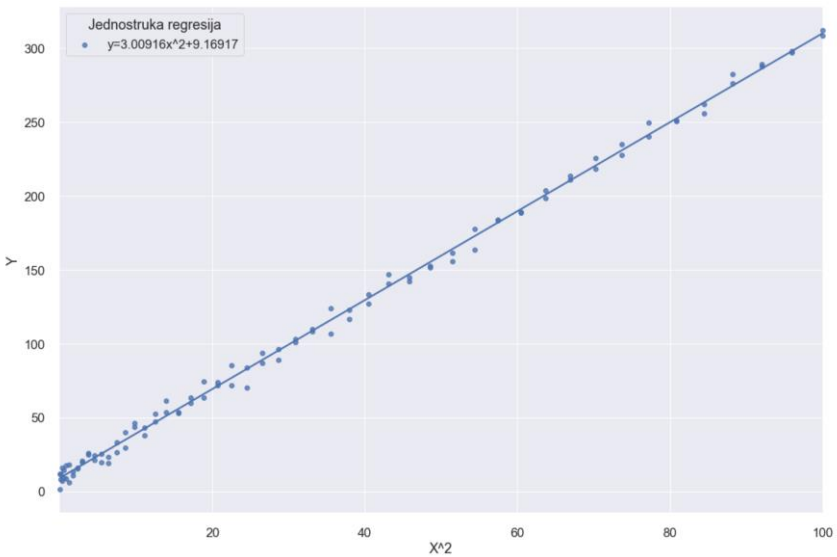

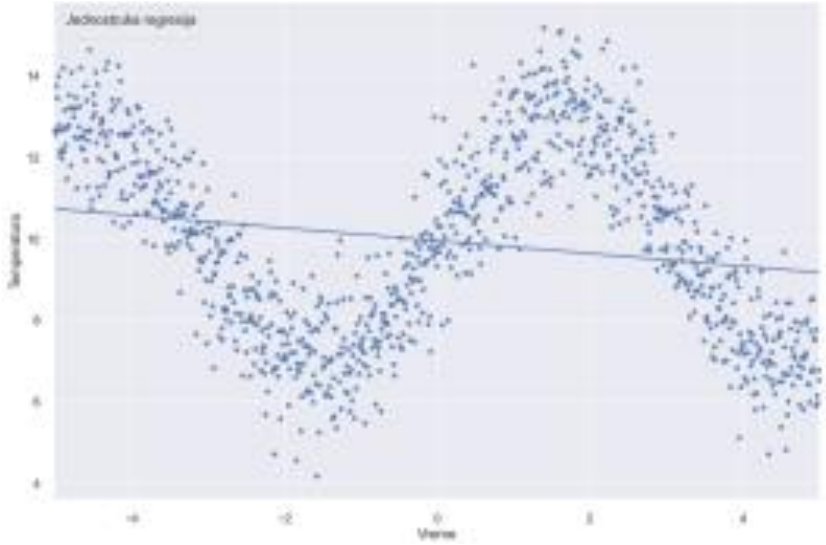

Nezavisnost grešaka ε_i

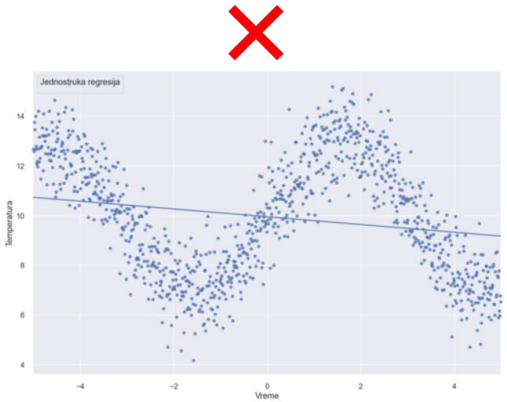

- Pretpostavka je vezana za MNK estimator

- Ali, takođe može da nam otkrije da li su vrednosti y međusobno nezavisne (značajano za ispravan model)

- Međusobna povezanost y vrednosti se najčešće javlja kod vremenskih serija
  - x – dan u godini
  - y – temperatura
  - ε_i verovatno ne bi bile nezavisne

  (ako je danas veoma toplo, vrlo je verovatno da će i sutra biti toplo)
  - Zašto to znanje ne bismo koristili u modelu?

Nezavisnost grešaka ε_i

- Ako ε_i i ε_j nisu nezavisne, onda nisu nezavisni ni y_i i y_j

- Intuitivno, ako pomoću y_i možemo da predvidimo y_j, nema smisla izostaviti tu informaciju iz modela modela
  - Odnosno, x nam ne pruža dovoljnu informaciju

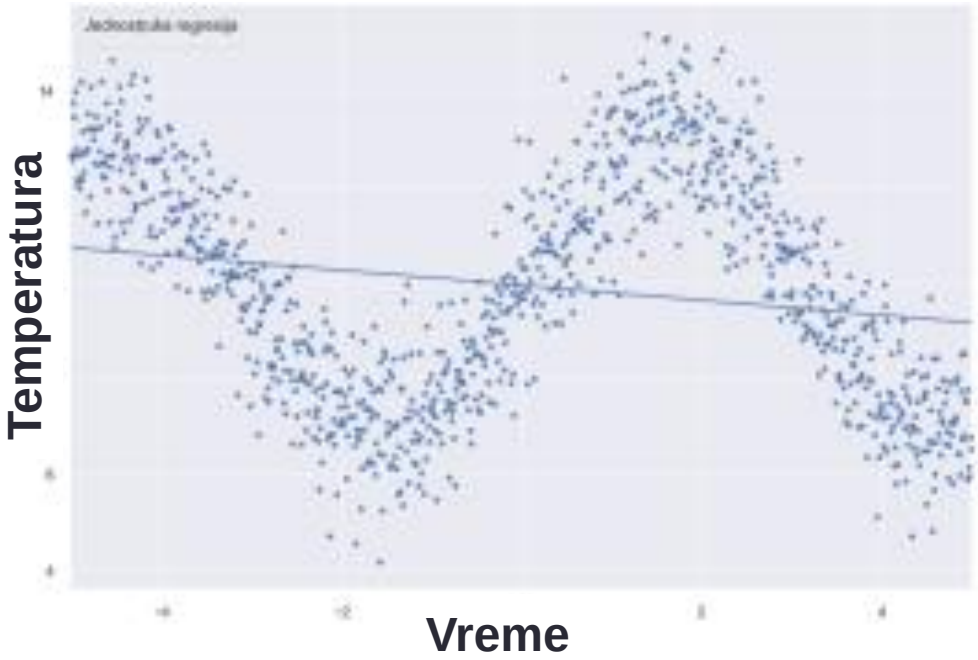

Regresiona prava nije dobar model trenda u podacima

Kako da znamo da su greške nezavisne?

1. Način: posmatranje grafika reziduala

- Reziduali e_i su procene grešaka ε_i dobijene iz uzorka:

$$e_i = \boxed{y_i} - \boxed{\hat{y}_i}$$

Stvarna vrednost — Predikcija regresionog modela

- Veza e_i i ε_i je ista kao veza između β_0 i β_1 sa b_0 i b_1

$$\boxed{Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i} \qquad \boxed{\hat{Y}_i = b_0 + b_1 X_i}$$

  - β_0, β_1 i ε su teorijski koncepti (vezani za populacioni model), dok su b_0, b_1 i e procene ovih koncepata dobijene iz uzorka podataka.

Kako da znamo da su greške nezavisne?

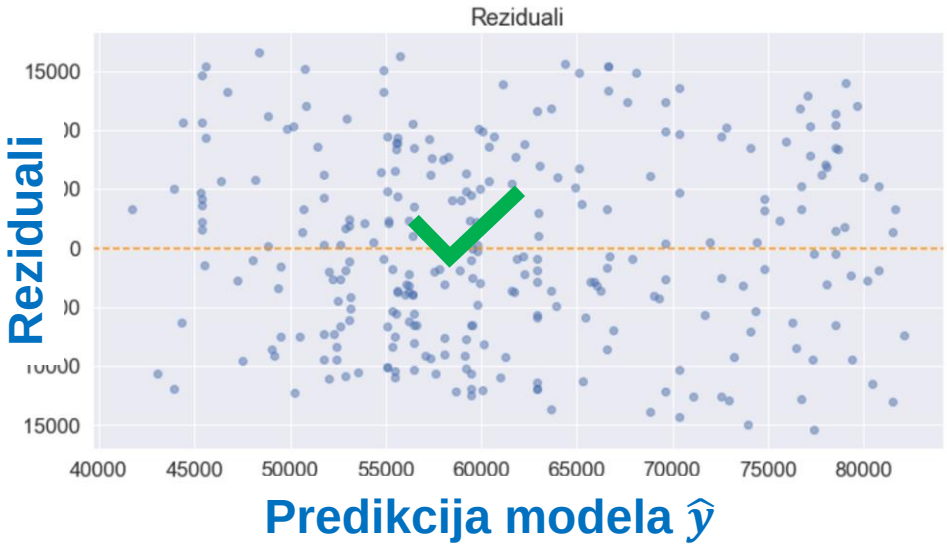

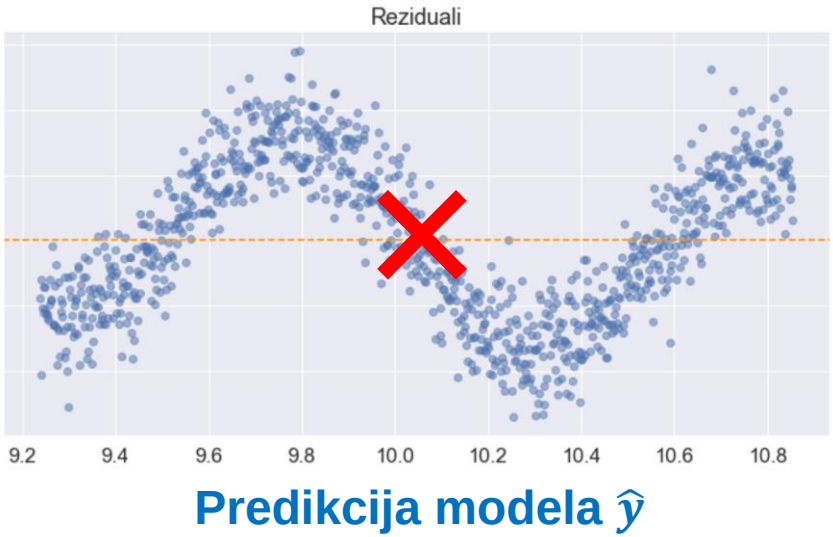

Reziduali ne prate nikakav šablon – međusobno su nezavisni

Sa grafika reziduala se vidi da reziduali imaju šablon – sledeći rezidual se može predvideti na osnovu prethodnog

Kako da znamo da su greške nezavisne?

2. Način: *Durbin-Watson* statistički test

- Statistički test koji meri autokorelaciju: korelaciju između vremenske serije y_k i te iste vremenske serije y_{k-1} pomerene za jednu vremensku jedinicu unazad
- Nećemo detaljno objašnjavati *Durbin-Watson* statistički test, već ćemo samo interpretirati rezultat testa
- U slučaju linearne regresije primenjuje se na rezidualima

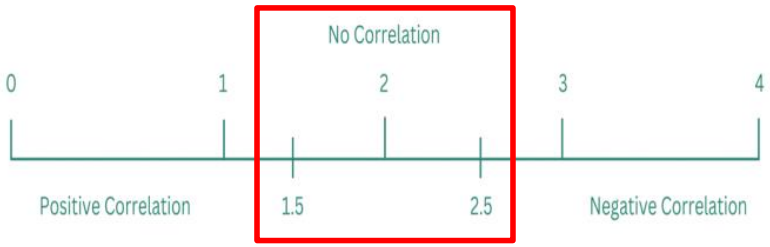

- Raspon vrednosti testa je 0-1, a pretpostavka je zadovoljena ako je rezultat u rasponu [1.5, 2.5].

Nezavisnost grešaka ε_i – testiranje – *Durbin-Watson*

Primer: cene kuća

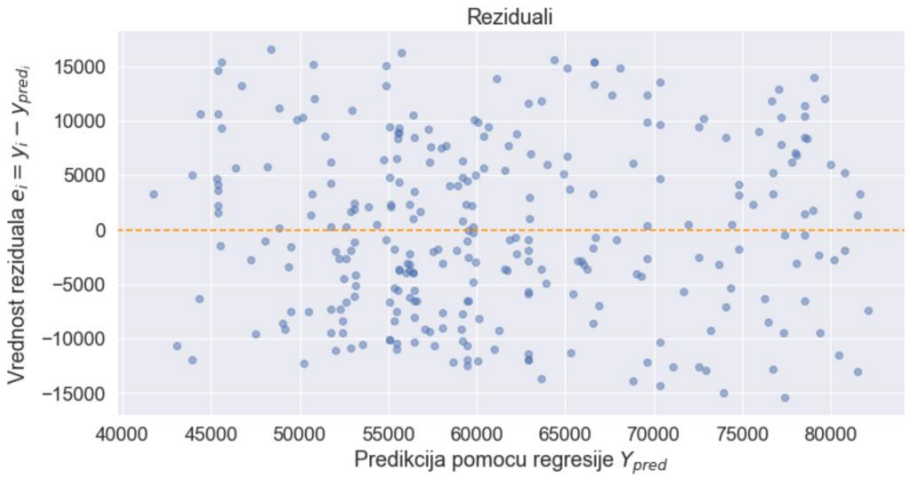

Primer: temperatura vazduha po vremenu

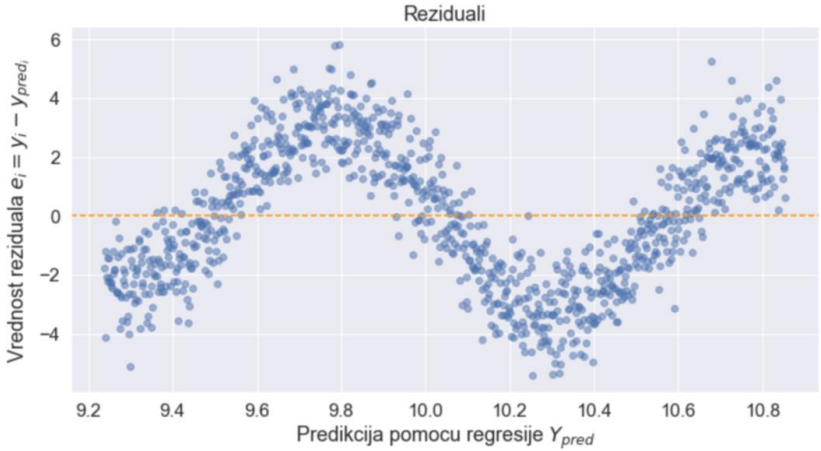

Durbin-Watson: 1.78
Nema autokorelacije
Pretpostavka važi.

(rezultat u rasponu [1.5, 2.5])

Durbin-Watson: 0.39
Pozitivna autokorelacija
Pretpostavka ne važi.

Šta ako greške nisu nezavisne?

- MNK nije prikladan estimator za linearnu regresiju
- Nećemo se fokusirati na dokaz ove činjenice niti na alternativne estimatore
- Zainteresovani mogu pročitati više o teoremi Gaus-Markova i npr. o Uopštenom Metodu Najmanjih Kvadrata (Weighted Least Squares)
  - Pored toga postoje tehnike kao što su Robusna linearna regesija ili Regresija pomoću kvantila

Šta ako greške nisu nezavisne?

- Procene parametara su nepouzdane
- Ne možemo zaključiti ništa o tome kako bi izgledao model kada bismo odabrali drugi uzorak podataka.
- Ne možemo da pouzdano znamo da li je došlo do preprilagođavanja (*overfitting*)
- Ako radimo sa podacima koji nisu vremenske serije, najčešće rešenje je pronalaženje dodatnih x
  - Npr., za procenu cene nekretnine, pored kvadrature koristiti i broj soba, kupatila,…
- Ako radimo sa vremenski serijama – koristimo model vremenskih serija (kasnija predavanja)

Normalnost grešaka ε_i

Greške ε_i su normalno distribuirane oko srednje vrednosti 0 za svako x_i

Za x_i regresioni model kao rezultat vraća srednju vrednost y_i u celoj populaciji

imamo puno malih i malo velikih grešaka, koje su podjednako pozitivne i negativne

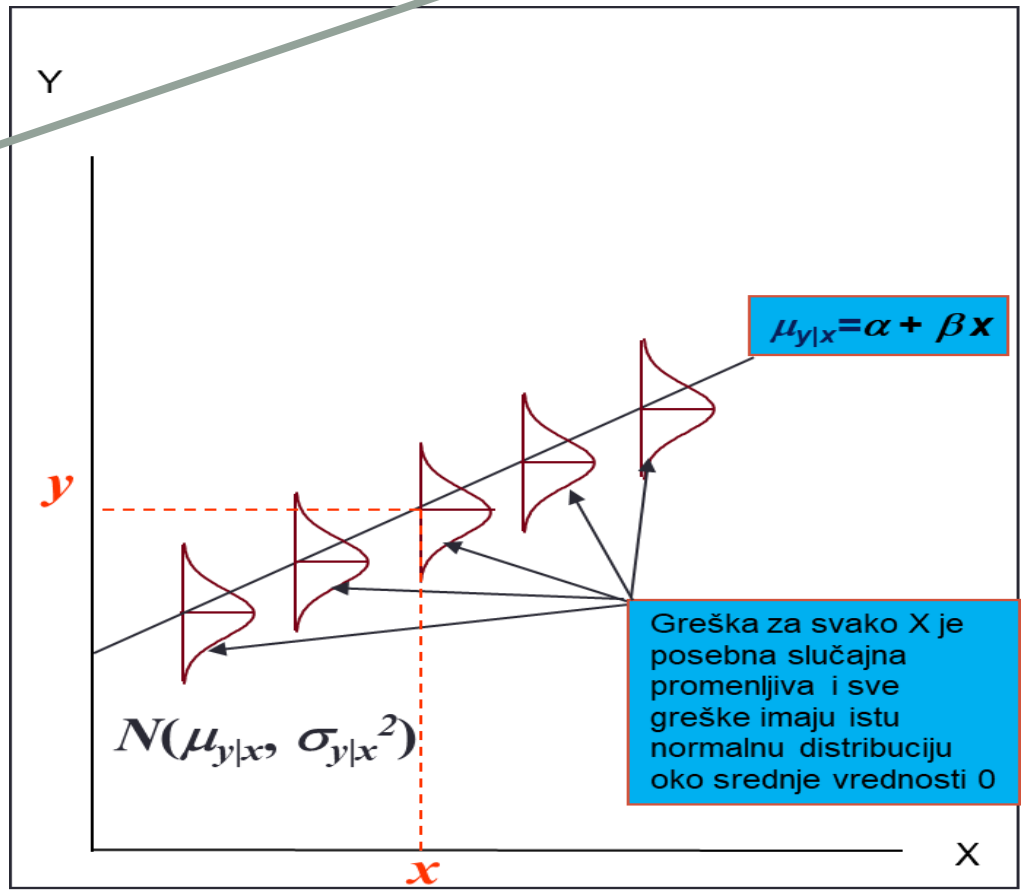

Kako znamo važi normalnost ε_i ?

- Objasnićemo prvo testiranje pretpostavke da je srednja vrednost 0
- Intuitivno, trebalo bi odrediti srednje vrednosti reziduala
- Na žalost, to nije dobar pristup jer je kod MNK po definiciji zbir reziduala uvek 0 (zbog čega je i srednja vrednost uvek 0)
- Prethodna tvrdnja se za jednostruku regresiju lako može izvesti iz jednog od koraka određivanja odsečka za MNK:

$$\frac{\delta SSE(k,n)}{\delta n} = 2\sum_{i=1}^{n}\underbrace{(y_i - kx_i - n)}_{\text{rezidual za } x_i}(-1) = 0$$

Kako znamo važi normalnost ε_i ?

- Možemo pogledati grafik rasipanja reziduala sa linijom* koja pokazuje koliko reziduali odstupaju od nule – želimo „što ravniju“ liniju.

Primer: cene kuća

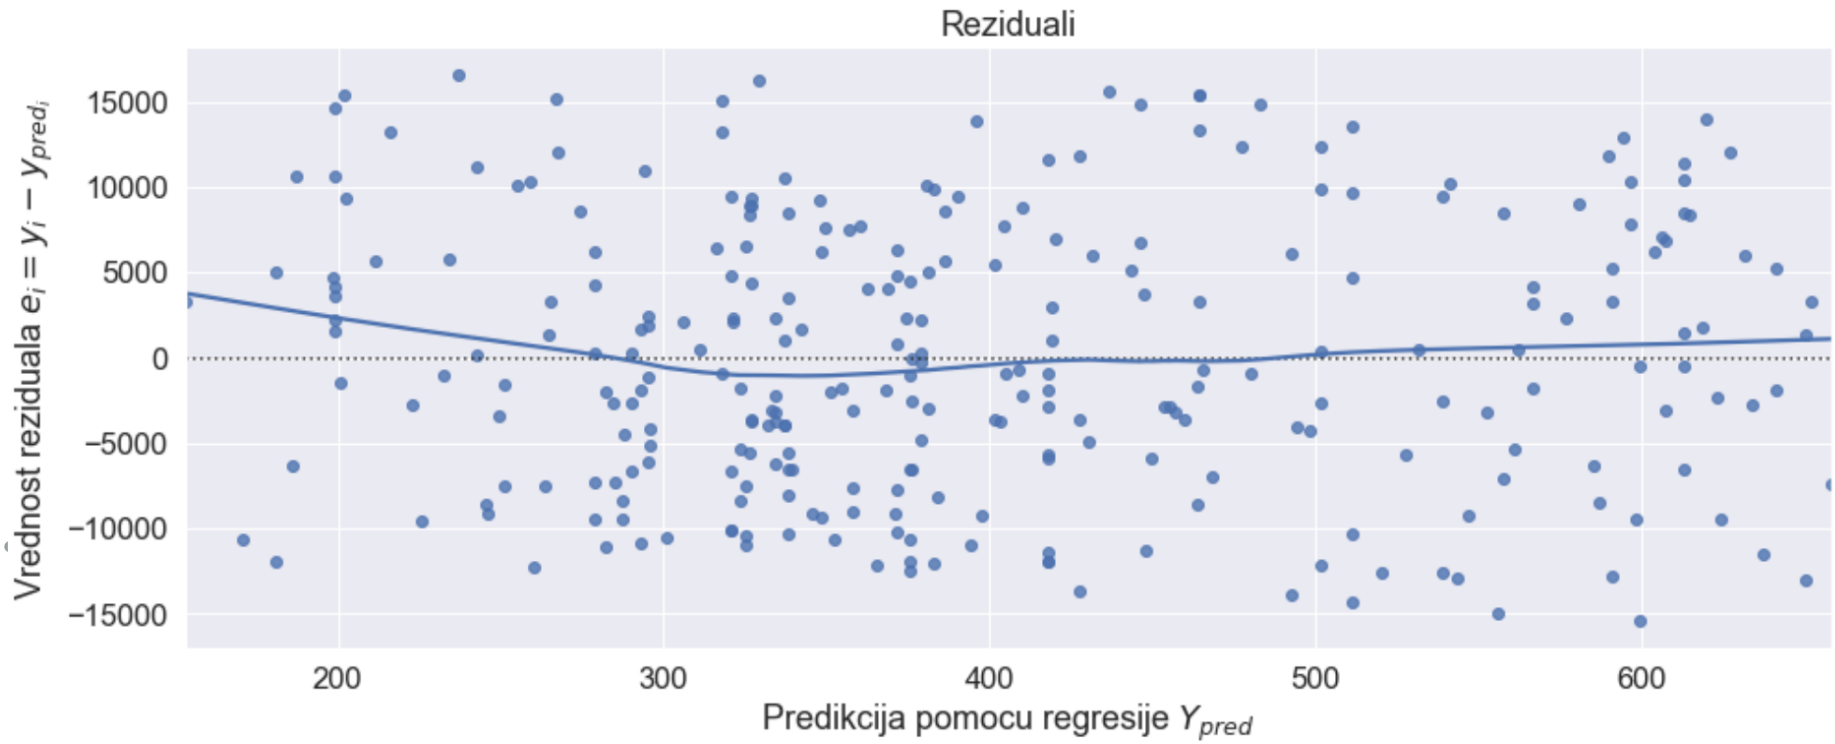

*Za detalje pogledati o LOWESS (*locally weighted scatterplot smoothing*) liniji.

Kako znamo važi normalnost ε_i ?

- Pretpostavku da je distribucija grešaka normalna testiramo pomoću:
  - Histograma reziduala
  - I nekog od statističkih testova (npr. *Shapiro-Wilk*)

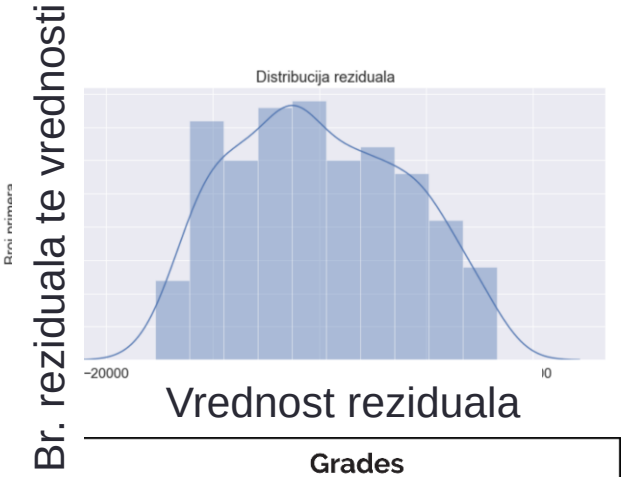

- Histogram se formira tako što:
  - x-osa: podelimo raspon svih primera na delove (npr., jednaki delovi)
  - y-osa: za svaki deo prebrojati podatke koji pripadaju tom rasponu

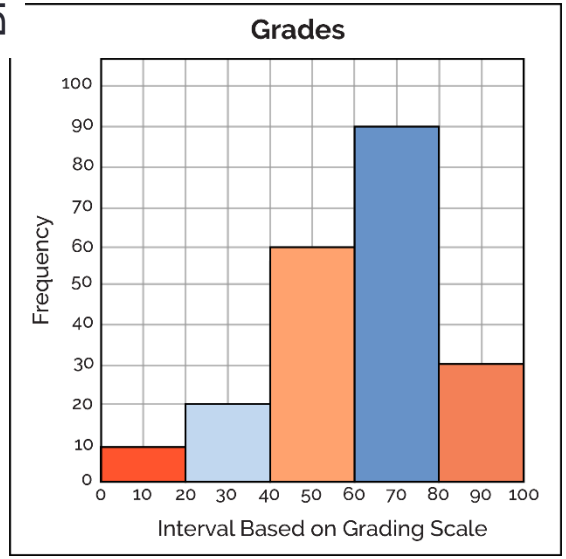

Kako znamo važi normalnost ε_i ?

- *Shapiro-Wilk* - statistički test pomoću koga za proizvoljne ulazne podatke možemo da proverimo da li su normalno distribuirani
- U slučaju linearne regresije primenjuje se na rezidualima
- Nećemo detaljno objašnjavati sam test, već samo interpretaciju njegovih rezultata
- Raspon vrednosti testa je [0, 1], a vrednost veća ili jednaka od 0.05 je indikator da podaci prate normalnu distribuciju
- Dakle, pretpostavka je zadovoljena ako je rezultat u rasponu [0.05, 1].

Kako znamo važi normalnost ε_i ?

Primer: cene kuća

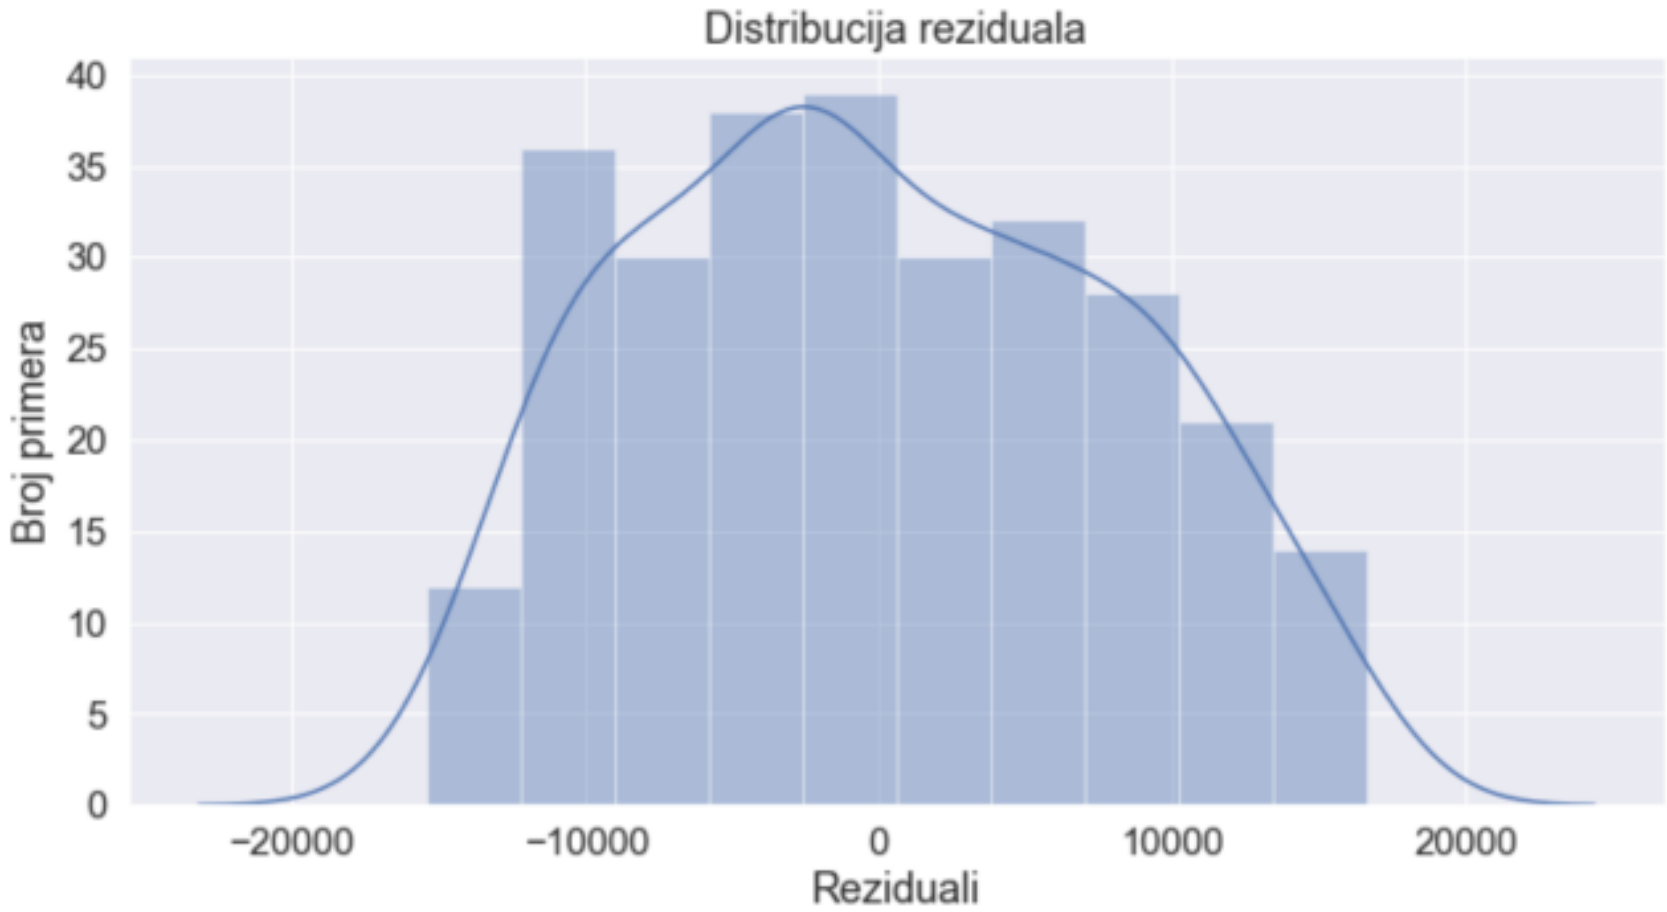

Shapiro-Wilk: $3.82 * 10^{-5}$

Pretpostavka (2) ne važi.

Šta ako je pretpostavka o normalnosti narušena?

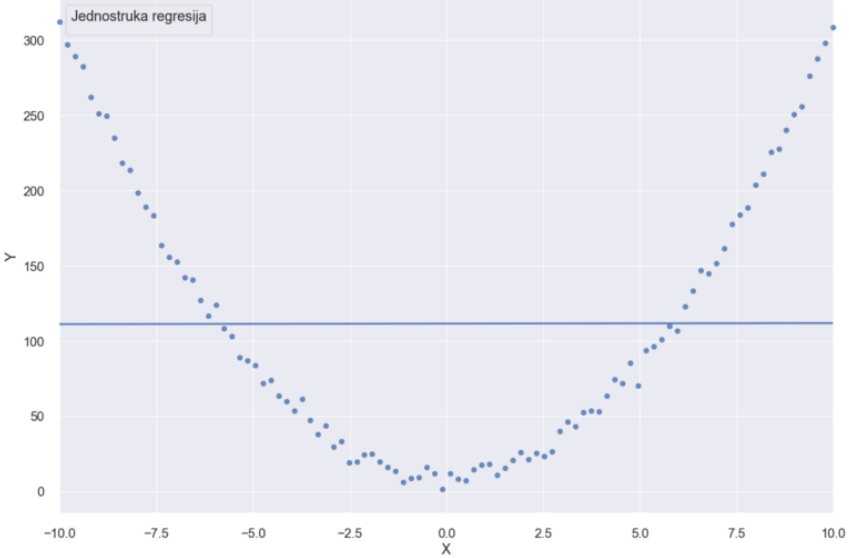

- Značajnija je pretpostavka da srednja vrednost grešaka ε_i nije 0
- To znači da linearan model nije prikladan model za dati uzorak podataka
- Potencijalna rešenja su ista kao kod narušenosti pretpostavke o linearnosti:
  - Promena modela (npr., neuronske mreže)
  - Uvođenje novih nezavisnih x
  - Transformacije postojećih x

Šta ako je pretpostavka o normalnosti narušena?

- Posledice narušenosti pretpostavke o normalnoj distribuciji ε_i zavise od veličine uzorka

- Ako je uzorak mali, procene parametara i predikcije modela su nevalidne
  - Model je potencijalno preprilagođen, a mi nemamo način da to utvrdimo

- Potencijalna rešenja: transformacija x i/ili y pomoću logartma ili korena

Šta ako je pretpostavka o normalnosti narušena?

- Ako je uzorak velik, u praksi se ova pretpostavka tipično ignoriše
- Smatra se da su zaključivanja o parametrima i predikcijama u slučaju promene uzroka validna
- Po (Green 1991)* grubo pravilo šta znači veliki uzorak je:

  104 + *broj_zavisnih_promenjljivih*

- Kod jednostruke regresije, uzorak sa bar 105 primera možemo smatrati velikim

*Green SB. How Many Subjects Does It Take To Do A Regression Analysis. Multivariate Behav Res. 1991 Jul 1;26(3):499-510.

Šta ako je pretpostavka o normalnosti narušena?

- Primer cena kuća: ako u model uvedemo sve nezavisne promenjljive iz skupa podataka dobijamo model višestruke linearne regresije prikazan u tabeli
- Reziduali takvog modela imaju normalnu distribuciju, što se može videti i sa grafika i iz rezultata Shapiro-Wilk testa

	coef
const	1.912e+04
lotsize(m^2)	63.1780
bedrooms	41.8319
bathrms	4348.5315
stories	3903.9671
driveway	1371.5360
recroom	3985.9209
fullbase	2492.1516
gashw	148.2952
airco	3045.3796
garagepl	671.0931
prefarea	4289.9797

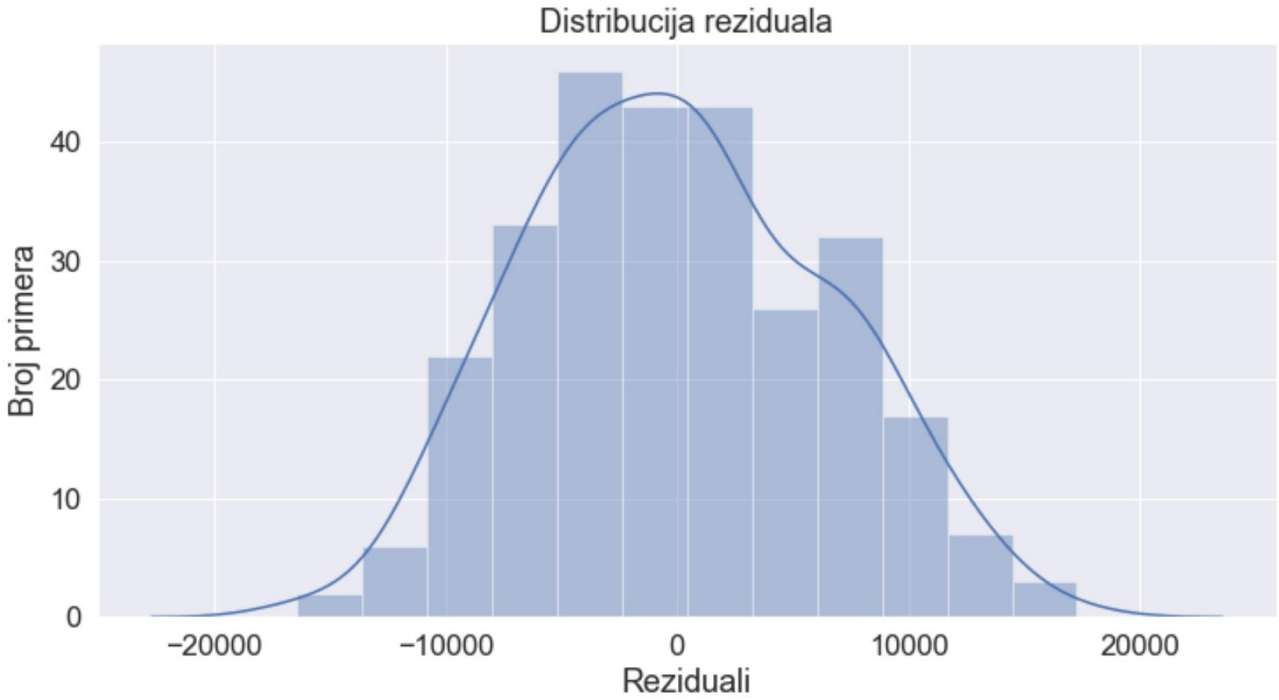

Shapiro-Wilk: 0.124
Pretpostavka (2) važi.

Revizija prethodnog gradiva

1. Navedite pretpostavke linearne regresije
   1. Linearnost (**L**inearity)
   2. nezavisnost grešaka ε_i (**I**ndependence of errors)
   3. normalnost grešaka ε_i (**N**ormality of errors)
   4. Jednakost varijanse ε_i (**E**qual variance of errors)

2. Objasnite pretpostavku o linearnosti
   - Ako odnos između x i y nije linearan, koristimo pogrešan model

Kako ovo proveravamo?

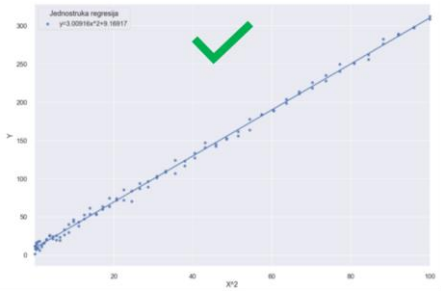

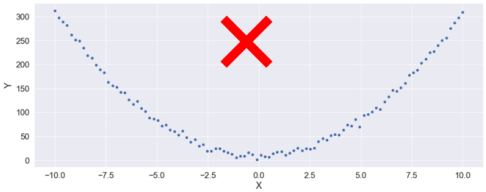

Kako da rešimo?

1. Transformacija X
2. Nelinearan model

Revizija prethodnog gradiva

1. Objasnite pretpostavku o nezavisnosti grešaka
   - Ako znamo nešto o nekoj grešci ε_i, to nam ne govori ništa o bilo kojoj drugoj grešci ε_j

Kako ovo proveravamo?

Grafik rasipanja reziduala i Durbin-Watson test

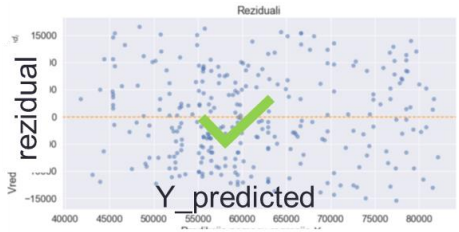

Durbin-Watson: $1.78 \in [1.5, 2.5]$

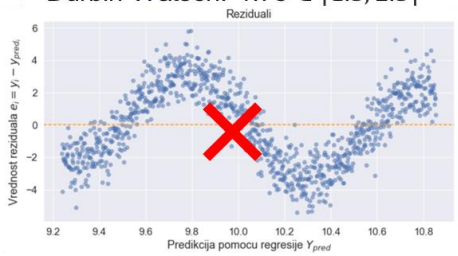

Durbin-Watson: $0.39 \notin [1.5, 2.5]$

Kako da rešimo?

1. Podaci su vremenske serije $\rightarrow$ koristiti taj model
2. Podaci nisu vremenske serije:
   1. Dodati druga obeležja
   2. Ne koristiti MNK estimator

Revizija prethodnog gradiva

1. Objasnite pretpostavku o normalnosti grešaka
   - Greške ε_i su (1) normalno distribuirane (2) oko srednje vrednosti 0 za svako x_i

Kako ovo proveravamo?

Dijagnostika (1)

Shapiro-Wilk: $0.124 \in [0.05,1]$

Shapiro-Wilk: $3.82 * 10^{-5} \notin [0.05, 1]$

Histogram reziduala i *Shapiro-Wilk test*

Dijagnostika (2)

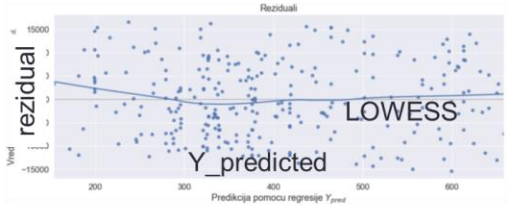

Grafik rasipanja reziduala sa LOWESS linijom

Kako da rešimo?

Veliki uzorak: možemo ignorisati

Mali uzorak: transformacija x i/ili y (log, √)

Jednaka varijansa grešaka ε_i – tumačenje

Normalne raspodele ε_i oko regresione prave imaju jednaku varijansu.

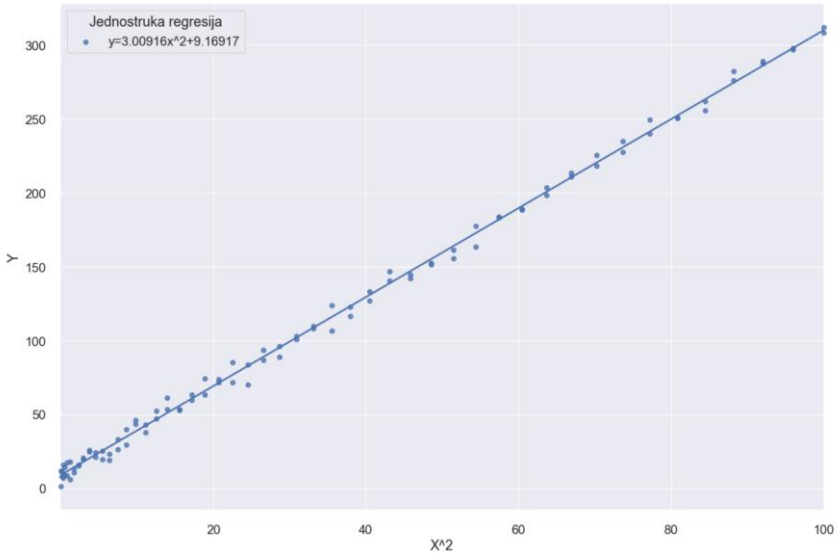

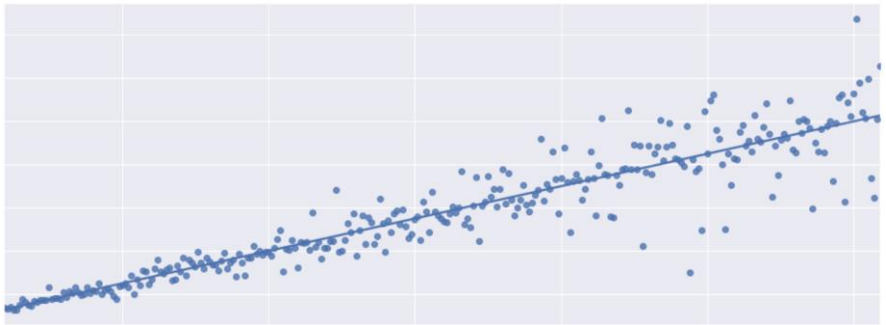

Intuitivno, želimo da kvalitet našeg modela bude jednak za svako X iz raspona koji imamo u uzroku

Jednaka varijansa grešaka ε_i – tumačenje

- Recimo da koristimo linearnu regresiju da modelujemo potrošnju nekog domaćinstva u zavisnosti od prihoda:

$$potrošnja = \beta_1 \cdot prihod + \beta_0$$

- Što su prihodi domaćinstva veći to je veća varijabilnost u potrošnji
  - Veći prihod daje mogućnost izbora u smislu da li će da se troši manje ili više
- Domaćinstva sa manjim prihodom nemaju mogućnost da mnogo variraju svoju potrošnju

Jednaka varijansa grešaka ε_i – tumačenje

- Grafik: vrednosti potrošnje imaju mnogo veću varijansu za veće prihode
- Predikcije su pouzdanije za manje prihode nego za veće
- Problematično → model treba da ima isti kvalitet predikcije u celom rasponu prihoda

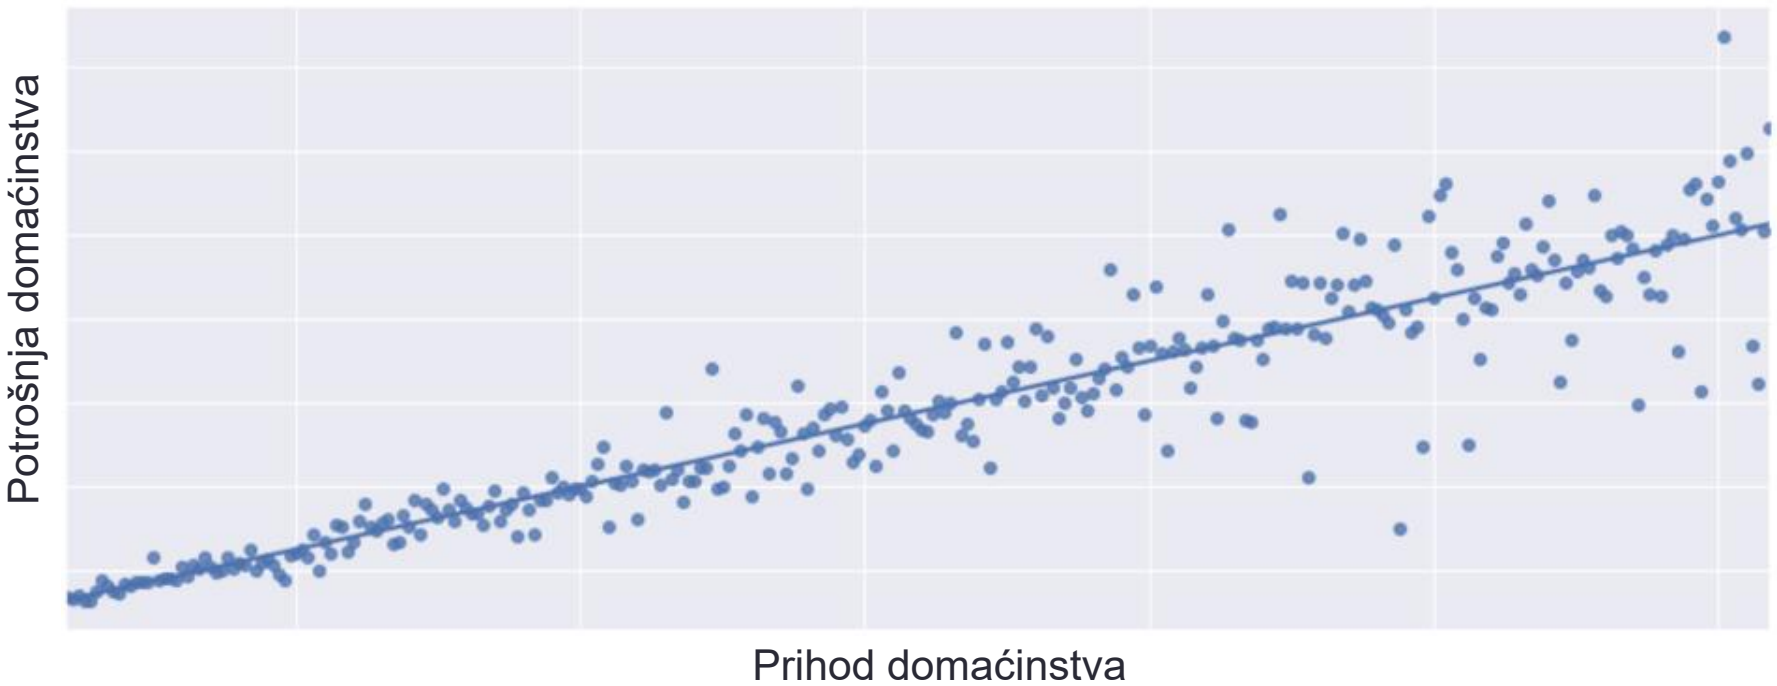

Kako znamo da je varijansa grešaka ε_i jednaka?

- Posmatramo grafik raspiranja reziduala
- Tipični šabloni za „neravnomernu rasutost“ reziduala oko 0 su „levak“ ili „mašna“

Bez šablona

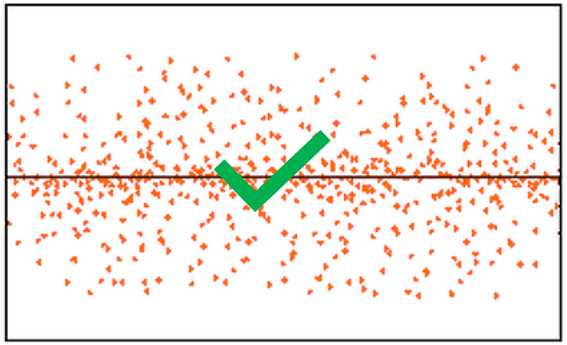

Random Cloud (No Discernible Pattern)

„Mašna“

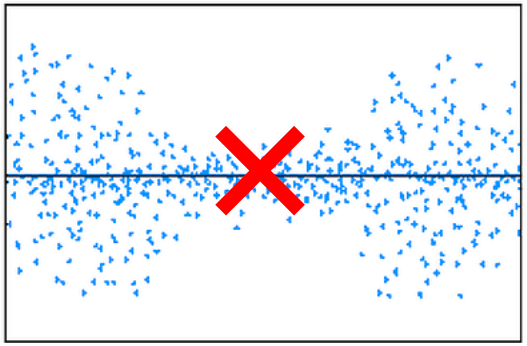

Bow Tie Shape (Pattern)

Pretpostavka ne važi

„Levak“

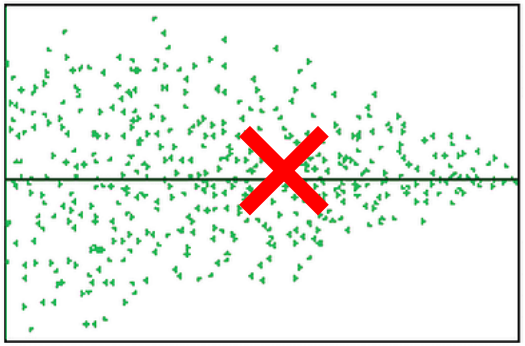

Fan Shape (Pattern)

Pretpostavka ne važi

Primer testiranja pretpostavke o jednakosti varijanse grešaka ε_i

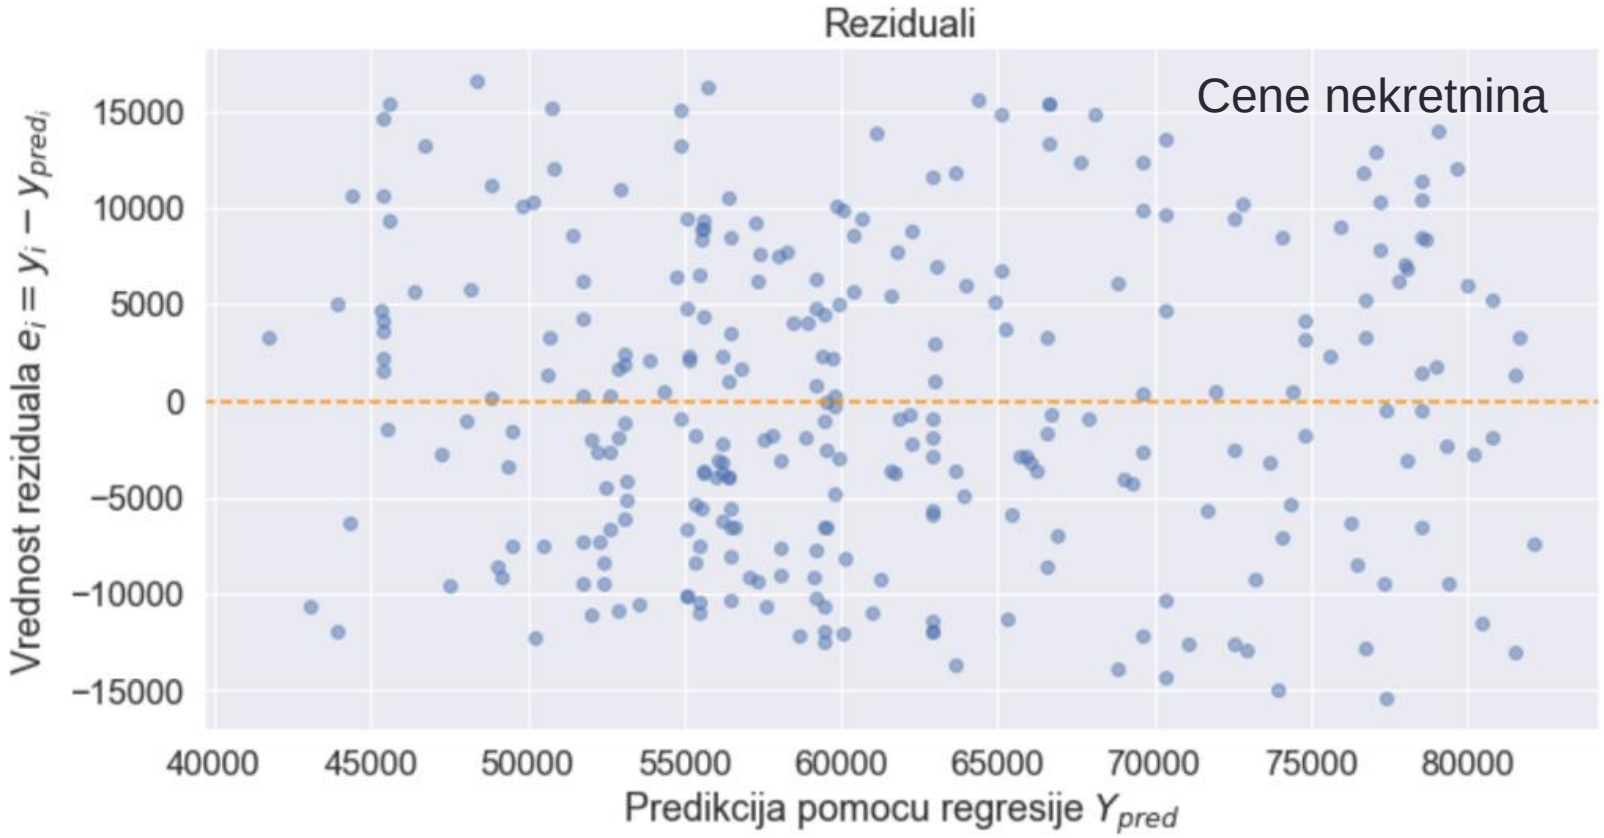

Na grafiku rasipanja nema šablona – prepostavka o jednakoj varijansi ε_i važi.

Šta ako je pretpostavka o jednakosti varijanse narušena?

- MNK nije prikladan estimator za linearnu regresiju

1. Isprobati transformacije X i/ili y $(log, \sqrt{})$

2. Ako ne uspe, zameniti estimator. Na primer, Uopšteni Metod Najmanjih Kvadrata (*Weighted Least Squares*)

Zaključivanje o modelu linearne regresije

- Nakon testiranja pretpostavki regresije prelazimo na testiranje kvaliteta modela:
  - statističko zaključivanje (*inference*) o regresionom modelu

- Koristimo trening skup (uzorak podataka korišćen za određivanje parametara modela)

- Pretpostavke → da li je model razuman
- Statističko zaključivanje → da li je model statistički podržan u populaciji

Zaključivanje o modelu linearne regresije – linearna veza između X i y?

- Pretpostavku o linearnosti proverili smo pomoću grafika rasipanja
- Dodatno je proveravamo pomoću testiranja statističkih hipoteza

- Kada testiramo statističke hipoteze mi želimo da proverimo da li je neka razlika vrednosti koju smo primetili u uzorku realna?
  - Da li linearnost stvarno važi u celoj populaciji
  - Ili odnos samo izgleda linearno u našem uzorku (zbog slučajne varijabilnosti)?

Na primer:
Sa li ljudi sa visokim pritiskom imaju više kardiovaskularnih bolesti – stvarno, ili samo u ovom uzorku?

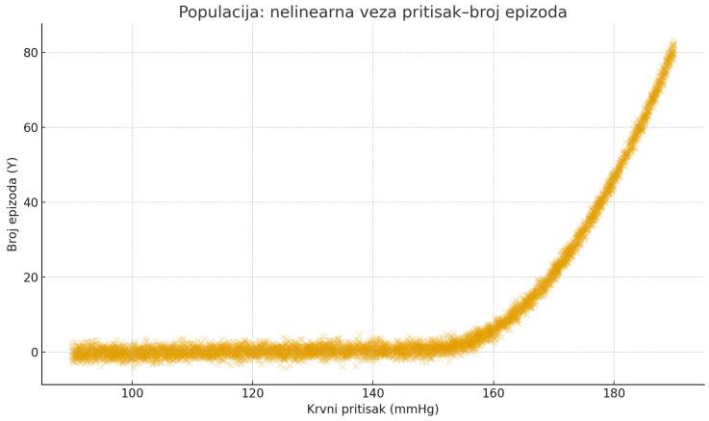

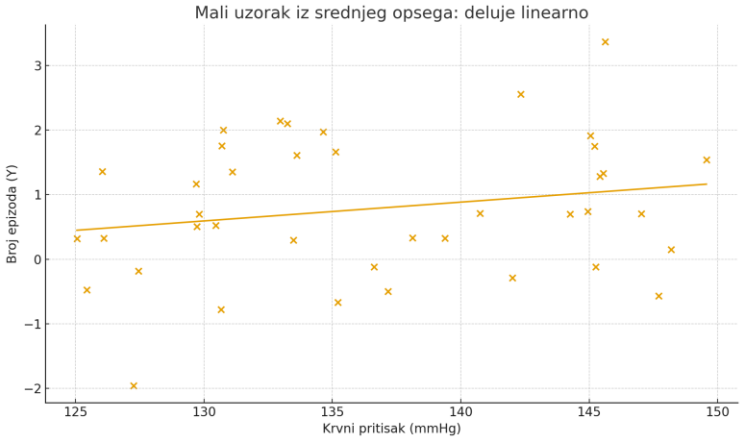

Zaključivanje o modelu linearne regresije – t-test

- Kada testiramo statističku hipotezu, koristimo statistički test koji meri odnos *signala* i *buke*
  - Signal je razlika u vrednostima koje želimo da proverimo
  - Buka je mera nesigurnosti u toj vrednosti (varijabilnost koja potiče iz konačnog uzorka)

- Buka je količnik dve vrednosti:
  1. Mere varijabilnosti vrednosti kada se promeni uzorak.
     - Koliko bi se naša procena promenila kada bismo uzeli novi uzorak?
  2. Veličine uzorka
     - Veći uzorak smanjuje buku zato što umanjuje slučajnu varijabilnost
     - Nije isto procenjivati broj kardiovaskularnih bolesti na uzorku od 100 ili 100.000 ljudi

- Što je buka veća, to smo manje sigurni u naše procene → signal mora biti jači da bi statistički test zaključio da je razlika stvarna

- Kao kada pričate sa nekim:
  - u čitaonici lako čujete i slab signal
  - Na svadbi, zbog velike buke, signal mora biti mnogo jači da biste ga razumeli

Zaključivanje o modelu linearne regresije – t-test

- Hipoteza koju testiramo je da li je $\beta_1=0$, odnosno da li postoji linearna veza između X i Y? (ako je 0, ne postoji):

$$Y = \beta_1 X + \beta_0 + \varepsilon = 0 \cdot X + \beta_0 + \varepsilon = \beta_0 + \varepsilon$$

- Za test koristimo b_1, odnosno procenu β_1 iz uzorka.

- Signal definišemo kao $b_1 - 0$

- Buku definišemo kao standardnu grešku nagiba: mera koliko bi nagib varirao za promene uzoraka podataka

Zaključivanje o modelu linearne regresije – standardna greška nagiba

- Nagib regresione prave b_1 dobijen pomoću MNK je procena populacionog nagiba β_1 (isprekidana linija na slici)
- Procena b_1 varira u zavisnosti od uzorka podataka
- Standardna greška nagiba je procena te varijabilnosti

Zaključivanje o modelu linearne regresije – standardna greška nagiba

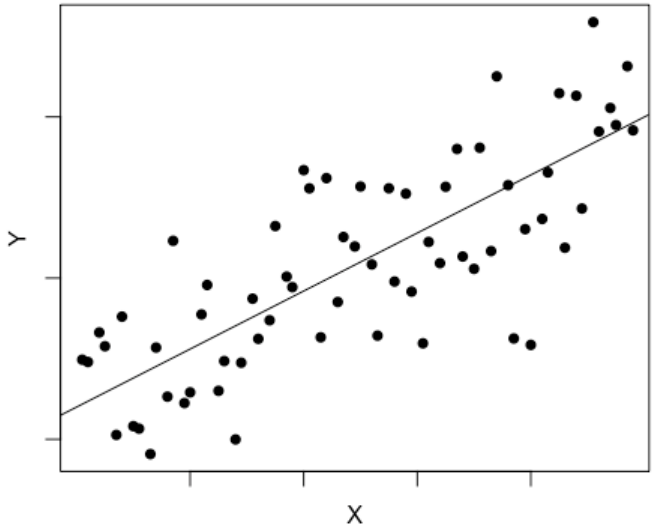

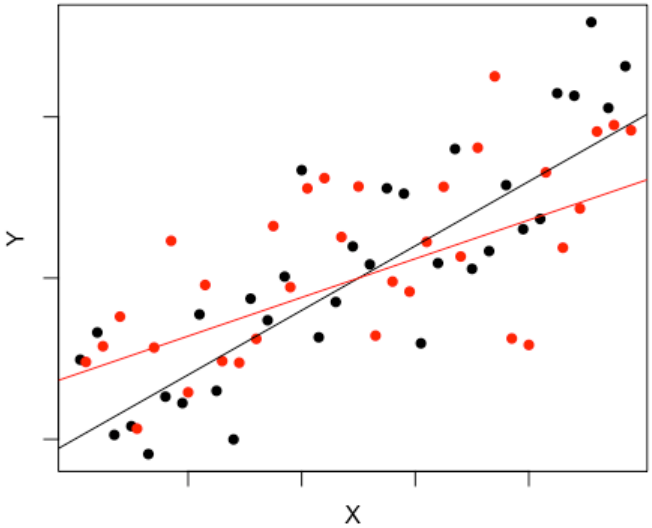

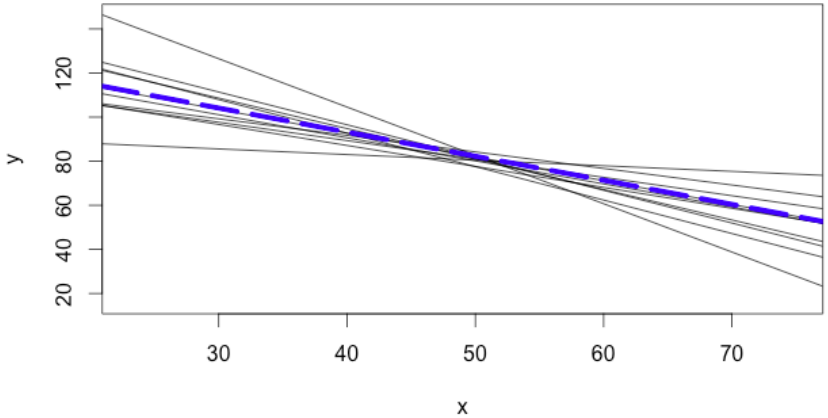

Standardna greška nagiba je procena varijabilnosti b_1

$$S_{b_1} = \frac{\text{vertikalno rasipanje (šum)}}{\text{horizontalni raspon X-a (korisna informacija)}}$$

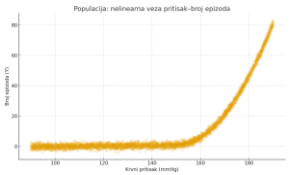

Zaključivanje o modelu linearne regresije – standardna greška nagiba

- Standardna greška nagiba (b_1) se računa na sledeći način:

$$S_{b_1} = \frac{S_{YX}}{\sqrt{SSX}} = \frac{S_{YX}}{\sqrt{\sum (X_i - \overline{X})^2}}$$

Koliko bi se nagib regresione prave b_1 menjao kada bismo ponovo uzeli drugi uzorak iz iste populacije?

Koliki je raspon x

$$S_{YX} = \sqrt{\frac{SSE}{n-2}}$$ = Standardna devijacija reziduala

(Koliko tačke „šaraju“ oko regresione linije)

- Obratite pažnju da veličina uzorka (n) figuriše u formuli za S_{YX}, te i na odnos signal-buka:
  - Veće n → manje S_{YX} → manje S_{b1}
  - Osnosno, veći uzorak „ublažava“ varijabilnost (smanjuje buku)

Zaključivanje o modelu linearne regresije – T-vrednost

- T-vrednost meri odnos signala i buke:

$$T - vrednost = \frac{signal}{buka} = \frac{b_1 - 0}{s_{b_1}} = \frac{b_1}{s_{b_1}}$$

- Ovo je konkretan broj. Šta nam on govori?

Zaključivanje o modelu linearne regresije – T-vrednost

- Idealno: znamo kakve su T-vrednosti kada hipoteza (β_1=0) važi
  - Onda bismo mogli da uporedimo dobijenu T-vrednost sa time i damo zaključak o važenju hipoteze

- Rešenje:
  - pronađemo populaciju primera u kojoj hipoteza važi
  - prikupimo više uzoraka iz populacije,
  - odredimo T-vrednosti
  - Kreiramo njihov histogram.

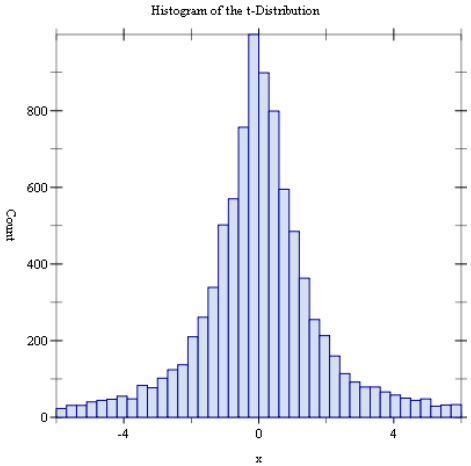

Zaključivanje o modelu linearne regresije – t-distribucija

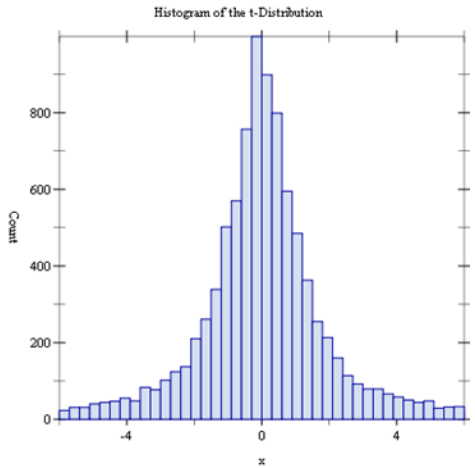

- Koliko je naša T-vrednost česta (koliko liči na ovu populaciju u kojoj hipoteza $\beta_1=0$ važi)?
- Na primer, vrednosti veće od 4 ili manje od -4 su retke, dok su vrednosti oko nule česte

- Ako naša T-vrednost nije česta → hipoteza $\beta_1=0$ ne važi
- Opisani postupak se koristi u praksi, ali ne moramo sami formirati histogram – istraživanjima je utvrđeno kako izgledaju histogrami T-vrednosti u slučaju kada važi $\beta_1=0$ (mali signal naspram buke)
- Oblik histograma određen je t-distribucijom – distribucija koju prate T-vrednosti

Zaključivanje o modelu linearne regresije – P-vrednost

- Kada imamo T-vrednost i t-distribuciju onda određujemo p-vrednost (*p-value*).

- P-vrednost je ukupna verovatnoća da ćemo iz t-distribucije izvući našu T-vrednost ili neku još manje verovatnu (obojen deo distribucije na slici).

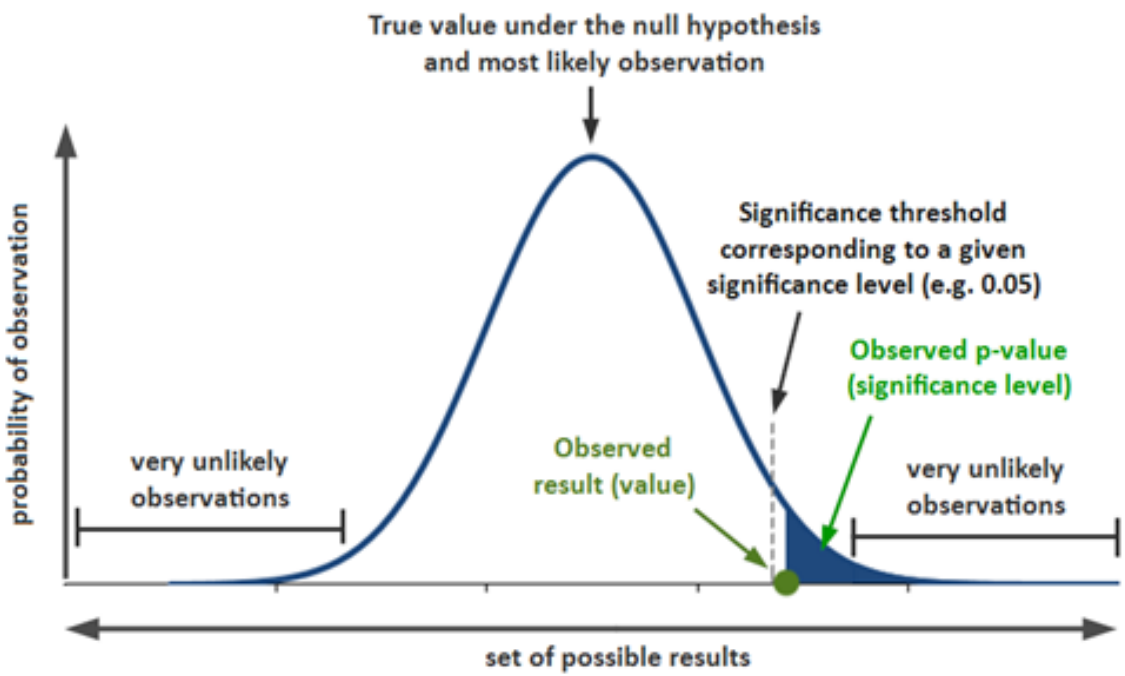

Zaključivanje o modelu linearne regresije – P-vrednost

- Želimo što manju p-vrednost. Prag koji se koristi u praksi je 0.05
  - Ako je p-vrednost ≤ 0.05 onda zaključujemo da signal postoji, odnosno da je $\beta_1 \neq 0$
- Veći deo distribucije zauzimaju T-vrednosti koje bismo dobili da važi $\beta_1=0$ (tako je t-distribucija formirana)
- Ako je p-vrednost ≤ 0.05 to znači da postoji ≤ 5% verovatnoće da ćemo dobiti našu T-vrednost ako važi $\beta_1=0$.
- Odnosno možemo sa 95% sigurnosti da zaključimo da je $\beta_1 \neq 0$.

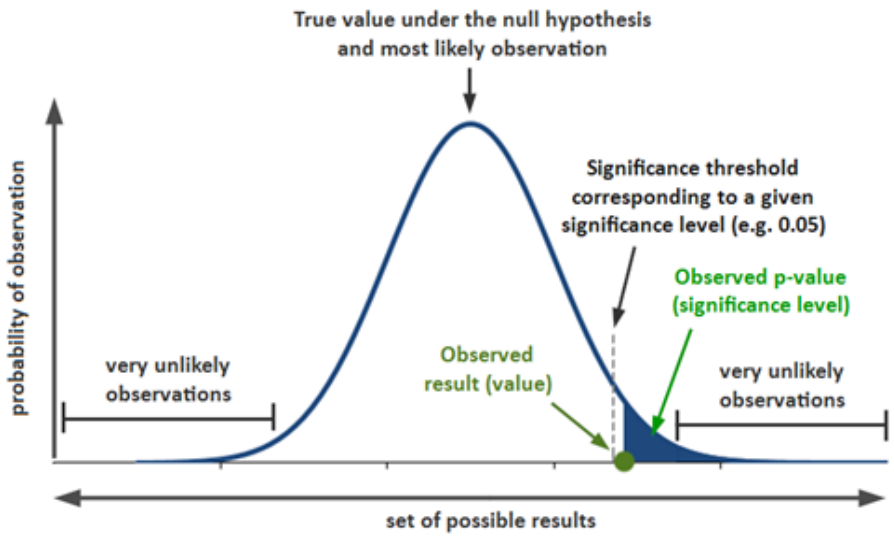

Zaključivanje o modelu linearne regresije – P-vrednost - Primer

- T- i p- vrednosti ne izračunavamo ručno, već koristimo softver
- Primer sa cenama kuća (*Python* biblioteka *statsmodels*):

	coef	std err	t	P>|t|
const	2.942e+04	1608.768	18.288	0.000
lotsize(m^2)	80.0664	3.856	20.764	0.000

- T-vrednost za β_1 je 20.764 dok je p-vrednost nula, tj. sigurno ispod 0.05.

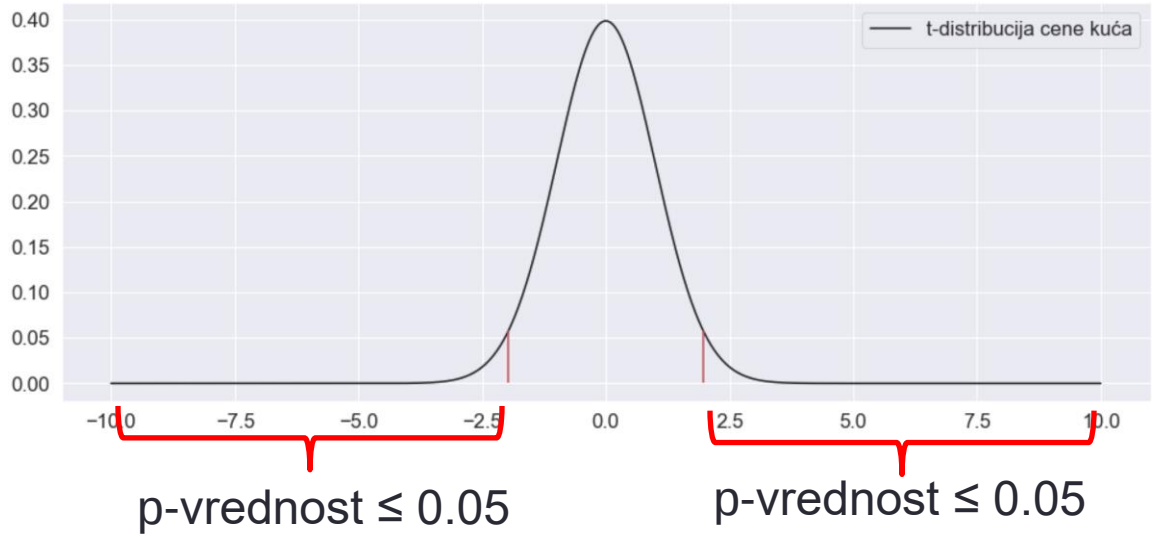

Zaključivanje o modelu linearne regresije – Interval poverenja

- Interval poverenja je raspon vrednosti u kome će se potencijalno naći prava vrednost parametra koji procenjujemo na osnovu uzorka

- Prava vrednost → vrednost koju bismo dobili kada bi nam uzorak bila cela populacija (nije nam dostupna)

- Interval poverenja nam daje „realan prostor“ gde se prava vrednost verovatno nalazi.

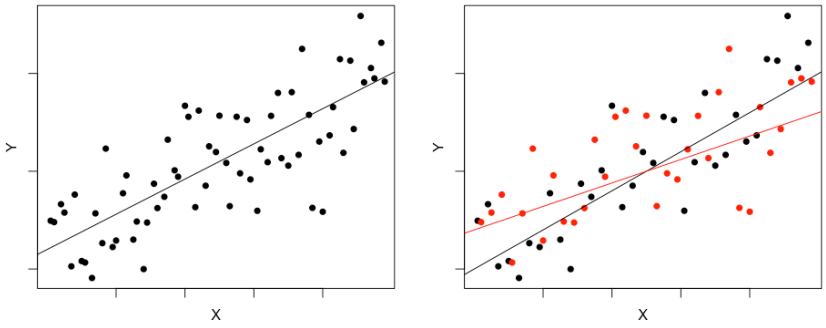

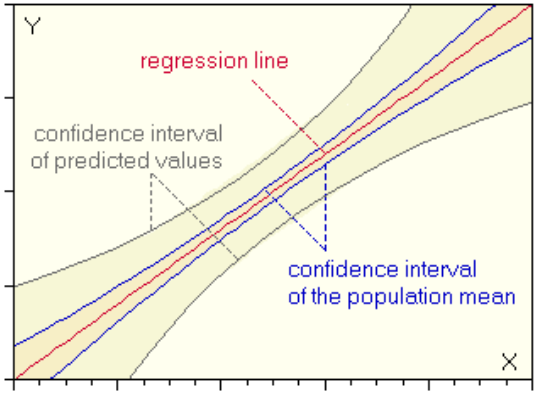

- Intervali poverenja kreiraju se za određeni procenat pouzdanosti

Zaključivanje o modelu linearne regresije – Interval poverenja za β_1

- Tipično se bira nivo pouzanosti od 95%
  - Kada bismo 100 puta uzeli novi uzorak i svaki put izračunali interval poverenja, oko 95 tih intervala bi sadržalo pravu vrednost parametara
  - Metod je 95% pouzdan

- Za linearnu regresiju kreiraju se intervali poverenja za parametre i predikcije

Zaključivanje o modelu linearne regresije – Interval poverenja za β_1 - Primer

- Interval poverenja za naš primer sa cenama kuća pomoću:

	coef	std err	t	P>|t|	[0.025	0.975]
const	2.942e+04	1608.768	18.288	0.000	2.63e+04	3.26e+04
lotsize(m^2)	80.0664	3.856	20.764	0.000	72.476	87.657

- Sa pouzdanošću od 95% zaključujemo da je β_1 između 72.4 i 87.6

- Na osnovu našeg uzorka možemo da sa pouzdanošću od 95% da tvrdimo da se cena kuće u populaciji poveća za iznos između 72.4 i 87.6 dolara kada se površina placa poveća za 1m^2

Zaključivanje o modelu linearne regresije – Interval predikcije

- Interval predikcije je raspon vrednosti u kome će se potencijalno naći prava vrednost zavisne promenjlijve Y za neko zadato X_d

- Prava vrednost → vrednost koju bi populacioni model vratio ako bismo u njega uneli X_d:

$$Y_d = \beta_1 \cdot X_d + \beta_0 + \varepsilon_d$$

- Gde su β_0 i β_1 parametri populacionog modela, X_d neka data tačka, a ε_d je greška populacionog modela za X_d

Zaključivanje o modelu linearne regresije – Interval predikcije

- Naravno, mi ne znamo parametre populacionog modela i slučajnu grešku ε_d
- Zato kreiramo interval predikcije kako bismo sa određenom pouzdanošću procenili gde se nalazi vrednost Y_d
- Npr., dat je populacioni model cena kuća u Srbiji (modelovan pomoću svih kuća u Srbiji) i znamo vrednosti svih slučajnih grešaka
- Y_d bi bila cena kuće koju bi vratio populacioni model za neko X_d (npr., 132m^2)

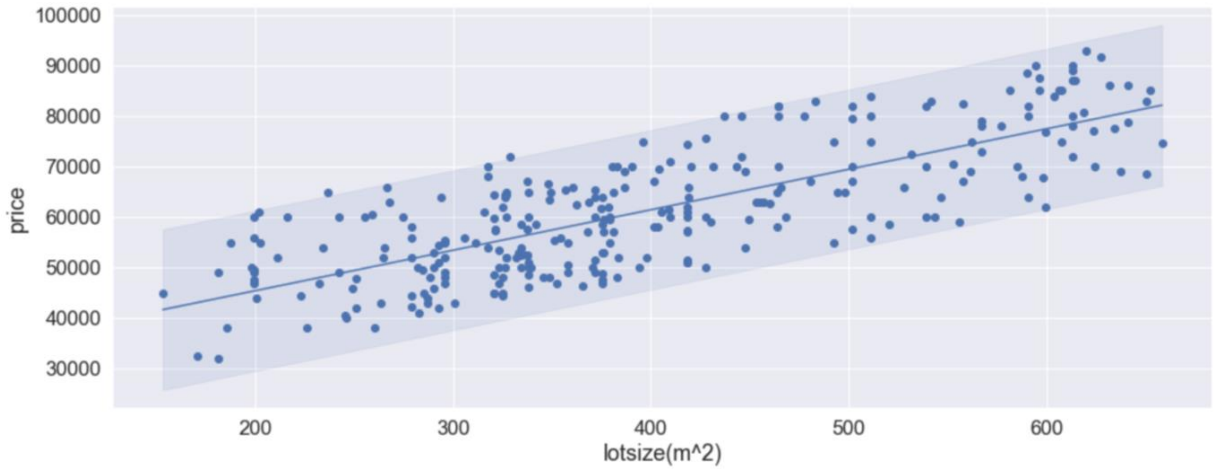

Zaključivanje o modelu linearne regresije – Interval predikcije - interpretacija

- Kao i kod intervala poverenja, moramo da odaberemo pouzdanost (tipično 95%)

- Interpretacija: za 100 različitih uzoraka, gde je za svaki kreiran interval predikcije za za dato X_d, 95 tih intervala sadrži pravu vrednost Y_d

- Ako bismo:
  - Uzeli 100 različitih uzoraka stanova iz populacije
  - Za svaki napravili model
  - Za svaki izračunali predikcioni interval za stan od 132 m²
  - Oko 95 od tih 100 intervala bi obuhvatilo pravu (stvarnu) tržišnu cenu tog stana

- Npr., za površinu od 132 m², model daje sledeći rezultat:
  - Procena očekivane cene (procena modela): 310.000 €
  - Predikcioni interval (95%): od 250.000 € do 370.000 € - realna cena nasumičnog stana te kvadrature obično pada u ovaj opseg

Zaključivanje o modelu linearne regresije – Interval predikcije – Primer cene kuća

- Pomoću Python biblioteke statsmodels izračunali smo intervale predikcije za svaki primer iz skupa podataka cena kuća

- Sa grafika se vidi da su intervali predikcije ravnomerni za ceo raspon X

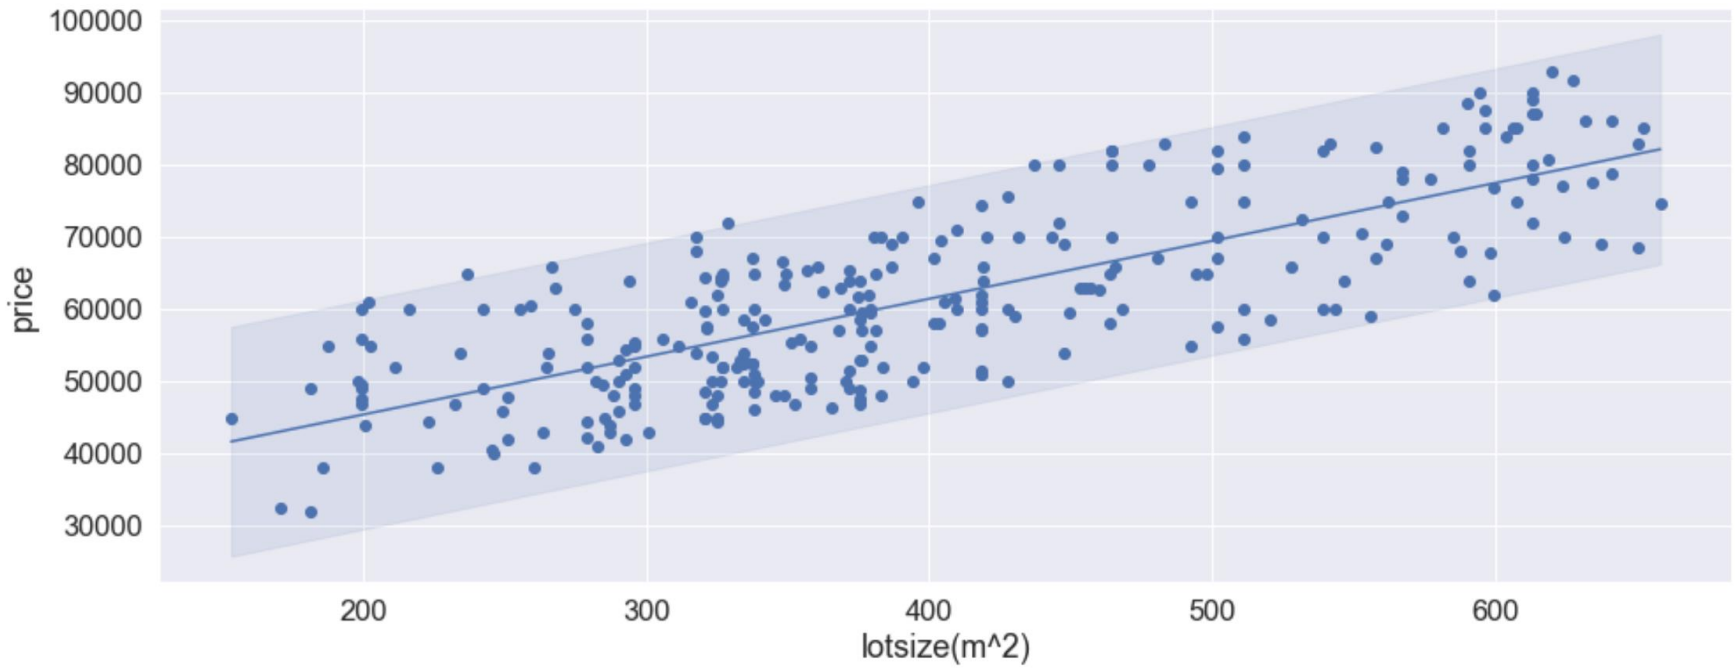

Zaključivanje o modelu linearne regresije – Interval predikcije – Primer cene kuća

- Pomoću *Python* biblioteke *statsmodels* izračunali smo interval predikcije sa pouzdanošću od 95% za kuću sa površinom 658.47m^2:

$$[66257.84, 98030.10]$$

- To znači da postoji verovatnoća od 95% da baš ovaj interval sadrži predikciju populacionog modela za x_d = 658.47m^2
- Interval je dosta širok imajući u vidu cenu u dolarima
- Širina je posledica relativno velike prosečne greške modela od 7993.22 dolara.
- Jedan od načina da se smanji prosečna greška je upotrebom dodatnih atributa pored površine placa – to je tema sledećeg predavanja
- Napomena: Povećanje skupa podataka je takođe dobar način da se smanji prosečna greška, ali proces pribavljanja novih podataka tipično nije lak