Programski prevodioci

05 Formalni jezici i automati

25-26

Dunja Vrbaški

Fakultet tehničkih nauka, Novi Sad

Prirodni jezik

- skup slova (azbuka, alfabet)
- skup reči građenih nad azbukom
- skup rečenica građenih nad skupom reči
- Reči prate pravila leksike
- Rečenice prate pravila sintakse jezika
- Rečenice prate pravila semantike jezika

Danas pada kiša.
Danas će padati kiša.
Danas je padala kiša.
~~*Je danas oni padala.*~~
~~*Juče će padati kiša.*~~ *?*

Rečnik – skup reči koje se nalaze u jeziku.
Skup pravila za prirodni jezik praktično predstavlja pravila konverzacije.
Pravila nisu jednostavna i teže se formalno opisuju.

Formalni jezici

Na formalan način opisujemo jezike i istražujemo njihove osobine.
Da li su neki jezici posebno zanimljivi ili korisni.

Alati:

- gramatike
- automati

Osnovni pojmovi

- Azbuka Σ - skup simbola
- Reč (string) ω - konačan niz simbola iz azbuke
- Prazna reč λ (ili ϵ) - reč (string) dužine 0

Obratiti pažnju – azbuka ne mora biti sačinjena od “slova”

karakteri → reči
reči → rečenice

Stepen alfabeta - n-ti stepen alfabeta je <u>skup reči</u> dužine n

$$\Sigma = \{0, 1\}$$

$$\Sigma^1 = \{0, 1\}$$
$$\Sigma^2 = \{00, 01, 10, 11\}$$
$$\Sigma^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$$
...

- u čemu je razlika između alfabeta i prvog stepena alfabeta?
- šta je nulti stepen?

$$\Sigma = \{0, 1\}$$ simboli

$$\Sigma^0 = \{\varepsilon\}$$ nije prazan skup

$$\Sigma^1 = \{0, 1\}$$ reči

$$\Sigma^2 = \{00, 01, 10, 11\}$$

$$\Sigma^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$$

...

Klinijeva zvezda - skup svih reči nad alfabetom uključujući i praznu

(nad alfabetom)

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \ldots = \bigcup_{i \geqslant 0} \Sigma^i$$

obratiti pažnju: reči su konačni nizovi simbola

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \ldots = \bigcup_{i \geqslant 0} \Sigma^i$$

$$\Sigma^+ = \Sigma^1 \cup \Sigma^2 \ldots = \bigcup_{i \geqslant 1} \Sigma^i = \Sigma^* \setminus \{\varepsilon\} = \Sigma^*\Sigma$$

$$\Sigma = \{0, 1\}$$
$$\Sigma^* = \{\varepsilon, 0, 1, 00, 01, 10, 11, \ldots., 1100101, \ldots.\}$$
$$\Sigma^+ = \{0, 1, 00, 01, 10, 11, \ldots., 1100101, \ldots.\}$$

Definicija: Neka je Σ neka azbuka. Svaki podskup L skupa svih reči Σ^* nad Σ zovemo jezik nad Σ.

Primetiti:

- Ne spominju se nikakva pravila ili gramatike
- Jezik je definisan kao rečnik, a ne preko nekih svojih pravila
- Nad jednom azbukom možemo imati više jezika (koliko?)

$$\mathcal{L} \subseteq \Sigma^*$$

$$\mathcal{L}_1 = \emptyset$$
$$\mathcal{L}_2 = \{\varepsilon\}$$
$$\mathcal{L}_3 = \Sigma^*$$

$$\mathcal{L}_4 = \{0\}$$
$$\mathcal{L}_5 = \{\varepsilon,\ 101,\ 111111\}$$
$$\mathcal{L}_6 = \{1,\ 11,\ 111,\ 11111, \ldots\}$$
$$\mathcal{L}_7 = \{01,\ 0001,\ 0101,\ 01111001, \ldots\}$$
$$\ldots$$

Primeri

$$\Sigma = \{a, b\}$$

$$L_1 = \{aaa, ab, baba\}$$

$$L_2 = \{a, aa, aaa, aaaa, \dots\}$$

$$L_3 = \{a, b, aabbb, aaab, aabb, \dots\}$$

$$L_4 = \{\varepsilon, a, b, aabbb, aaab, aabb, \dots\}$$

$$L_5 = \{\varepsilon, abba, bbba, baaab, ab, \dots\}$$

Konačan skup reči – možemo zapisati sve reči zapisati

Beskonačan skup reči – da li možda postoji neko pravilo? Da li se nekako formalno mogu opisati takvi jezici?

Koja su pravila?

$$\Sigma = \{a, b\}$$

$$L_1 = \{aaa, ab, baba\}$$

$$L_2 = \{a, aa, aaa, aaaa, \dots\}$$

$$L_3 = \{a, b, aabbb, aaab, aabb, \dots\}$$

$$L_4 = \{\varepsilon, a, b, aabbb, aaab, aabb, \dots\}$$

$$L_5 = \{\varepsilon, abba, bbba, baaab, ab, \dots\}$$

Leksika i sintaksa

Šta je jezik?
Koja su pravila?

Kako da stignemo do programiranja, automatizacije?
Još pojmova i tvrđenja.

- Jezik je bilo koji podskup konačanih reči nad alfabetom.
- I nad jezicima se uvodi operacija konakatenacije.

Konkatenacija - spajanje dva jezika gde novi jezik sadrži sve reči nastale konkatenacijom reči iz pojedinačnih jezika

$$L_1L_2 = L_1 \cdot L_2 = \{w = xy \mid x \in L_1 \wedge y \in L_2\}$$

$$\Sigma = \{0, 1\}$$
$$L_1 = \{00, 11\}$$
$$L_2 = \{\varepsilon, 1\}$$

$$L_1 L_2 = \{00, 11, 001, 111\}$$

$$L_1 = \{\varepsilon, 0, 00, 000, \ldots\}$$
$$L_2 = \{\varepsilon, 1, 11, 111, \ldots\}$$

$$L_1 \cdot L_2 = ?$$

$$L^n = \begin{cases} \{\varepsilon\}, & n = 0 \\ LL^{n-1}, & n \geqslant 1 \end{cases}$$

$$\Sigma = \{0, 1\}$$
$$L = \{00, 11\}$$

$$L^0 = \{\varepsilon\}$$
$$L^1 = \{00, 11\}$$
$$L^2 = \{0000, 0011, 1100, 1111\}$$
$$L^3 = ?$$

$$L^* = L^0 \cup L^1 \cup L^2 \ldots = \bigcup_{i \geqslant 0} L^i$$

$$L^* = L^0 \cup L^1 \cup L^2 \ldots = \bigcup_{i \geqslant 0} L^i$$

$$L^+ = L^1 \cup L^2 \ldots = \bigcup_{i \geqslant 1} L^i$$

Tvrđenje

$$L^+ = LL^*$$

$$L^+ \subseteq LL^*$$

$$x \in L^+$$

$$\rightarrow$$

$$x \in \bigcup_{i \geqslant 1} L^i$$

$$\rightarrow$$

$$\exists i,\ i \geqslant 1,\ x \in L^i = LL^{i-1}$$

$$\rightarrow$$

$$x \in \bigcup_{i \geqslant 1} L^i = \bigcup_{i \geqslant 1} LL^{i-1} = L \bigcup_{i \geqslant 1} L^{i-1} = L \bigcup_{i \geqslant 0} L^i = LL^*$$

$$LL^* \subseteq L^+$$

$$x \in LL^*$$

$$\rightarrow$$

$$x \in L \bigcup_{i \geqslant 0} L^i$$

$$\rightarrow$$

$$\exists i,\ i \geqslant 0,\ x \in LL^i$$

$$\rightarrow$$

$$x \in L \bigcup_{i \geqslant 0} L^i = \bigcup_{i \geqslant 0} LL^i = \bigcup_{i \geqslant 0} L^{i+1} = \bigcup_{i \geqslant 1} L^i = L^+$$

Intuitivno:

```
temp = 5
```

{jezik naredbe dodele} = {jezik identifikatora} {jezik dodele} {jezik literala}

Šta su afabeti, a šta reči (stringovi) ovih jezika?
Gde će se ovde negde pojaviti nešto što liči (ili jeste) + ili *?

Gramatike

Pravila na osnovu kojih se grade reči/stringovi

Mehanizam za generisanje

$$S_0 \rightarrow aS_1$$
$$S_1 \rightarrow aS_1$$
$$S_1 \rightarrow bS_1$$
$$S_1 \rightarrow \varepsilon$$

Automati

Prihvataju ili ne prihvataju određenu reč kao reč nekog jezika

Mehanizam za prepoznavanje

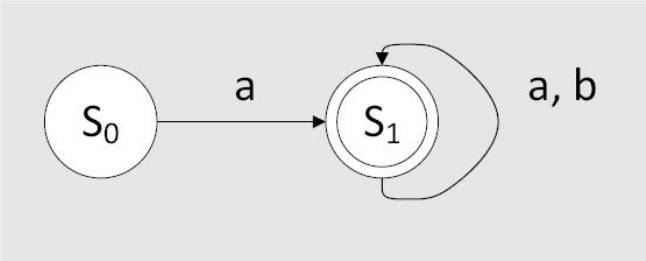

Zapravo su apstraktne mašine, matematičke konstrukcije, modeli računanja, ali imaju zgodnu vizuelnu reprezentaciju

Definicija: Gramatika je uređena četvorka $G = (\Sigma, N, P, S)$ gde je:

- Σ skup terminala (simbola)
- N skup neterminala (pojmova)
- P skup pravila izvođenja
- S početni pojam

- *Σ, N, P su neprazni, konačni, skupovi*
- $\Sigma \cap N = \varnothing$
- *P je skup pravila u obliku* $(\Sigma \cup N)^* N (\Sigma \cup N)^* \rightarrow (\Sigma \cup N)^*$

Definicija: Gramatika je uređena četvorka $G = (\Sigma, N, P, S)$ gde je:

- Σ skup terminala (simbola)
- N skup neterminala (pojmova)
- P skup pravila izvođenja
- S početni pojam

- *Σ, N, P su neprazni, konačni, skupovi*
- $\Sigma \cap N = \varnothing$
- *P je skup pravila u obliku $(\Sigma \cup N)^* N (\Sigma \cup N)^* \rightarrow (\Sigma \cup N)^*$*

Primer 1

$$S_0 \rightarrow aS_1$$
$$S_1 \rightarrow aS_1$$
$$S_1 \rightarrow bS_1$$
$$S_1 \rightarrow \varepsilon$$

Primer 2

$$S \rightarrow aSa$$
$$S \rightarrow bSb$$
$$S \rightarrow a$$
$$S \rightarrow b$$
$$S \rightarrow \varepsilon$$

Gramatika je alat koji omogućava generisanje svih reči koje pripadaju jeziku.

$S_0 \rightarrow aS_1$
$S_1 \rightarrow aS_1$
$S_1 \rightarrow bS_1$
$S_1 \rightarrow \varepsilon$

a
aa
aaab
ababa
...

Vratićemo se na gramatike...

Definicija: Deterministički konačni automat (DKA) je uređena četvorka $A = (S, \Sigma, \sigma, s_0, F)$ gde je:

- S - skup stanja
- Σ - alfabet
- σ - funkcija prelaza, σ: S x Σ → S
- s_0 - inicijalno stanje
- F - skup završnih stanja

DFA, Deterministic Finite Automaton

Definicija: Deterministički konačni automat (DKA) je uređena četvorka $A = (S, \Sigma, \sigma, s_0, F)$ gde je:

- S - skup stanja
- Σ - alfabet
- σ - funkcija prelaza, σ: S x Σ → S
- s_0 - inicijalno stanje
- F - skup završnih stanja

Primer

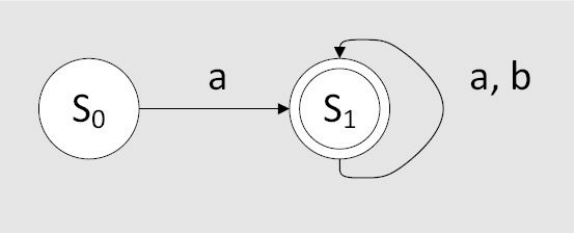

Definicija: Deterministički konačni automat (DKA) je uređena četvorka $A = (S, \Sigma, \sigma, s_0, F)$ gde je:

- S - skup stanja
- Σ - alfabet
- σ - funkcija prelaza, σ: S x Σ → S
- s_0 - inicijalno stanje
- F - skup završnih stanja

Primer

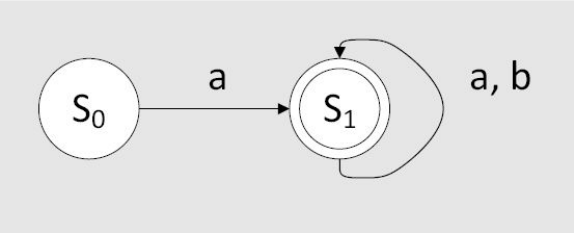

$\sigma(s_0, a) = s_1$

$\sigma(s_1, a) = s_1$

$\sigma(s_1, b) = s_1$

...

$\sigma(s_n, a_n) = s_{n+1}$

s_{n+1} pripada F?

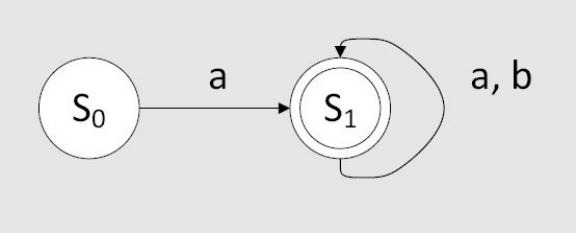

$\sigma(s_0, a) = s_1$

$\sigma(s_1, a) = s_1$

$\sigma(s_1, b) = s_1$

$\sigma(s_0, b) = ?$

Automat je alat koji omogućava prepoznavanje svih reči koje pripadaju jeziku.

Da li za određenu reč (string) završavamo u finalnom stanju?

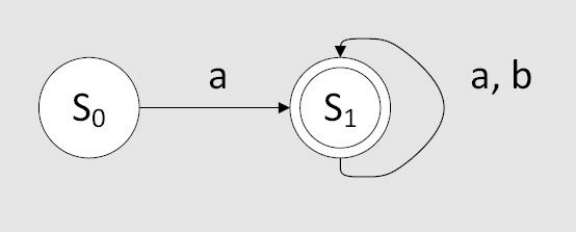

a
aa
aaab
ababa
...

Primer 1

$S_0 \rightarrow aS_1$
$S_1 \rightarrow aS_1$
$S_1 \rightarrow bS_1$
$S_1 \rightarrow \varepsilon$

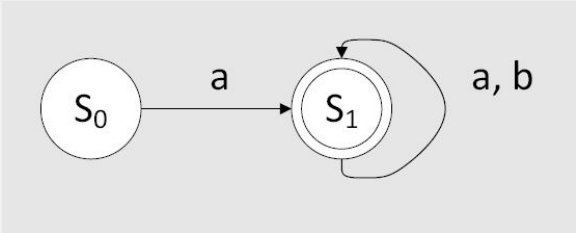

Primer 2

$S \rightarrow aSa$
$S \rightarrow bSb$
$S \rightarrow a$
$S \rightarrow b$
$S \rightarrow \varepsilon$

?

Ne mogu se svi formalni jezici predstaviti konačnim automatima.

Regularni jezici se mogu predstaviti konačnim automatima.

Postoje i druge klase jezika.

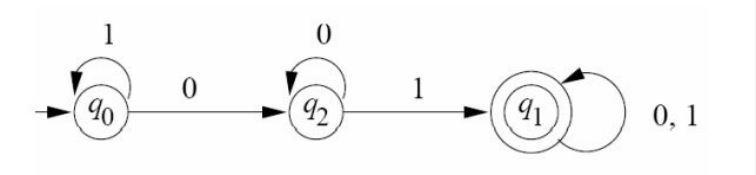

Koji jezik prihvata ovaj automat?

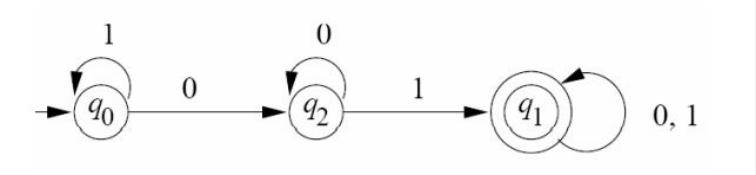

Koji jezik prihvata ovaj automat?

Reči imaju podstring 01.

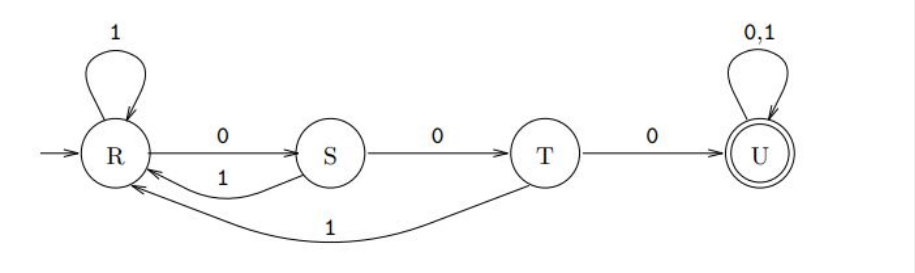

Koji jezik prihvata ovaj automat?

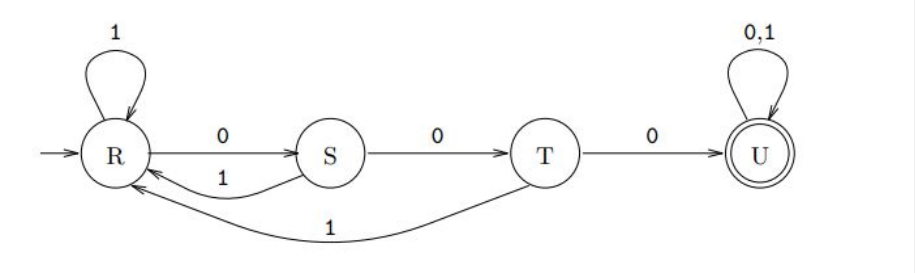

Koji jezik prihvata ovaj automat?

Reči imaju podstring 000.

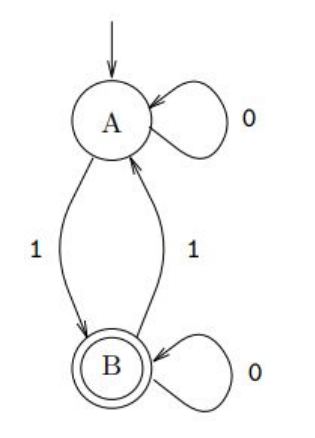

Koji jezik prihvata ovaj automat?

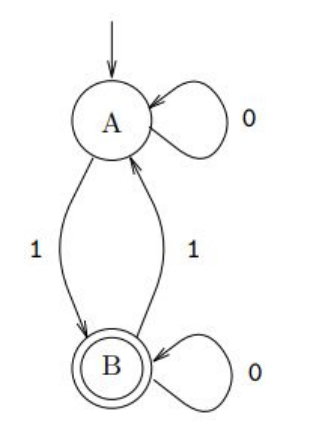

Koji jezik prihvata ovaj automat?

Reči imaju neparan broj simbola 1.

Da li od ovih automata možemo da napravimo automat koji proverava

- da li ima neparan broj 1 i ima podniz 000
- da li ima neparan broj 1 ili ima podniz 000
- da li ima neparan broj 1 i nema podniz 000
- da li ima paran broj 1 i ima podniz 000

Da li imamo sistematičan način da kombinujemo automate za bilo koje jezike?

Iz naše perspektive, zašto bi nam to bilo korisno?